Herramientas Econométricas

La Función de Esperanza Condicional (CEF)

Ricardo Pasquini

UCA

19 de octubre de 2026

Plan

- Motivación: describir el ingreso en la población
- La Función de Esperanza Condicional (CEF): definición, estimación y propiedades
- Estimar la CEF es un problema de datos: precisión vs. granularidad
- La regresión como una CEF paramétrica

Dos ejemplos a lo largo de la clase

1. Ingresos individuales en CABA (EAH): ejemplo principal.
2. Salarios en una empresa de tecnología (datos simulados, libro *Econometrics with Simulations*): nos permite jugar con el dashboard porque *conocemos* la CEF verdadera.

Objetivos

Al finalizar esta clase podrán:

1. Definir la CEF, $m(x) = E[Y \mid X = x]$, y reconocer su estimación como la generalización de "promediar por grupo" a cualquier variable X.
2. Estimarla empíricamente y explicar por qué la estimación se vuelve ruidosa cuando pocas observaciones comparten un valor de X.
3. Explicar por qué un modelo de regresión puede aproximar la CEF con menos datos, y qué se gana y qué se pierde.
4. Ubicar a $Y = \beta_0 + \beta_1 X + \varepsilon$ como un caso particular –lineal– de esta idea.

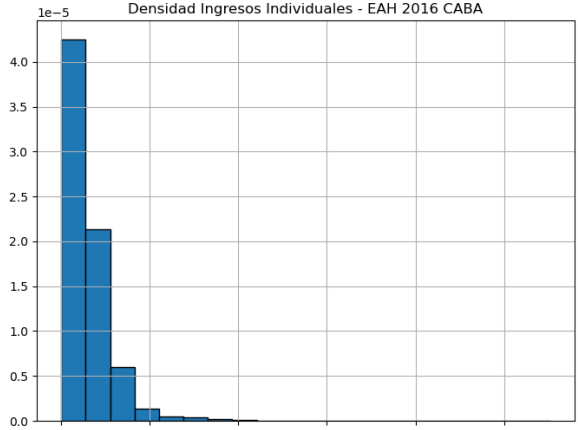
Distribuciones poblacionales

- Y es una *variable aleatoria* proveniente de una población con función de distribución acumulada (CDF)

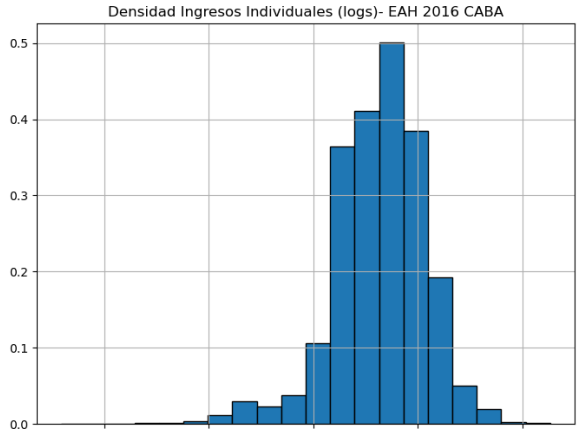
$$F(y) = \Pr(Y \leq y)$$

- Los factores explicativos $X_1, \ldots, X_k$ también son variables aleatorias, con sus propias distribuciones.
- Una variable aleatoria es una variable cuyo resultado es a priori desconocido y queda determinado por un experimento; aquí, por la extracción de un individuo de la población.

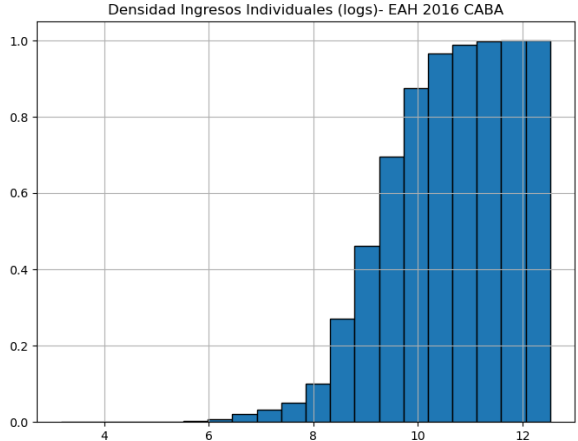
Distribución del ingreso – Densidad



Distribución del logaritmo del ingreso – Densidad



Distribución del ingreso – Densidad acumulada

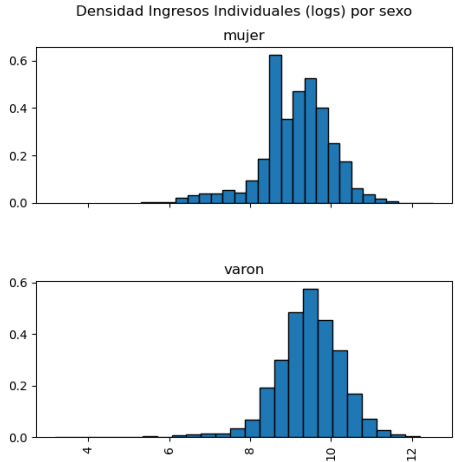


Distribución del ingreso por sexo

¿Explica el sexo la distribución del ingreso? ¿Varía la distribución del ingreso de acuerdo al sexo?

- Lo inspeccionamos gráficamente
- Usaremos el valor esperado condicional como una aproximación

Distribución del ingreso por sexo



Distribución del ingreso por sexo

Aproximación: promedio muestral

- Intuitivamente, un valor que sirve para describir la muestra es el promedio

$$\text{Avg}[Y \mid \text{sexo} = \text{hombre}] = 9{,}44 \qquad \text{Avg}[Y \mid \text{sexo} = \text{mujer}] = 9{,}13$$

sexo	count	mean	std	min	25 %	50 %	75 %	max
mujer	5324.000000	9.136385	0.877134	5.298317	8.612503	9.210340	9.718660	12.528156
varon	4789.000000	9.444136	0.813080	3.178054	8.987197	9.472705	9.928180	12.206073

Descripción de ingresos

Del promedio muestral a la esperanza condicional

- Nuestro objetivo no es sólo describir una muestra: queremos establecer una teoría a nivel *poblacional*.
- Proponemos la esperanza matemática de Y dentro de cada subpoblación:

$$E[Y \mid \text{sexo} = \text{hombre}] \qquad E[Y \mid \text{sexo} = \text{mujer}]$$

- ¿Y si en vez de una categoría, la variable condicionante es numérica (años de escolaridad, experiencia)?

Repaso: esperanza matemática

- $E[X]$ (a veces μ_X) es un promedio ponderado de todos los valores posibles de X; los pesos los da la densidad.
- Caso discreto, caso continuo:

$$E[X] = \sum_{j=1}^{k} x_j P(x_j) \qquad E[X] = \int_{-\infty}^{\infty} x f(x)\, dx$$

- Propiedades: $E[c] = c$; $E[aX + b] = aE[X] + b$; $E\left[\sum a_i X_i\right] = \sum a_i E[X_i]$

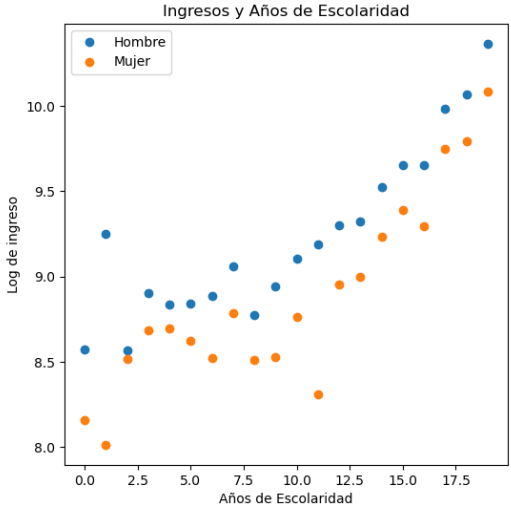
La Función de Esperanza Condicional (CEF)

- Es natural interesarse por el ingreso *de las mujeres*, *de los hombres*, *de quienes tienen 12 años de escolaridad*: subpoblaciones.
- La CEF es el valor esperado de Y condicional a $X = x$:

$$m(x) = E[Y \mid X = x]$$

- Es un objeto **poblacional**: una propiedad fija de la distribución conjunta de (X, Y), que no depende de ninguna muestra.
- Lo que calculamos con datos –promediar Y entre las observaciones con el mismo X– es una **estimación** de ese objeto, no el objeto en sí.
- Si X es categórica (sexo) basta promediar por categoría. Si X es numérica: agrupamos por cada valor posible y promediamos.

Ingresos y años de escolaridad: la CEF empírica



Un modelo simple: $Y = m(X) + \varepsilon$

- Definimos el error como $\varepsilon \equiv Y - m(X)$, de modo que

$$Y = m(X) + \varepsilon$$

- Hasta ahora escribíamos $Y = F(X) + \varepsilon$ con F desconocida. Bajo condiciones generales, la F que mejor describe la relación **es** la CEF: $F(x) = m(x)$.
- Propiedad del error:

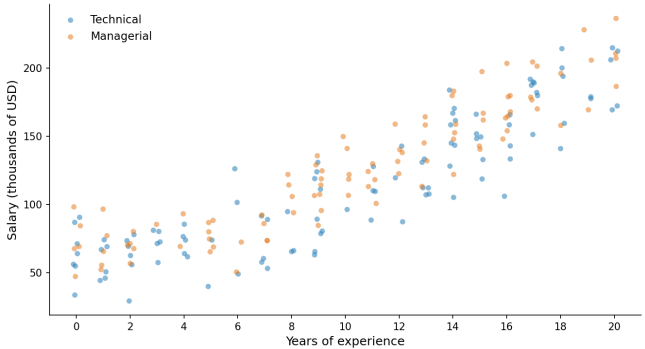
$$E[\varepsilon \mid X = x] = 0 \quad \text{para todo } x \quad \Rightarrow \quad E[\varepsilon] = 0$$

$$E[\varepsilon \mid X] = E[Y - m(X) \mid X] = E[Y \mid X] - m(X) = m(X) - m(X) = 0$$

Segundo ejemplo: una empresa de tecnología

Muestra de 200 empleados con tres datos por persona (datos simulados, por lo que conocemos la CEF verdadera):

- salario anual (en miles de USD),
- años de experiencia (valores enteros),
- *track* de carrera: **Técnico** o **Gerencial**.



Qué se ve en la nube de puntos

- La nube es ruidosa, pero a simple vista: los Gerenciales (naranja) están sistemáticamente por encima de los Técnicos (azul).
- Dentro de cada color, el salario sube con la experiencia, aunque no de manera prolija.

Pregunta guía

¿Cuál es la mejor forma de resumir esta nube con **un número por nivel de experiencia**, en vez de un número para todos?

Estimando un promedio por cada valor de experiencia

La experiencia se mide en años enteros: para cada valor, promediamos el salario de todos los empleados con exactamente esa experiencia.

$$\hat{m}(x) = \frac{1}{n_x} \sum_{i:\, X_i = x} Y_i$$

[Dashboard: CEF por bins (`cef_bins`)]

- Con $n = 50$: ¿qué tan consistentes son los puntos de la CEF empírica entre valores vecinos?
- ¿Los puntos más erráticos están sobre barras altas o bajas del conteo?
- ¿Qué pasa con la CEF agregada al prender y apagar "Separar por track"?
- Con $n = 5000$: ¿cambiaron los datos o cambió el estimador?

Dashboard: CEF por bins, $n = 50$

Parámetros de la simulación

Tamaño de muestra (n)

50 | 200 | 1000 | 5000

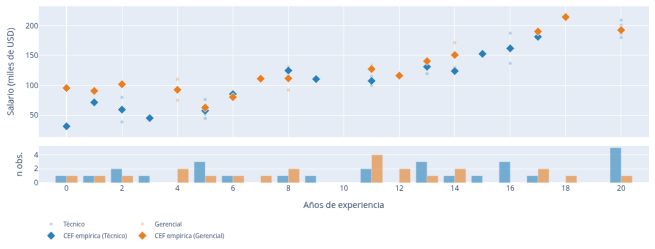
Separar por track (Técnico / Gerencial)

Mostrar CEF poblacional (verdadera)

Estadísticas por valor de experiencia

Años de experiencia	n (Técnico)	Media (Técnico)	n (Gerencial)	Media (Gerencial)
0	1	31.4	1	95.5
1	1	71.5	1	90.7
2	2	59.4	1	101.8
3	1	45.2	0	–
4	0	–	2	92.5
5	3	57.6	1	62.8
6	1	85.3	1	80.3
7	0	–	1	111.1
8	1	124.7	2	111.6
9	1	110.5	0	–
10	0	–	0	–
11	2	107.4	4	127.3
12	0	–	2	116.2

Dispersión y CEF empírica



Dashboard: CEF por bins, $n = 5000$

Parámetros de la simulación ?

Tamaño de muestra (n)

50 | 200 | 1000 | **5000**

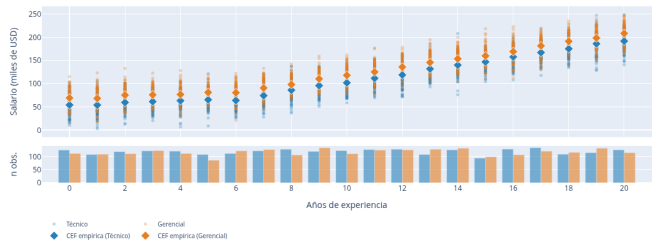
Separar por track (Técnico / Gerencial)

Mostrar CEF poblacional (verdadera)

Estadísticas por valor de experiencia ?

Años de experiencia	n (Técnico)	Media (Técnico)	n (Gerencial)	Media (Gerencial)
0	126	54.4	113	69.4
1	109	54.1	110	68.5
2	120	59.7	112	75.6
3	123	61.6	124	76.2
4	122	63.5	113	76.9
5	109	65.6	87	81.4
6	113	64.1	123	80.7
7	123	74.5	128	90.9
8	129	86.4	107	98.3
9	121	96.0	135	110.6
10	124	102.2	112	118.3
11	128	111.8	126	125.3
12	129	119.0	127	126.1

Dispersión y CEF empírica ?



Estimar la CEF es, fundamentalmente, un problema de datos

- A medida que crece la cantidad de celdas (valores distintos de X) respecto del tamaño de muestra, cada celda recibe menos observaciones y su promedio se vuelve más variable.
- No es una falla de la CEF: $m(x)$ es un objeto poblacional bien definido y su estimador es **insesgado** (ver demostración A.1).
- El problema es de **precisión**, no de sesgo:

$$\mathrm{Var}(\hat{m}(x)) = \frac{\mathrm{Var}(Y \mid X = x)}{n_x}$$

- Hay un trade-off genuino entre **granularidad** (cuántos valores de X distingo) y **precisión** (qué tan confiable es el promedio en cada uno).
- Mismo problema en el ejemplo de ingresos: pocas observaciones en los extremos de escolaridad.

La CEF como mejor predictor

- Dado X, buscamos una función $g(X)$ que prediga Y lo mejor posible, en el sentido de minimizar el error cuadrático medio:

$$\min_{g} \; E\left[(Y - g(X))^2\right]$$

- **Resultado:** la solución es $g(x) = m(x) = E[Y \mid X = x]$. Ninguna otra función de X, lineal o no, predice mejor en promedio (demostración A.3).
- Desventaja práctica: no siempre es fácil estimar $m(x)$ (pocos datos en el x de interés), ni conocemos su forma funcional.

Una forma más eficiente de aproximar la CEF

- Promediar por cada valor de X divide la muestra en compartimentos cada vez más chicos: ganamos resolución, perdemos precisión.
- Un **modelo paramétrico** (una recta, una recta con un quiebre) impone una forma funcional a $m(x)$ y la estima usando **toda** la muestra a la vez.
- El modelo "toma prestada fuerza" de las observaciones vecinas en lugar de tratar cada valor de X como un problema aislado.
- Esa es, en esencia, la apuesta de un modelo de regresión.

CEF empírica vs. regresión: cara a cara

[Dashboard: De la CEF a una regresión (`cef_regression`)] Mismo conjunto de datos; elegimos un modelo y medimos la distancia (RECM) a la CEF poblacional verdadera.

- Con $n = 50$: ¿qué RECM es menor, "CEF por bins" o "Regresión + dummy y quiebre"?
- Con $n = 5000$: ¿mejora mucho la "Regresión agrupada" (que ignora el track y el quiebre)?
- ¿Cuál de los dos mejora más al pasar de $n = 50$ a $n = 5000$: CEF por bins, o regresión con dummy y quiebre?
- ¿Qué tienen en común los modelos que *no* mejoran con más datos?

Dashboard: CEF empírica, $n = 50$

Parámetros de la simulación

Modelo

- CEF empírica
- Regresión agrupada
- Regresión + dummy de track
- Regresión + dummy y quiebre

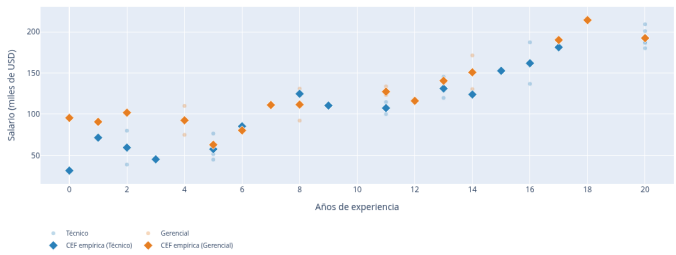
Tamaño de muestra (n_1)

50 | 200 | 1000 | 5000

Calidad de ajuste (RECM vs. CEF verdadera)

Modelo	RECM (miles USD)
CEF empírica	**16.21**
Regresión agrupada	11.74
Regresión + dummy de track	9.05
Regresión + dummy y quiebre	3.85

Dispersión, CEF empírica y ajuste del modelo



Dashboard: regresión agrupada, $n = 50$

Parámetros de la simulación

Modelo

- CEF empírica
- **Regresión agrupada**
- Regresión + dummy de track
- Regresión + dummy y quiebre

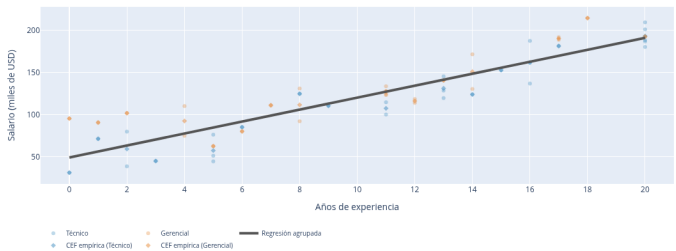
Tamaño de muestra (n)

50 | 200 | 1000 | 5000

Calidad de ajuste (RECM vs. CEF verdadera)

Modelo	RECM (miles USD)
CEF empírica	16.21
Regresión agrupada	**11.74**
Regresión + dummy de track	9.05
Regresión + dummy y quiebre	3.85

Dispersión, CEF empírica y ajuste del modelo



Dashboard: regresión + dummy y quiebre, $n = 50$

Parámetros de la simulación

Modelo

- CEF empírica
- Regresión agrupada
- Regresión + dummy de track
- **Regresión + dummy y quiebre**

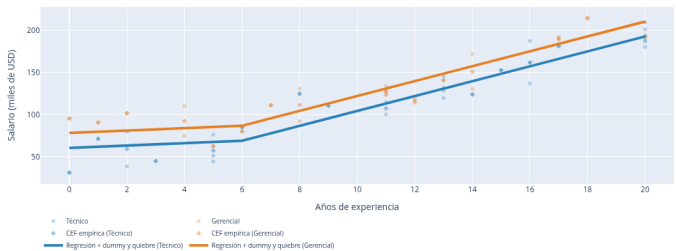
Tamaño de muestra (n_1)

50	200	1000	5000

Calidad de ajuste (RECM vs. CEF verdadera)

Modelo	RECM (miles USD)
CEF empírica	16.21
Regresión agrupada	11.74
Regresión + dummy de track	9.05
Regresión + dummy y quiebre	**3.85**

Dispersión, CEF empírica y ajuste del modelo



Dashboard: regresión agrupada, $n = 5000$

Parámetros de la simulación

Modelo

- CEF empírica
- **Regresión agrupada**
- Regresión + dummy de track
- Regresión + dummy y quiebre

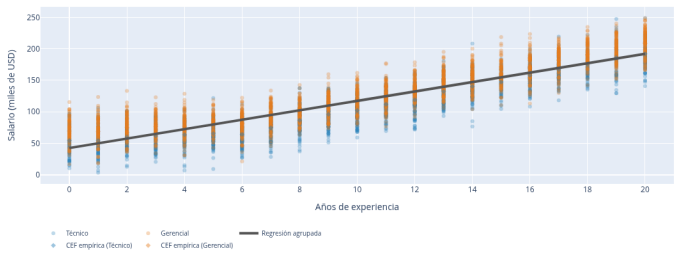
Tamaño de muestra (n)

50 | 200 | 1000 | **5000**

Calidad de ajuste (RECM vs. CEF verdadera)

Modelo	RECM (miles USD)
CEF empírica	1.50
Regresión agrupada	**11.27**
Regresión + dummy de track	8.41
Regresión + dummy y quiebre	0.38

Dispersión, CEF empírica y ajuste del modelo



Dashboard: regresión + dummy y quiebre, $n = 5000$

Parámetros de la simulación

Modelo

- CEF empírica
- Regresión agrupada
- Regresión + dummy de track
- **Regresión + dummy y quiebre**

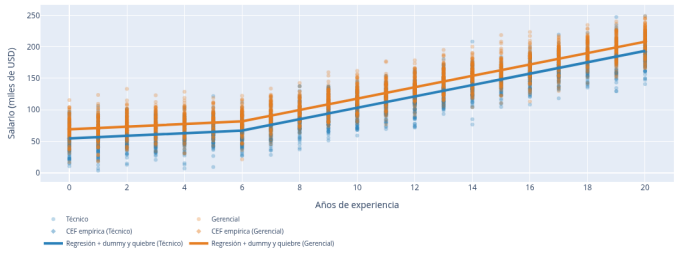
Tamaño de muestra (n)

50 | 200 | 1000 | **5000**

Calidad de ajuste (RECM vs. CEF verdadera)

Modelo	RECM (miles USD)
CEF empírica	1.50
Regresión agrupada	11.27
Regresión + dummy de track	8.41
Regresión + dummy y quiebre	**0.38**

Dispersión, CEF empírica y ajuste del modelo



Regresión como CEF paramétrica: el trade-off

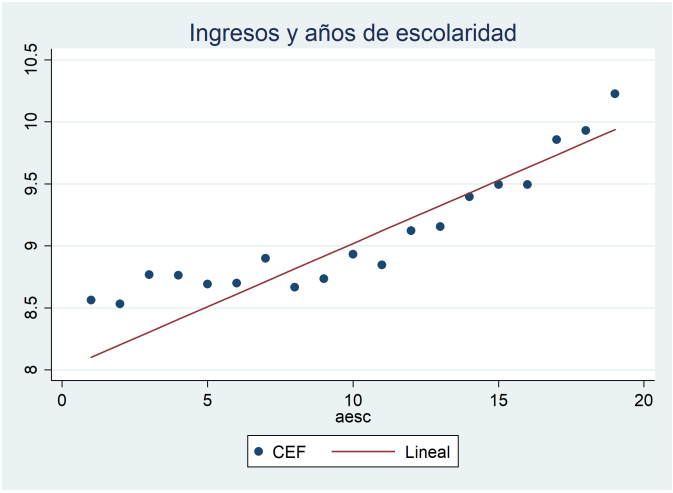
- Un modelo de regresión impone una forma funcional a $m(x)$ a cambio de necesitar mucha menos información en cada punto.
- **Forma funcional correcta** (recta con quiebre en el umbral de promoción + diferencia de nivel entre tracks): el modelo se acerca más a la CEF verdadera que la CEF empírica, incluso con muestras chicas.
- **Forma funcional incorrecta** (regresión agrupada): el modelo es **sesgado**, sistemáticamente errado en ciertas regiones, y ese error *no* se corrige con más datos. El ruido de la CEF empírica sí se reduce con la muestra.

En una oración

Comprometerse con una forma funcional a cambio de eficiencia es lo que organiza el resto de los capítulos de regresión.

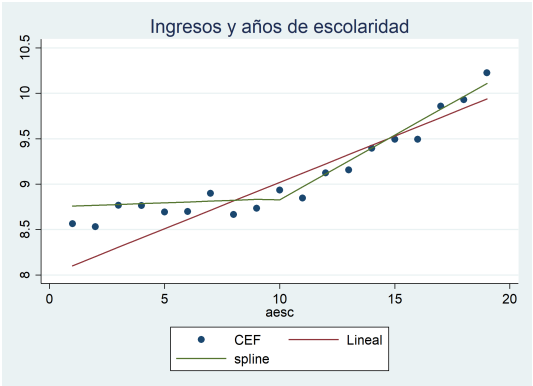
De vuelta a los ingresos: la forma funcional importa

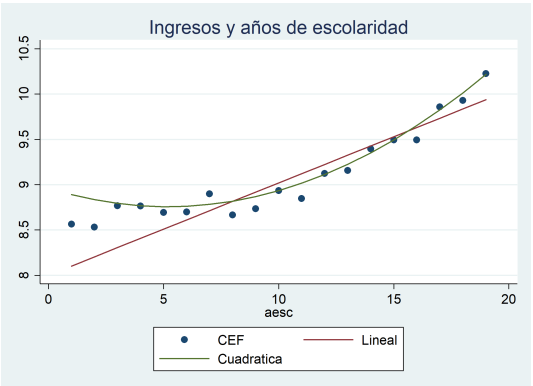
Proyección lineal vs. CEF



A veces la relación lineal es buena sólo en un segmento: un modelo lineal puede estar mal especificado.

De vuelta a los ingresos: flexibilizando la forma funcional





$\beta_1 + \beta_2 esc + \beta_3 (esc - 9) 1(esc \geq 9)$ $\beta_1 + \beta_2 exp + \beta_3 exp^2$

Spline (quiebre) y cuadrática: dos formas paramétricas de aproximar la CEF de log(ingreso).

Cierre y lo que viene

- La mejor F en $Y = F(X) + \varepsilon$, en el sentido del menor error cuadrático medio, es la CEF: $F(x) = m(x) = E[Y \mid X = x]$.
- Su estimación por promedios es insesgada pero ruidosa; una regresión es más eficiente *si* la forma funcional es razonable.
- **Próximo paso:** suponer que F es lineal, $Y = \beta_0 + \beta_1 X + \varepsilon$, y ver cómo se estima.
- Una simplificación honesta: en este ejemplo usamos dos variables explicativas (experiencia y track) para mostrar una no-linealidad y una diferencia entre grupos. Las próximas clases parten de una sola variable explicativa para construir la mecánica de la regresión, y luego reincorporan múltiples variables, incluidas las categóricas.

Práctica

Usando datos de la EAH CABA:

1. Analizar (gráficamente) la distribución del ingreso y
2. Aproximar el CEF $E[y \mid \text{escolaridad}]$
3. Graficar $E[y \mid \text{escolaridad}]$ vs. su mejor aproximación lineal
4. Estimar y graficar una proyección cuadrática para $E[y \mid \text{escolaridad}]$
5. Estimar y graficar un modelo tipo spline

Opcional: replicar en código el ejemplo de salarios (cuaderno `cef_notebook` del libro).

A.1 El promedio muestral por celda es insesgado para la CEF

Fijamos x y sea n_x el número de observaciones con $X_i = x$. El estimador es $\hat{m}(x) = \frac{1}{n_x} \sum_{i:X_i=x} Y_i$.
Cada Y_i de la celda es, por construcción, una extracción de la distribución de Y condicional a $X = x$, así que $E[Y_i \mid X_i = x] = m(x)$. Entonces

$$E\big[\hat{m}(x) \mid \text{celda}\big] = \frac{1}{n_x} \sum_{i:X_i=x} E[Y_i \mid X_i = x] = \frac{1}{n_x} \sum_{i:X_i=x} m(x) = m(x)$$

El sesgo es cero; lo que varía con n_x es la **precisión**: $\mathrm{Var}(\hat{m}(x)) = \mathrm{Var}(Y \mid X = x)/n_x$.

A.2 El error de la CEF tiene media condicional cero

Definimos $\varepsilon = Y - m(X)$. Condicional a $X = x$, $m(X)$ es una constante igual a $m(x)$:

$$E[\varepsilon \mid X = x] = E[Y - m(X) \mid X = x] = E[Y \mid X = x] - m(x) = m(x) - m(x) = 0$$

Vale para todo x, luego $E[\varepsilon \mid X] = 0$. Por la ley de esperanzas iteradas,

$$E[\varepsilon] = E\big[E[\varepsilon \mid X]\big] = 0$$

A.3 La CEF minimiza el error cuadrático medio de predicción

Para cualquier $g(X)$, sumamos y restamos $m(X)$:

$$\begin{aligned} E[(Y - g(X))^2] &= E\left[\left((Y - m(X)) + (m(X) - g(X))\right)^2\right] \\ &= E[(Y - m(X))^2] + 2E[(Y - m(X))(m(X) - g(X))] + E[(m(X) - g(X))^2 \end{aligned}$$

El término cruzado se anula por esperanzas iteradas y A.2:

$$E\Big[(m(X) - g(X)) \underbrace{E[Y - m(X) \mid X]}_{=0}\Big] = 0$$

Por lo tanto

$$E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2] \;\geq\; E[(Y - m(X))^2]$$

con igualdad sólo si $g = m$: la CEF es el único minimizador.