Herramientas Econométricas

Estructura del error y modelos de clasificación

Ricardo Pasquini

UCA

23 de octubre de 2026

Plan de la clase

1. **Heterocedasticidad**: qué pasa si la varianza del error no es constante
2. **Autocorrelación serial**: errores correlacionados en el tiempo
3. **Autocorrelación espacial**: errores correlacionados en el espacio
4. **Modelos de clasificación**: variable dependiente binaria (logit y probit)

Dos ejemplos a lo largo de la clase

1. Datos reales: ingresos y escolaridad en CABA (EAH 2016, $n = 10{,}048$); actividad económica argentina (EMAE, 1993–2013); precios de alquileres temporarios en Ámsterdam; ocupación en la EAH.
2. Datos simulados del libro *Econometrics with Simulations*: con los dashboards *conocemos* el proceso verdadero y podemos ver qué pasa en miles de muestras.

Objetivos

Al finalizar esta clase podrán:

1. Decir qué conserva MCO y qué deja de valer cuando se viola cada supuesto sobre los errores.
2. Diagnosticar heterocedasticidad, autocorrelación serial y autocorrelación espacial (gráficos y tests).
3. Corregir los errores estándar (HC, Newey-West, Conley o clusters) y saber cuándo conviene además modelar la dependencia.
4. Reconocer cuándo una "autocorrelación" es en realidad un **síntoma de mala especificación**.
5. Estimar e interpretar un modelo logit o probit, y calcular efectos marginales.

El hilo de la clase: ¿qué pasa si relajamos los supuestos sobre el error?

Hasta ahora usamos

$$\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I \quad \Longrightarrow \quad \mathrm{Var}(\hat{\beta} \mid X) = \sigma^2 (X'X)^{-1}$$

Es decir: **(i)** misma varianza para todos y **(ii)** errores no correlacionados entre observaciones.

	Insesgadez	Errores estándar	Eficiencia
Heterocedasticidad	se mantiene	**incorrectos**	se pierde
Correlación serial	se mantiene	**incorrectos**	se pierde
Correlación espacial	se mantiene	**incorrectos**	se pierde

- En los tres casos: **los coeficientes siguen siendo válidos**, pero **la incertidumbre que reportamos no**. Los tests t, los intervalos y los p-valores pueden engañarnos.
- Los tres tienen la misma solución general: reemplazar $\sigma^2 (X'X)^{-1}$ por un estimador tipo "**sándwich**".

Motivación: la fórmula de la varianza supone algo que no siempre vale

Para el modelo simple, la varianza de $\hat{\beta}_1$ que usamos hasta ahora es

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{SST_x}$$

y de ella salen el error estándar, los tests t y los intervalos de confianza.

- Para llegar ahí supusimos **homocedasticidad**: $\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma^2$ para todo i.
- En la práctica es difícil de sostener: la dispersión del error suele depender de los regresores, del tamaño de las unidades o del grupo.

Ejemplos

- Gasto vs. ingreso: un hogar de ingreso alto tiene un rango de gasto mucho más amplio.
- Salarios vs. tamaño de la empresa: más dispersión en las grandes.
- Datos de países: crecimiento más volátil en economías chicas y poco diversificadas.

Heterocedasticidad: definición

Homocedasticidad: $\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma^2$ para todo i.
Heterocedasticidad: $\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma_i^2$ varía entre observaciones.

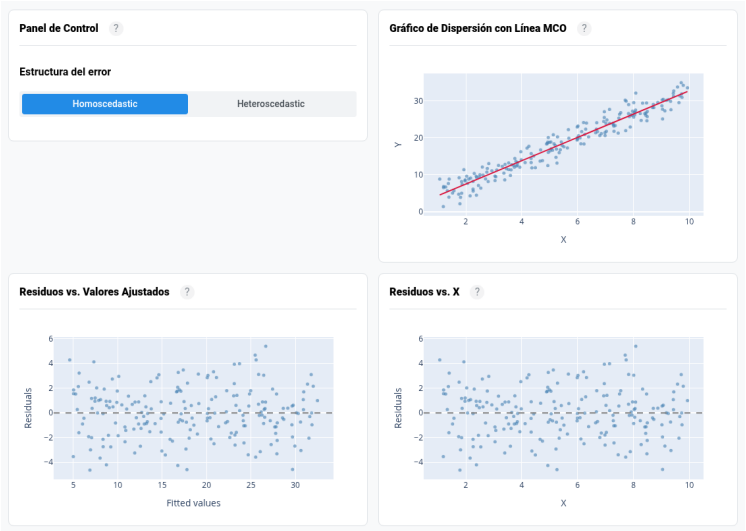
Patrones habituales:

- Varianza proporcional a X_i (o a X_i^2): la dispersión crece con el regresor.
- Varianza distinta por grupo: varones y mujeres, países desarrollados y en desarrollo.
- Varianza estructural: si y es una dummy, $\mathrm{Var}(y \mid x) = p(1-p)$ depende de x (lo veremos en la Parte D).

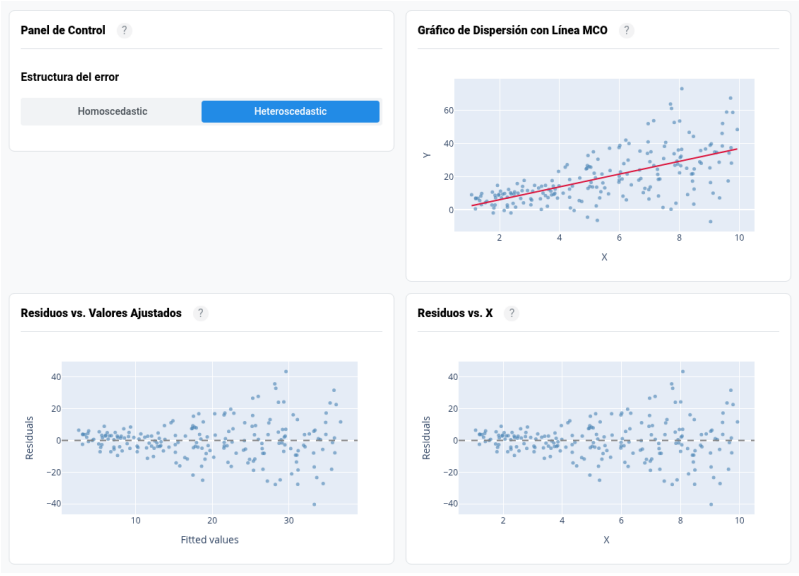
Diagnóstico visual: el gráfico de residuos contra valores ajustados. Un "embudo" que se abre hacia la derecha señala heterocedasticidad.

Dashboard: ¿cómo se ve la heterocedasticidad?

[Dashboard: heterosc_visual]

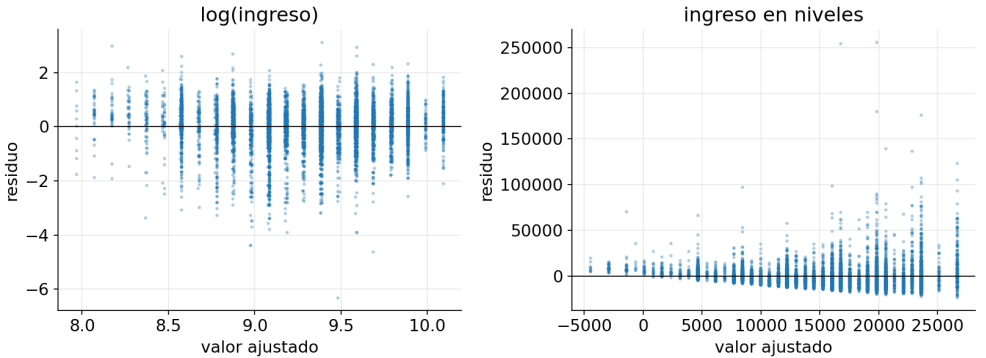


Dashboard: el embudo



Ejemplo real: ingreso y escolaridad (EAH 2016)

Modelo: $\log(\textit{ingreso}) = \beta_0 + \beta_1\, \textit{aesc} + \beta_2\, \textit{mujer} + \varepsilon \quad (n = 10{,}048)$



- **En logaritmos** el patrón es **leve**: la dispersión es parecida en todo el rango.
- **En niveles** el embudo es claro: quienes ganan más tienen residuos más dispersos. Es una de las razones por las que trabajamos con $\log(\textit{ingreso})$.

Qué le pasa a MCO: veámoslo con una simulación

Ponemos el "punto de vista de dios": generamos datos con errores homocedásticos o heterocedásticos, estimamos en 500 muestras y miramos:

1. ¿Se mueve el **centro** de la distribución de $\hat{\beta}_1$? ¿Cambia su **dispersión**?
2. ¿El centro de $\widehat{\mathrm{Var}}(\hat{\beta}_1)$ coincide con la varianza que **realmente** tiene $\hat{\beta}_1$?
3. ¿Con qué frecuencia los intervalos del 95 % contienen al β_1 verdadero?

[Dashboard: heteroscedasticity]

Dashboard: errores heterocedásticos, 500 simulaciones



Qué observamos

- **El estimador sigue centrado en el valor verdadero**: no hay sesgo.
- **La distribución es más ancha**: MCO pierde precisión.
- **La varianza estimada con la fórmula convencional está sesgada**: su centro no coincide con la varianza efectivamente observada entre simulaciones.
- **La cobertura cae por debajo del 95 %**: los intervalos y los tests construidos con el error estándar convencional ya no son válidos.

Conclusión provisoria

Con heterocedasticidad, los **coeficientes** de MCO siguen siendo buenos, pero la **inferencia** que hacemos con la fórmula usual no.

Resultados formales

1. Insesgadez se mantiene. La demostración solo usa $E[\varepsilon_i \mid X] = 0$, no la varianza constante:

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_i (x_i - \bar{x})\varepsilon_i}{SST_x} \;\Rightarrow\; E[\hat{\beta}_1 \mid X] = \beta_1$$

2. La varianza correcta cambia. Con $\mathrm{Var}(\varepsilon_i \mid X) = \sigma_i^2$:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sum_i (x_i - \bar{x})^2 \sigma_i^2}{SST_x^2} \;\neq\; \frac{\sigma^2}{SST_x}$$

En regresión múltiple es el **sándwich**:

$$\mathrm{Var}(\hat{\beta} \mid X) = (X'X)^{-1}\Big(\sum_i \sigma_i^2 x_i x_i'\Big)(X'X)^{-1}$$

3. Se pierde eficiencia. MCO sigue siendo lineal e insesgado, pero deja de ser MELI (Gauss-Markov requiere homocedasticidad): existe un estimador con menor varianza (MCP, más adelante).

Diagnóstico: tests formales

Ambos tienen como hipótesis nula la homocedasticidad.

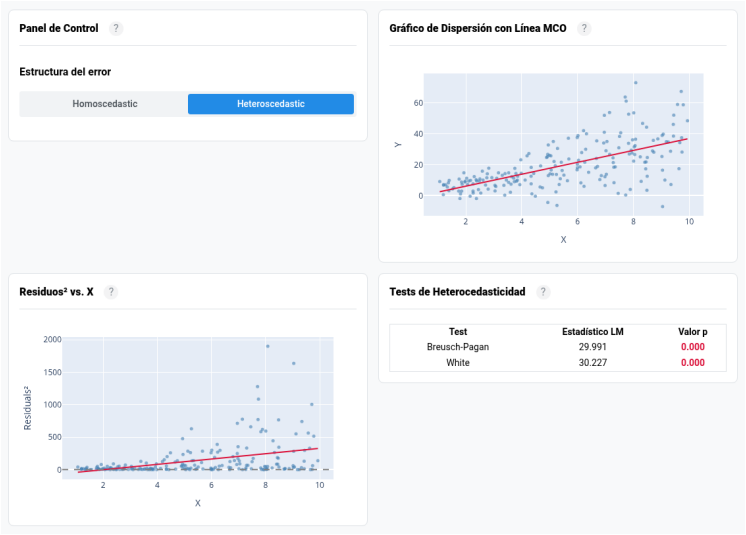
Test	Regresión auxiliar de $\hat{\varepsilon}_i^2$ sobre	Estadístico	Distribución
Breusch-Pagan	los regresores	$n \cdot R^2_{aux}$	$\chi^2(k)$
White	regresores, cuadrados y productos cruzados	$n \cdot R^2_{aux}$	$\chi^2(p)$

1. Estimar MCO y guardar los residuos $\hat{\varepsilon}_i$.
2. Calcular $\hat{\varepsilon}_i^2$ y regresarlo sobre las variables que indica el test.
3. Comparar $n \cdot R^2_{aux}$ con la distribución χ^2.

- Rechazar H_0 confirma que hay heterocedasticidad, **no** revela su forma ni cuánto importa.
- Con muestras grandes, los tests rechazan ante desvíos mínimos: hay que mirar también la **magnitud** del problema.

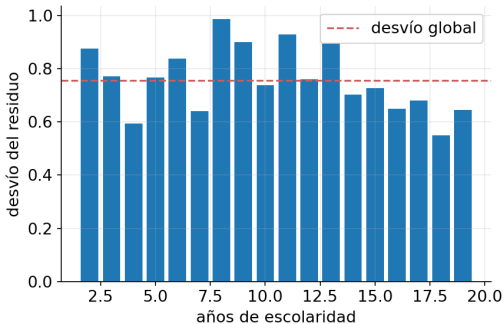
Dashboard: los tests en acción

[Dashboard: heterosc_diagnostics]



EAH: el test rechaza... ¿y entonces?

	log(*ingreso*)	*ingreso* en niveles
Breusch-Pagan: estadístico (p)	30.2 ($p < 0{,}001$)	83.8 ($p < 0{,}001$)
White: estadístico (p)	36.5 ($p < 0{,}001$)	124.9 ($p < 0{,}001$)



- Con $n = 10{,}048$ ambos tests **rechazan** la homocedasticidad incluso en logaritmos.
- Pero el desvío del residuo varía poco con la escolaridad (entre 0.63 y 0.80, sin un patrón creciente): el problema es **de magnitud moderada**.
- La pregunta relevante es: ¿cambian los errores estándar? Veamos la solución.

La solución I: errores estándar robustos (HC)

Idea de White (1980): **mantener los coeficientes de MCO** y estimar el sándwich reemplazando σ_i^2 por $\hat{\varepsilon}_i^2$:

$$\widehat{\mathrm{Var}}_{HC0}(\hat{\beta}) = (X'X)^{-1}\Big(\sum_i \hat{\varepsilon}_i^2 x_i x_i'\Big)(X'X)^{-1}$$

- **HC1**: multiplica por $n/(n-k)$ (corrección de grados de libertad). Es el estándar en economía aplicada.
- **HC2** y **HC3**: dividen cada $\hat{\varepsilon}_i^2$ por $(1-h_{ii})$ o $(1-h_{ii})^2$, con h_{ii} el *leverage*: más conservadores, mejores con muestras chicas o leverage dispar.
- No cambian $\hat{\beta}$: solo recalculan el error estándar.
- En `statsmodels`: `smf.ols(...).fit(cov_type='HC1')`.

Costo prácticamente nulo

Si los errores son homocedásticos, los errores robustos coinciden aproximadamente con los convencionales. Por eso se reportan por defecto.

Dashboard: comparando estimadores de la varianza

[Dashboard: robust_estimators]: sin corrección



Dashboard: con HC1



Qué observamos

- Con errores robustos los **estadísticos** t se parecen a la distribución t teórica y la **cobertura** se acerca al 95 %, sin tocar las estimaciones puntuales.
- HC2 y HC3 mejoran la cobertura en muestras chicas.
- Con errores homocedásticos todos los métodos coinciden: no hay penalidad por usar errores robustos.

EAH: errores estándar convencionales vs. robustos

	log(*ingreso*)		*ingreso* (niveles)	
	aesc	*mujer*	*aesc*	*mujer*
Coeficiente	0.1015	-0.2962	1517.4	-3797.2
EE convencional	0.0020	0.0151	33.2	248.5
EE HC1	0.0020	0.0150	37.7	250.0
EE HC3	0.0020	0.0150	37.7	250.0

- En logaritmos, los errores robustos son **prácticamente idénticos**: la heterocedasticidad estaba, pero no cambia la inferencia.
- En niveles el error estándar de *aesc* sube de 33.2 a 37.7 (el t baja de 45.7 a 40.3).
- Moraleja: **reportar siempre los errores robustos**; si coinciden con los convencionales, mejor.

La solución II: mínimos cuadrados ponderados (MCP)

Si $\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma^2 h(X_i)$ con h conocida, dividimos cada observación por $\sqrt{h(X_i)}$: el error transformado es homocedástico y MCO sobre el modelo transformado es **MELI**. Equivale a minimizar

$$\sum_i \frac{1}{h(X_i)} (y_i - \beta_0 - \beta_1 x_i)^2$$

- Da **más peso a las observaciones menos ruidosas**.
- En la práctica h es desconocida: se estima a partir de los residuos (MCG factible), por ejemplo regresando $\log \hat{\varepsilon}_i^2$ sobre los regresores.
- **Riesgo**: si h está mal especificada, los pesos pueden empeorar las cosas. Siempre reportar también MCO con errores robustos.

EAH (log): con $\log \hat{\varepsilon}_i^2$ sobre *aesc*, *aesc*^{2} y *mujer*: $\hat{\beta}_{aesc}^{MCP} = 0{,}1016$ (EE 0.0020) vs. 0.1015 (EE 0.0020) en MCO: casi idénticos, como era de esperar con heterocedasticidad leve.

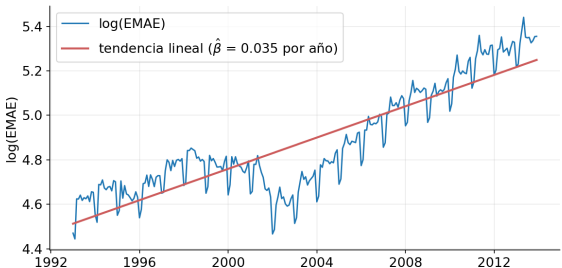
Resumen: guía práctica frente a la heterocedasticidad

1. **Mirar** siempre el gráfico de residuos contra valores ajustados.
2. **Testear** con Breusch-Pagan o White, pero juzgar la **magnitud** (¿cambian los errores estándar?).
3. Ante la duda: **errores robustos HC1** (HC3 si n es chico). Es el mínimo estándar.
4. Si la estructura de la varianza es estimable: MCP para ganar eficiencia, siempre acompañado de MCO + HC.
5. Los coeficientes de MCO **nunca** se descartan por heterocedasticidad: solo cambia la cuantificación de la incertidumbre.
6. Transformar la variable (por ejemplo, logaritmos) suele atenuar el problema.

Pausa

[Pausa]

Motivación: ¿cuánto crece tendencialmente la actividad económica?



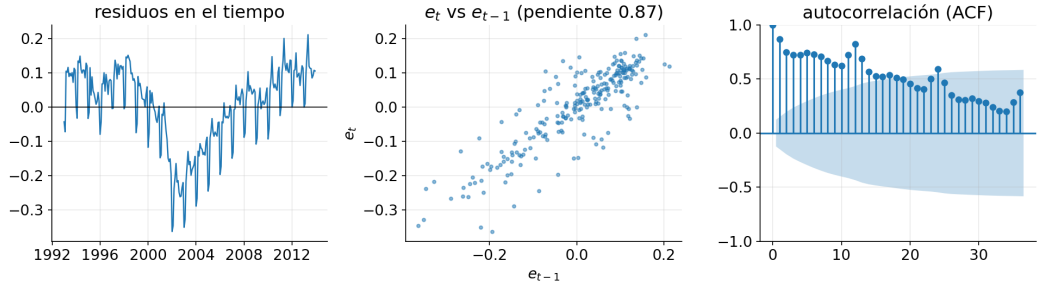
EMAE mensual, 1993–2013 ($T = 252$).
Modelo:

$$\log(EMAE_t) = \beta_0 + \beta_1\, t + \varepsilon_t, \quad t \text{ en años}$$

	$\hat{\beta}_1$	Error estándar	t	IC 95 %
MCO, EE convencional	0.0352	0.0012	29.3	[0.0328, 0.0376]
MCO, EE Newey-West ($L = 12$)	0.0352	0.0029	12.2	[0.0295, 0.0409]

Mismos datos, mismo coeficiente (3.6 % anual): el error estándar casi se **multiplica por 2.4**.
¿En cuál confiamos?

El problema: los errores de meses vecinos se parecen



- Los residuos forman **rachas**: muchos meses seguidos por encima de la tendencia y luego muchos por debajo (ciclo económico, crisis de 2001–2002).
- La autocorrelación de primer orden de los residuos es 0.87: casi no hay información nueva de un mes al siguiente.
- Los $T = 252$ meses contienen **mucha menos información independiente** que 252 observaciones.

Autocorrelación serial: definición

Se viola el supuesto de errores no correlacionados: $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) \neq 0$ para $t \neq s$.

El modelo más simple es el proceso autorregresivo de primer orden, **AR(1)**:

$$\varepsilon_t = \rho\, \varepsilon_{t-1} + u_t, \qquad |\rho| < 1, \quad u_t \text{ ruido independiente}$$

- $\rho > 0$: un error positivo tiende a ser seguido por otro positivo. $\rho < 0$: los signos se alternan.
- $\mathrm{Corr}(\varepsilon_t, \varepsilon_{t-s}) = \rho^s$ (decae geométricamente) y $\mathrm{Var}(\varepsilon_t) = \sigma_u^2/(1-\rho^2)$.
- **Origen**: factores omitidos que se mueven lento (ciclo, inercia, estacionalidad, shocks que se disipan de a poco).

Supuesto que mantenemos: los regresores son **estrictamente exógenos**, x_t no correlacionado con ningún ε_s (pasado, presente o futuro).

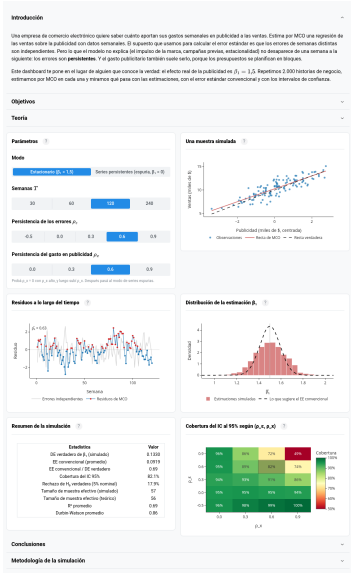
Qué le pasa a MCO: simulación de una empresa con ventas y publicidad

Ventas semanales dependen de la publicidad con efecto verdadero $\beta_1 = 1{,}5$. Los errores siguen un AR(1) con persistencia ρ_ε y la publicidad también es persistente (ρ_x). Repetimos esa historia 2.000 veces.

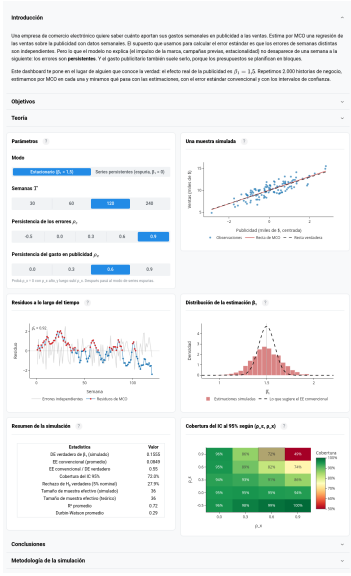
1. Con $\rho_x = 0$, ¿qué pasa al subir ρ_ε?
2. Si subimos también ρ_x: ¿qué pasa con el cociente entre el error estándar convencional y la dispersión verdadera, y con la cobertura?
3. ¿Se pueden ver las rachas en los residuos?

[Dashboard: serial_correlation_cost]

Dashboard: $\rho_\varepsilon = 0{,}6$, $\rho_x = 0{,}6$, $T = 120$



Dashboard: $\rho_\varepsilon = 0{,}9$, $\rho_x = 0{,}6$, $T = 120$



Qué observamos

- **El estimador sigue centrado en el valor verdadero**: MCO es insesgado.
- **Pero su distribución es más ancha de lo que creemos**: el error estándar convencional queda por debajo de la dispersión verdadera y los intervalos del "95 %" cubren bastante menos.
- **El daño requiere persistencia de ambos lados**: si $\rho_x = 0$ o $\rho_\varepsilon = 0$, el problema desaparece. Lo que importa es el **producto** $\rho_\varepsilon \rho_x$.
- Con $\rho_\varepsilon \rho_x < 0$ pasa lo contrario: el error convencional es demasiado grande.

Resultados formales: insesgadez y varianza

Insesgadez se mantiene: la demostración solo usa $E[\varepsilon_t \mid X] = 0$.

La varianza correcta incluye las covarianzas cruzadas:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{1}{SST_x^2} \sum_t \sum_s (x_t - \bar{x})(x_s - \bar{x}) \,\mathrm{Cov}(\varepsilon_t, \varepsilon_s)$$

La fórmula convencional σ^2 / SST_x conserva solo los términos $t = s$. Si x_t y x_s también están correlacionados, las covarianzas cruzadas **se suman** en lugar de cancelarse.

Con errores y regresor AR(1) y T grande:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) \approx \frac{\sigma^2}{SST_x} \cdot \frac{1 + \rho_\varepsilon \rho_x}{1 - \rho_\varepsilon \rho_x}$$

- Con $\rho_\varepsilon = \rho_x = 0{,}6$ el factor es 2.1: la varianza real es más del doble de la reportada.
- **Tamaño efectivo de muestra**: $T_{ef} \approx T \, \dfrac{1 - \rho_\varepsilon \rho_x}{1 + \rho_\varepsilon \rho_x}$.

EMAE: cuántas observaciones independientes tenemos

- El error estándar Newey-West es 2.4 veces el convencional. Como la varianza es el cuadrado, el tamaño de muestra **efectivo** es

$$T_{ef} \approx T \left(\frac{EE_{conv}}{EE_{HAC}} \right)^2 \approx 252 \times \left(\frac{0{,}0012}{0{,}0029} \right)^2 \approx 44 \text{ meses}$$

- Es decir, **21 años de datos mensuales equivalen, para esta regresión, a unas 44 observaciones independientes**.
- El estadístico t baja de 29.3 a 12.2: sigue siendo muy significativo, pero la inferencia es otra.
- Cuando la autocorrelación es menos extrema o el regresor menos persistente, la diferencia es menor.

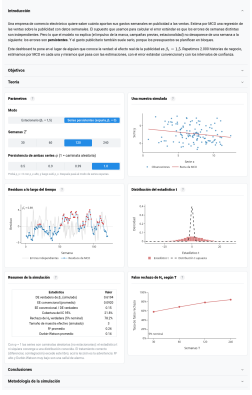
Efecto en las conclusiones

Con errores convencionales el IC es [0.0328, 0.0376]; con Newey-West es [0.0295, 0.0409]. El crecimiento tendencial es significativo, pero estimado con bastante menos precisión de lo que parecía.

El caso extremo: regresión espuria

Si dos series **independientes** son muy persistentes (caminatas aleatorias), al regresar una sobre otra obtenemos coeficientes "significativos" con una frecuencia muy superior al 5 %, un R^2 alto y un Durbin-Watson cercano a 0 (Granger y Newbold, 1974).

[Dashboard: serial_correlation_cost], modo *series persistentes*



Regresión espuria: la lección

- En el dashboard, con caminatas aleatorias independientes y $T = 120$, se rechaza $H_0 : \beta_1 = 0$ en alrededor del 80 % de las muestras, y el porcentaje **aumenta** con T.
- Las series no son estacionarias: el tratamiento correcto (diferenciar, cointegración) excede este curso.
- **Alarma**: un R^2 alto junto con un Durbin-Watson muy bajo **no es una buena noticia**.
- Nuestro ejemplo del EMAE: tendencia determinística + errores persistentes. $R^2 = 0{,}774$ y DW $= 0{,}26$. Es un caso para mirar con cuidado.

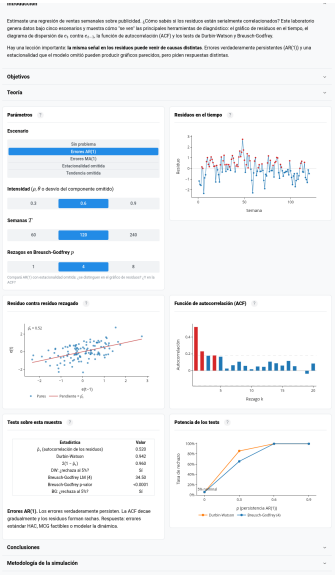
Diagnóstico I: mirar los residuos

- **Residuos en el tiempo**: rachas de igual signo.
- e_t **contra** e_{t-1}: una nube sin forma indica independencia; la pendiente estima ρ.
- **Función de autocorrelación (ACF)**: correlación entre e_t y e_{t-s} con bandas $\pm 1{,}96/\sqrt{T}$. Decae lentamente en un AR(1); se corta en un MA(1); muestra picos periódicos si hay estacionalidad omitida.

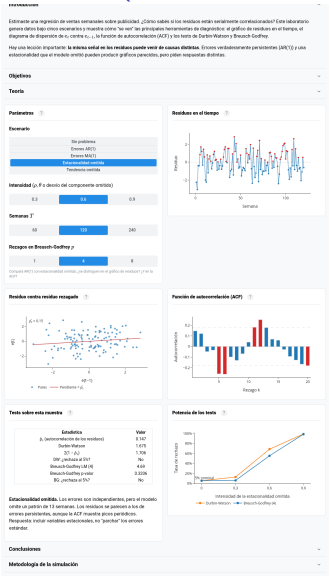
Explorar con el dashboard de diagnóstico: cinco escenarios (sin problema, AR(1), MA(1), estacionalidad omitida, tendencia omitida).

[Dashboard: serial_correlation_diagnostics]

Dashboard: errores AR(1), $\rho = 0{,}6$



Dashboard: estacionalidad omitida (errores independientes)



Diagnóstico II: Durbin-Watson y Breusch-Godfrey

H_0: no hay autocorrelación serial.

Durbin-Watson: $DW = \frac{\sum_{t=2}^{T}(e_t - e_{t-1})^2}{\sum_t e_t^2} \approx 2(1 - \hat{\rho}_1)$. Cerca de 2: sin correlación; menor a 2: positiva; mayor a 2: negativa.

Breusch-Godfrey: regresar e_t sobre los regresores originales y p rezagos de e_t; $LM = T \cdot R^2_{aux} \sim \chi^2(p)$.

Test	Detecta	Válido con y_{t-1} como regresor
Durbin-Watson	solo orden 1	No
Breusch-Godfrey	hasta orden p	Sí

- Número de rezagos p: 4 (trimestral), 12 (mensual), o el período de la estacionalidad esperada.
- En la práctica, Breusch-Godfrey es la elección más segura.

EMAE: los tests

Estadístico		Valor
Durbin-Watson	0.26	($\approx 2(1-\hat{\rho}_1)$ con $\hat{\rho}_1 = 0{,}87$)
Breusch-Godfrey (12 rezagos): *LM* (p)		221.4 ($p < 0{,}001$)

- Se rechaza claramente la ausencia de autocorrelación serial.
- Antes de corregir errores estándar, la pregunta clave es: **¿por qué hay autocorrelación?**

La autocorrelación como *síntoma*

- La estacionalidad o la tendencia omitidas generan residuos que **parecen** un AR(1) aunque los errores verdaderos sean independientes.
- En ese caso la solución no es estadística sino de **especificación**: incluir la variable que falta (dummies estacionales, un quiebre, un evento).
- Conecta con el sesgo por variable omitida de la clase anterior.

EMAE: la tendencia lineal ignora que la economía tuvo un quiebre alrededor de 2002. Con tendencia lineal por tramos (quiebre en julio de 2002):

	Pendiente antes	Pendiente después	DW
Tendencia única	0.0352	0.0352	0.26
Tendencia con quiebre	0.0126	0.0668	0.71

- El "crecimiento tendencial del 3.6 %" **mezclaba dos regímenes** muy distintos. El DW mejora (de 0.26 a 0.71) pero la autocorrelación sigue.
- Aun con la mejor especificación razonable, persiste dependencia: hace falta corregir la inferencia.

La solución I: errores estándar HAC (Newey-West)

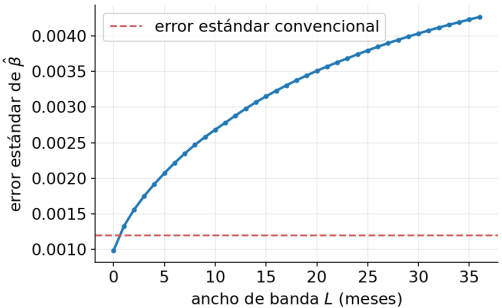
Mantener los coeficientes de MCO y estimar el sándwich incluyendo las autocovarianzas de los residuos hasta el rezago L:

$$\widehat{\mathrm{Var}}_{HAC}(\hat{\beta}) = (X'X)^{-1}\hat{S}\,(X'X)^{-1}, \quad \hat{S} = \hat{\Gamma}_0 + \sum_{\ell=1}^{L}\Big(1 - \frac{\ell}{L+1}\Big)(\hat{\Gamma}_\ell + \hat{\Gamma}_\ell')$$

con $\hat{\Gamma}_\ell = \sum_t e_t e_{t-\ell}\, x_t x_{t-\ell}'$ y pesos de Bartlett.

- Con $L = 0$ se obtiene el estimador de White (HC0): **HAC generaliza a HC**.
- **Elección de** L: muy corto ignora autocovarianzas relevantes; muy largo agrega ruido. Regla común: $L = \lfloor 4(T/100)^{2/9} \rfloor$ (para $T = 252$: $L = 4$).
- **Límite**: es un resultado asintótico; con muestras chicas y mucha persistencia sigue quedando corto. Tampoco corrige la ineficiencia de MCO.
- En `statsmodels`: `fit(cov_type='HAC', cov_kwds={'maxlags': L})`.

EMAE: la elección del ancho de banda

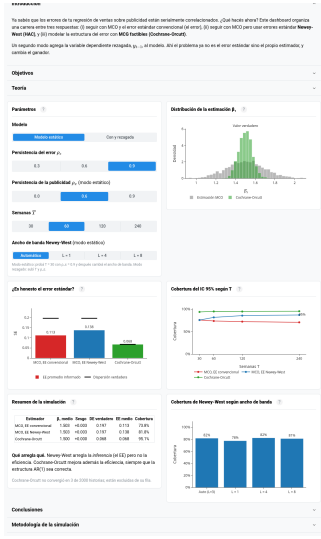


L	EE	t
0 (White)	0.0010	35.7
4 (regla)	0.0019	18.4
12	0.0029	12.2
24	0.0037	9.4

- Con $L = 0$ (solo heterocedasticidad) el EE es de hecho **menor** que el convencional: ignorar la correlación serial pesa más que la heterocedasticidad.
- El EE crece con L y se estabiliza: hay que **reportar la sensibilidad** a L.
- Conclusión robusta: la pendiente es significativa, con un t de entre 9.4 y 18.4.

Dashboard: comparando estimadores con autocorrelación

[Dashboard: serial_correlation_fixes], modo estático ($\rho_\varepsilon = 0{,}9$, $\rho_x = 0{,}6$, $T = 60$)



Cuidado con y_{t-1} como regresor

Si el modelo incluye y_{t-1} y los errores siguen correlacionados, el regresor deja de ser exógeno:

$$y_t = \beta_0 + \gamma\, y_{t-1} + \beta_1 x_t + \varepsilon_t, \qquad \mathrm{Cov}(y_{t-1}, \varepsilon_t) \neq 0$$

- MCO deja de ser consistente: no mejora con T. **Los errores HAC no lo arreglan**: corrigen la incertidumbre alrededor de un centro equivocado.
- Solución: especificar bien la dinámica (rezagos suficientes hasta que Breusch-Godfrey no rechace), o usar variables instrumentales.

[Dashboard: serial_correlation_fixes], modo *con y rezagada*

Dashboard: y_{t-1} como regresor, $T = 240$



Resumen: guía práctica frente a la autocorrelación serial

1. **Graficar** los residuos en el tiempo y su ACF.
2. **Breusch-Godfrey** para confirmar (Durbin-Watson como complemento rápido).
3. **Preguntarse primero si falta algo en el modelo**: estacionalidad, tendencia, un quiebre, un evento.
4. Si persiste: **errores HAC (Newey-West)** por defecto; reportar la sensibilidad al ancho de banda.
5. Si interesa la eficiencia: MCG factible o modelo con rezagos, siempre con MCO + HAC como chequeo.
6. Con y_{t-1} como regresor el problema es de **consistencia**, no de errores estándar.
7. Si la correlación es por grupos (hogares, ciudades), usar errores **clusterizados**.

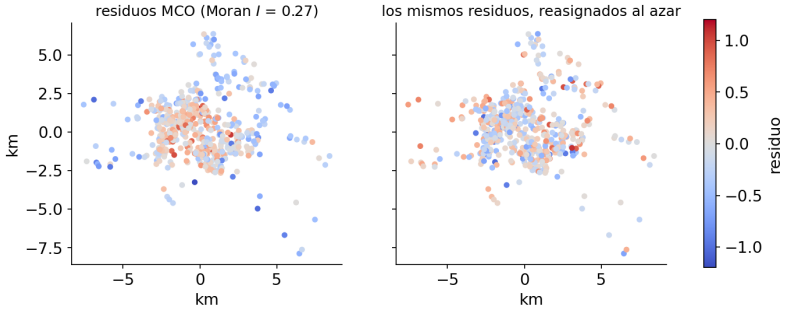
Pausa

[Pausa]

Motivación: alquileres temporarios en Ámsterdam

Regresión del log del precio por noche sobre capacidad y dormitorios, para 600 alojamientos (Inside Airbnb).

	Coef.	EE convencional (t)	EE Conley, 1 km (t)	EE clusters (barrio)
Capacidad	0.088	0.018 (4.8)	0.021 (4.1)	0.022
Dormitorios	0.124	0.025 (4.9)	0.029 (4.4)	0.028



En el mapa de la izquierda, los residuos del mismo signo **se agrupan** (Moran $I = 0{,}27$); a la derecha, los mismos residuos reasignados al azar.

Autocorrelación espacial: definición

Se viola el supuesto de errores no correlacionados a través de la geografía: $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$ cuando i y j están cerca.

Primera ley de la geografía (Tobler, 1970)

"Todo está relacionado con todo lo demás, pero las cosas cercanas están más relacionadas que las lejanas."

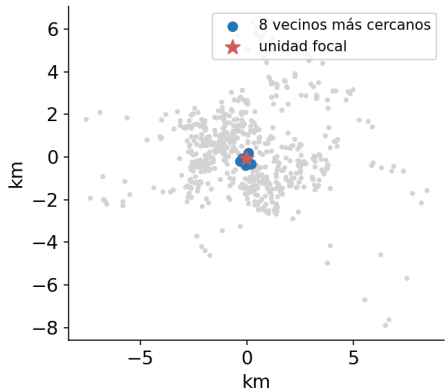
- Correlación positiva (la más común): parches de residuos altos junto a altos. Negativa: patrón de tablero de ajedrez.
- Es el mismo problema que la autocorrelación serial, con **distancia en lugar de tiempo**.
- **Obstáculo nuevo**: con N unidades hay N^2 covarianzas posibles y no se pueden estimar sin imponer una estructura. En el tiempo el orden da una estructura natural; en el espacio hay que **elegirla**.

La matriz de pesos W: traducir "cerca" en números

W es una matriz $N \times N$ con $w_{ij} > 0$ si j es vecino de i (y $w_{ii} = 0$):

- **Contigüidad**: comparten borde (torre) o borde y esquina (reina).
- k **vecinos más cercanos**.
- **Banda de distancia**: todos los que están a menos de un radio.

Se acostumbra **estandarizar por filas** (cada fila suma 1): $(Wy)_i$ es el promedio de y de los vecinos de i, el **rezago espacial**.



W es un supuesto, no un dato

La respuesta práctica no es buscar la W "verdadera" sino verificar que las conclusiones no cambian con alternativas razonables.

Proceso de error espacial

El análogo del AR(1) es el **proceso de error espacial**:

$$\varepsilon = \lambda W\varepsilon + u \qquad \Longleftrightarrow \qquad \varepsilon = (I - \lambda W)^{-1}u$$

con u ruido independiente y λ la intensidad de la dependencia: el error de cada unidad es un múltiplo del promedio de los errores de sus vecinos más ruido propio.

- $\lambda = 0$: errores independientes.
- ρ_x análogo: los regresores también pueden estar **agrupados** en el espacio (por ejemplo, promociones por zona).
- Mantenemos **exogeneidad estricta**. Más adelante veremos qué pasa cuando la dependencia está en el propio y (rezago espacial).

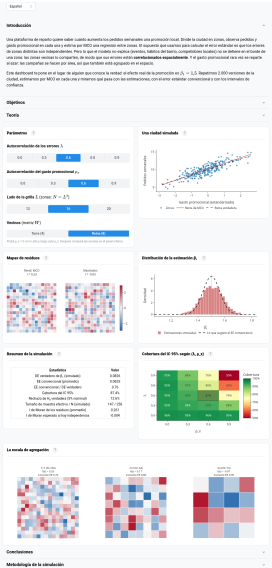
Qué le pasa a MCO: ciudad dividida en zonas

Pedidos semanales de una plataforma de delivery en zonas de una grilla; efecto verdadero de la promoción $\beta_1 = 1{,}5$. Demanda local no medida con dependencia espacial λ; promociones agrupadas por zona (ρ_x). Simulamos 2.000 ciudades.

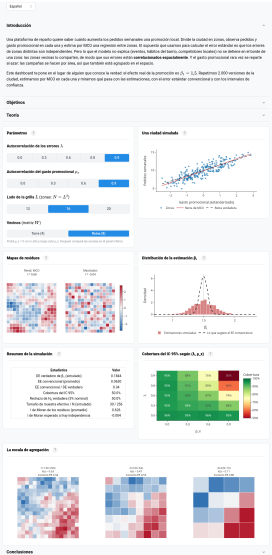
1. Con $\rho_x = 0$, ¿qué cambia al subir λ?
2. ¿Qué pasa al subir también ρ_x?
3. Comparar el mapa de residuos con el mismo mapa reasignado al azar. ¿Se ven parches?

[Dashboard: spatial_correlation_cost]

Dashboard: $\lambda = 0{,}6$, $\rho_x = 0{,}6$



Dashboard: $\lambda = 0{,}9$, $\rho_x = 0{,}9$



Qué observamos y resultados formales

- **Insesgadez se mantiene**: la demostración usa solo $E[\varepsilon \mid X] = 0$.
- **Los errores estándar convencionales son incorrectos**: la varianza correcta es el sándwich

$$\mathrm{Var}(\hat{\beta} \mid X) = (X'X)^{-1}X'\Sigma X(X'X)^{-1}, \quad \Sigma = \sigma_u^2[(I - \lambda W)'(I - \lambda W)]^{-1}$$

  mientras que la fórmula convencional supone $\Sigma = \sigma^2 I$.
- **Se necesita estructura espacial de ambos lados**: si $\rho_x = 0$ o $\lambda = 0$, el problema casi desaparece. En el ejemplo de Ámsterdam, los dormitorios no están agrupados en el espacio y la corrección fue chica.
- No hay un factor cerrado como en el caso serial; se define igual el **tamaño efectivo de muestra** $N_{ef} = N\,(\overline{EE}_{conv}/DE_{verd})^2$, que el dashboard calcula por simulación.
- También se pierde eficiencia (MCG pondera por Σ^{-1}).

Dependencia en y no es dependencia en los errores

- y puede estar fuertemente autocorrelacionado en el espacio (Moran alto) y los **residuos** no mostrar dependencia alguna: si los regresores explican el patrón geográfico (por ejemplo, la distancia al centro), no queda nada en el error.
- A la inversa, un Moran significativo *en los residuos* dice algo específico del modelo: falta una variable con estructura espacial, o hay interacciones no modeladas.
- Por eso **siempre se diagnostica sobre los residuos**, no sobre y.

Ámsterdam: el Moran del log precio es 0.14; el de los residuos de MCO, 0.27.

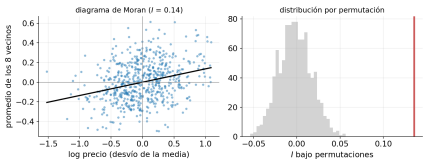
Diagnóstico I: mapas de residuos e índice de Moran

Mapa de residuos con escala divergente, comparado con una reasignación aleatoria. Es gratis y muy informativo.

Moran's I: análogo espacial de la autocorrelación de primer orden. Con $z_i = e_i - \bar{e}$ y W estandarizada por filas,

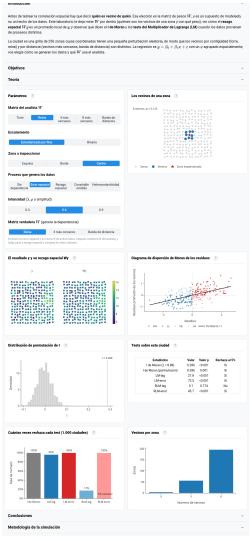
$$I = \frac{z'Wz}{z'z}$$

- $E[I] = -1/(N-1) \approx 0$ bajo la nula de ausencia de autocorrelación espacial.
- $I > 0$: vecinos parecidos; $I < 0$: vecinos distintos.
- Inferencia por **permutaciones**: se reasignan los valores al azar y se compara.
- El **diagrama de Moran** grafica Wz contra z: su pendiente es I.

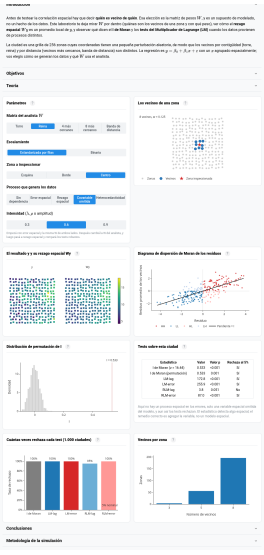


Dashboard: diagnósticos (error espacial, intensidad 0.6)

[Dashboard: spatial_correlation_diagnostics]



Dashboard: covariable omitida con estructura espacial



Diagnóstico II: tests LM (¿error o rezago?)

Moran dice que hay *algo* espacial; no dice qué. Los tests LM de Anselin usan solo los residuos de MCO para dos alternativas:

Test	Alternativa	Reacciona también a
Moran I (residuos)	Cualquier dependencia	variables omitidas, no linealidades
LM-error	Error espacial (SEM)	rezago espacial
LM-lag	Rezago espacial (SAR)	error espacial
LM-error / LM-lag robustos	Lo mismo, corrigiendo por la otra	menos sensibles a la otra

Regla: si solo rechaza un test robusto, esa es la dirección; si rechazan ambos, seguir el **mayor**.

Ámsterdam: Moran $I = 0{,}27$ ($p = 0{,}001$); LM-error 194, LM-lag 96; robustos: error 139, lag 41. La dependencia es de tipo **error**.

La dependencia espacial como *síntoma*

- En Ámsterdam el mapa muestra un patrón: los alojamientos céntricos están por encima de la recta y los periféricos por debajo. No es una dependencia misteriosa entre vecinos: **falta una variable**, la distancia al centro.
- Al agregarla, el Moran de los residuos baja de 0.27 a 0.09 y el LM-error robusto de 139 a 13.

	Sin distancia al centro	Con distancia al centro
Moran I de los residuos	0.27	0.09
LM-error robusto	139	13
LM-lag robusto	41	3
Coef. de dormitorios	0.124	0.166

- Es el mismo mensaje que en el caso serial: **primero especificar bien**, luego corregir la inferencia. Conecta con el sesgo por variable omitida.

La solución I: errores estándar espacialmente robustos

Conley (HAC espacial): mantiene los coeficientes y suma las covarianzas entre scores de unidades cercanas, ponderadas por distancia:

$$\widehat{\mathrm{Var}}_{Conley}(\hat{\beta}) = (X'X)^{-1}\Big[\sum_i \sum_j K\Big(\frac{d_{ij}}{h}\Big) e_i e_j \, x_i x_j'\Big](X'X)^{-1}, \quad K(u) = (1-u)_+$$

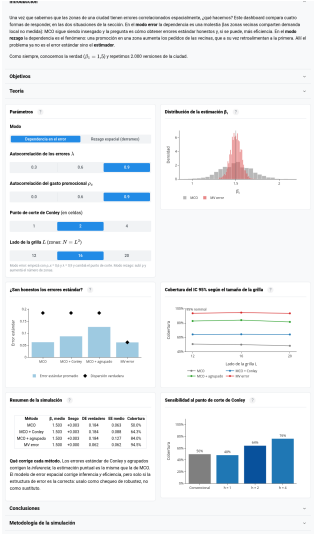
h es el **radio de corte**: análogo del ancho de banda L.

Clusters: permitir correlación arbitraria dentro de cada región (barrio, comuna) y ninguna entre regiones. Es la misma idea con una estructura de grupos en lugar de una distancia. Buen default si hay suficientes regiones y la dependencia no cruza los bordes.

Dormitorios (con distancia al centro)	Convencional	Clusters	Conley 1 km
EE	0.023	0.022	0.022

Dashboard: comparando correcciones (dependencia en el error)

[Dashboard: spatial_correlation_fixes], modo error ($\lambda = \rho_x = 0{,}9$)



Un puente con nuestro ejemplo: EAH y clusters por comuna

Los errores de personas de la misma comuna (o del mismo hogar) **comparten componentes**: es dependencia "espacial" en sentido amplio.

log(*ingreso*), coef. de *aesc* ($\hat{\beta} = 0{,}1015$)	EE	t
Convencional	0.0020	50.3
HC1	0.0020	50.9
Clusters por hogar (5.939 hogares)	0.0021	48.5
Clusters por comuna (15 comunas)	0.0037	27.4

- La heterocedasticidad y la dependencia entre miembros del hogar casi no importan.
- Pero al permitir correlación dentro de la comuna el error estándar de *aesc* **casi se duplica** (el t baja de 50.3 a 27.4): el 12.9 % de la varianza de *aesc* es entre comunas y el 1.5 % de la del residuo: regresor agrupado + error agrupado.
- Cuidado: con solo 15 clusters, los errores clusterizados son poco confiables. Es una cota de alerta, no un valor definitivo.

Límites y cautelas

- **Problema de la unidad espacial modificable (MAUP)**: los resultados dependen de la escala y la zonificación elegida. Agrupar los mismos datos en bloques mayores cambia las correlaciones, las pendientes y el número efectivo de observaciones. No hay agrupación "correcta": conviene mostrar robustez.
- **Falacia ecológica**: de una relación entre promedios de zonas no se infiere que valga entre los individuos.
- **Cambio de soporte**: mezclar datos puntuales con datos por área sin cuidado.
- Los efectos espaciales no siempre cambian las conclusiones (como vimos en Ámsterdam): diagnosticar, reportar inferencia robusta y dejar que la evidencia hable.

Resumen: guía práctica frente a la autocorrelación espacial

1. **Mapear** siempre los residuos.
2. Calcular **Moran de los residuos** y los tests LM (robustos) con algunas matrices W razonables.
3. **Preguntarse primero si falta algo**: distancia al centro, características locales, efectos fijos por zona.
4. Si persiste: errores estándar **espacialmente robustos** (Conley o clusters por región).
5. Si interesa eficiencia y la dependencia es ruido: modelo de error espacial (SEM), con MCO + robustos como chequeo.
6. Si los **derrames** son la pregunta: SAR, SLX o Durbin, interpretando efectos directos e indirectos; MCO es inconsistente bajo rezago espacial.

El hilo común: el estimador sándwich

$$\widehat{\mathrm{Var}}(\hat{\beta}) = (X'X)^{-1}\,\hat{S}\,(X'X)^{-1}$$

Problema	"Relleno" $\hat{S}$	Herramienta
Homocedástico, independiente	$\hat{\sigma}^2 X'X$	fórmula usual
Heterocedasticidad	$\sum_i e_i^2 x_i x_i'$	HC1, HC3
Correlación serial (tiempo)	incluye autocovarianzas hasta L	Newey-West (HAC)
Correlación espacial (distancia)	incluye covarianzas hasta el radio h	Conley
Correlación por grupos	permite correlación dentro de cada grupo	clusters

- En todos los casos los coeficientes de MCO **no cambian**; solo cambia cómo medimos su incertidumbre.
- Y en los tres casos, antes de corregir: **¿falta una variable en el modelo?**

Pausa

[Pausa]

Motivación: variable dependiente binaria

- ¿Qué determina que una persona esté **ocupada**? El resultado es binario: $y = 1$ si está ocupada, $y = 0$ si no.
- EAH 2016, personas de 25 a 60 años ($n = 6{,}894$; 84 % ocupadas). Regresores: años de escolaridad, edad, edad^2 y mujer.
- El reflejo natural: correr MCO con $y \in \{0, 1\}$. Es el **modelo de probabilidad lineal** (MPL):

$$E[y \mid x] = P(y = 1 \mid x) = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

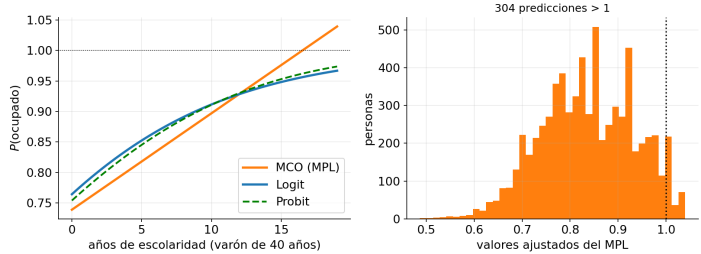
- β_j es el cambio en la probabilidad por unidad de x_j. Es simple y suele funcionar bien en el centro de la distribución, pero tiene dos fallas estructurales.

Las dos fallas del MPL

1. **Predicciones fuera de** $[0, 1]$. Nada impide que $\hat{\beta}_0 + \hat{\beta}_1 x$ sea negativa o mayor que 1.
2. **Heterocedasticidad estructural.** Como $y \sim \text{Bernoulli}(p)$:

$$\text{Var}(y \mid x) = p(1 - p)$$

depende de x por construcción, y no se elimina transformando el modelo lineal.
(Conecta con la Parte A: errores robustos HC en el MPL.)



En nuestro ejemplo

- El MPL estima que un año más de escolaridad aumenta la probabilidad de estar ocupado en 0.0158 (1.6 puntos porcentuales) y que ser mujer la reduce en -0.150.
- Pero para 304 personas (4.4 % de la muestra) predice una probabilidad **mayor que 1** (máximo 1.04).
- Solución: una función que mapee el índice lineal en $(0, 1)$ por construcción.

[Dashboard: binary_outcome]: comparar MCO, logit y probit (clientes de una empresa SaaS)

Dashboard: MCO

Introducción

Cuando la variable dependiente Y_i toma solo dos valores — 0 o 1 — el método de mínimos cuadrados ordinarios (MCO) puede aplicarse, pero presenta dos problemas estructurales:

1. **Predicciones fuera de rango:** La recta ajustada $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ puede producir probabilidades negativas o mayores a 1, lo que carece de sentido.
2. **Heterocedasticidad por construcción:** Como $Y_i \in \{0, 1\}$, la varianza del error $Y_i - p_i$ es igual a $p_i(1 - p_i)$, que varía con X. Esta es una violación estructural del supuesto de homocedasticidad de MCO.

Los modelos **Logit** y **Probit** resuelven los dos problemas modelando $P(Y = 1|X) = F(\beta_0 + \beta_1 X)$, donde F es la CDF logística o normal respectivamente, garantizando predicciones en $(0, 1)$.

Escenario: Una empresa de SaaS quiere predecir qué usuarios van a abandonar el servicio en los próximos 30 días. $Y_i = 1$ si el usuario i abandonó, 0 si permaneció. La variable explicativa es X_i = promedio de inicios de sesión por semana.

Objetivos de Aprendizaje

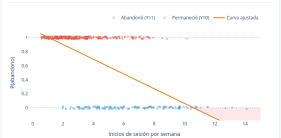
Los Tres Modelos

Parámetros de la Simulación

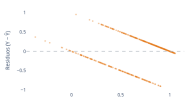
Modelo

MCO | Logit | Probit

Datos y Curva Ajustada



Residuos vs. Valores Ajustados



Resumen del Modelo

Métrica	Valor
β_1 estimado	-0.1050
Error estándar	0.0062
Valor p	< 0.001
P(abandono | X=2)	0.902
P(abandono | X=5)	0.587
P(abandono | X=10)	0.062
% predicciones fuera de [0,1]	9.0%
Log-verosimilitud	-208.95

Dashboard: logit



Qué observamos

- **MCO falla en las colas, no en el centro**: con probabilidad moderada y muestra grande, la pendiente del MPL es parecida a la de logit y probit.
- El problema aparece al **predecir**: con soporte amplio de X el MPL produce predicciones fuera de $[0, 1]$.
- Los residuos del MPL tienen una estructura de **dos bandas** (heterocedasticidad intrínseca).
- Logit y probit son similares entre sí; difieren sobre todo cuando la probabilidad se acerca a 0 o 1.

El modelo logit

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots)}} = \Lambda(x'\beta)$$

Λ es la función logística: mapea cualquier número real en $(0, 1)$. Su forma equivalente, lineal en los **log-odds**:

$$\ln \frac{P(y = 1 \mid x)}{1 - P(y = 1 \mid x)} = \beta_0 + \beta_1 x_1 + \cdots$$

- β_j es el cambio en los **log-odds** por unidad de x_j; equivalentemente, los odds se **multiplican por** e^{β_j}.
- Se estima por **máxima verosimilitud**.

Probit: $P(y = 1 \mid x) = \Phi(x'\beta)$, con Φ la normal estándar. Motivación: variable latente $y^* = x'\beta + \varepsilon$, $\varepsilon \sim N(0, 1)$, y $y = 1$ si $y^* > 0$. Logit y probit rara vez cambian las conclusiones.

Estimación por máxima verosimilitud

Idea: elegir los parámetros que hacen **más probable** la muestra que observamos. Para n observaciones independientes:

$$\ell(\beta) = \sum_{i=1}^{n} \left[y_i \ln \Lambda(x_i'\beta) + (1 - y_i) \ln \left(1 - \Lambda(x_i'\beta)\right) \right]$$

- No hay fórmula cerrada: se maximiza numéricamente (Newton-Raphson).
- Bajo condiciones estándar el estimador es consistente y asintóticamente normal: los errores estándar, tests z e intervalos se usan como siempre.
- Contraste con MCO: no hay R^2; se reporta el **pseudo-R^2** de McFadden, $1 - \ell(\hat{\beta})/\ell_0$.

EAH: $\ell(\hat{\beta}) = -2823{,}2$ frente a $\ell_0 = -3067{,}2$ (modelo sin regresores): pseudo-$R^2 = 0{,}080$.

EAH: ocupación, MPL, logit y probit

	MPL (MCO)	Logit	Probit
Escolaridad	0.0158	0.115	0.066
Mujer	-0.150	-1.219	-0.665
Efecto marginal promedio (AME): escolaridad	0.0158	0.0146	0.0149
Efecto marginal promedio (AME): mujer	-0.150	-0.154	-0.151

- Los **coeficientes** de logit y probit **no son comparables** con los del MPL ni son efectos marginales.
- Interpretación logit: un año más de escolaridad multiplica los odds de estar ocupado por $e^{0{,}115} = 1{,}122$ (+12 %). Ser mujer los multiplica por 0.296.
- Los **efectos marginales promedio** sí son comparables: MPL, logit y probit son muy parecidos (0.0158, 0.0146, 0.0149).

Efectos marginales: el efecto no es constante

Con logit y probit la pendiente de la probabilidad depende de *dónde* estemos:

$$\frac{\partial P(y=1 \mid x)}{\partial x_j} = f(x'\beta) \cdot \beta_j$$

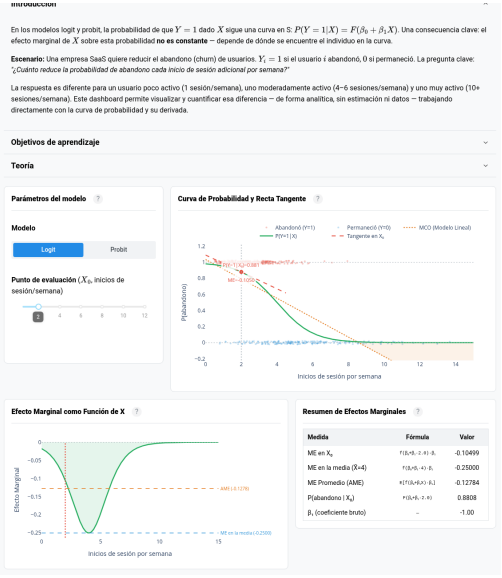
con $f = \Lambda(1-\Lambda)$ en logit y $f = \phi$ en probit. Se reportan tres resúmenes:

- **ME en un punto** x_0: la derivada evaluada en un perfil de interés.
- **ME en la media (MEM)**: evaluado en $\bar{x}$.
- **ME promedio (AME)**: $\frac{1}{n}\sum_i f(x_i'\hat{\beta})\,\hat{\beta}_j$. Es el más usado: tiene interpretación de efecto promedio en la población observada y es el análogo del coeficiente del MPL.

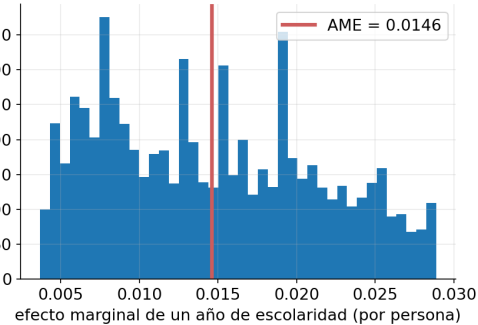
El efecto es máximo donde la probabilidad es 0.5 y tiende a cero en las colas.

[Dashboard: marginal_effects]

Dashboard: efectos marginales



EAH: el efecto de un año de escolaridad según el perfil



Varón de 40 años (logit):

	P(ocup.)	+1 año de esc.
7 años	0.88	0.0117
17 años	0.96	0.0044

- El efecto de un año más es **casi 3 veces mayor** para quien parte de 7 años de escolaridad que para quien parte de 17: cuanto más alta la probabilidad inicial, menos margen hay.
- El AME (0.0146) promedia esa heterogeneidad; el MEM da 0.0139.
- A los 12 años de escolaridad: varón 0.93 vs. mujer 0.79 de probabilidad de estar ocupado.

Cierre sobre bondad de ajuste y extensiones

- **Clasificar con umbral 0.5**: acierta en el 83.4 % de los casos, apenas por debajo del 83.7 % que se logra prediciendo "ocupado" siempre. Con una clase dominante, la tasa de aciertos es una medida pobre: conviene mirar la verosimilitud o curvas ROC.
- **Más de dos categorías sin orden** (por ejemplo, elegir comuna de residencia): **logit multinomial**, una ecuación por categoría respecto a una de referencia (ver apéndice y dashboard `multinomial_logit`).
- **Lo que no vimos**: modelos ordenados, datos de panel, inferencia causal con resultados binarios.

Resumen: guía práctica para variables dependientes binarias

1. El MPL es un buen primer paso: coeficientes interpretables y robustos si se usan errores HC (heterocedasticidad estructural).
2. Para predecir probabilidades o con colas: **logit** o **probit** (similares; elegir por convención).
3. Los coeficientes son log-odds (logit) o índices (probit): **reportar efectos marginales** (AME).
4. Los efectos marginales dependen del perfil: reportarlos en perfiles de interés además del promedio.
5. Estimación por máxima verosimilitud: pseudo-R^2 y log-verosimilitud en lugar de R^2.

Práctica

1. (EAH) Estimar log(*ingreso*) sobre *aesc*, *mujer*, *edad* y $edad^2$. Test de Breusch-Pagan; comparar errores convencionales, HC1 y clusters por comuna.
2. (EMAE) Agregar dummies mensuales al modelo de tendencia. ¿Cambia el DW? ¿Y el error estándar HAC? Probar $L = 4, 12, 24$.
3. (Ámsterdam) Cambiar W (4, 8, 16 vecinos) y comparar el Moran de los residuos y las conclusiones.
4. (EAH) Estimar un logit de ocupación agregando una interacción entre *aesc* y *mujer*. Calcular el AME de *aesc* por sexo.
5. (Dashboards) Encontrar un caso donde el error estándar convencional sea *demasiado grande* (pista: $\rho_\varepsilon \rho_x < 0$).

Apéndice: MCG factible (Cochrane-Orcutt)

Si creemos que los errores son AR(1), podemos explotar la estructura: restar ρ veces la ecuación en $t-1$ ("cuasi-diferencias") da un modelo con errores independientes:

$$y_t - \rho\, y_{t-1} = \beta_0(1-\rho) + \beta_1(x_t - \rho\, x_{t-1}) + u_t$$

- ρ se estima de los residuos de MCO y se itera hasta converger (Prais-Winsten conserva la primera observación).
- Es más eficiente que MCO *si* el AR(1) es correcto, y los regresores son estrictamente exógenos.
- **EMAE** (`GLSAR`): $\hat{\rho} = 0{,}87$, $\hat{\beta}_1 = 0{,}0356$ (EE 0.0046) frente a 0.0352 (EE HAC 0.0029). Con tanta persistencia el EE de MCG es incluso mayor: la ganancia depende de que el modelo sea el correcto.
- Práctica razonable: usar MCG como chequeo de robustez y siempre reportar MCO + HAC.

Apéndice: modelar el error espacial (SEM)

Si la dependencia está en los errores y es un parámetro de "ruido", se puede modelar:

$$y = X\beta + \varepsilon, \qquad \varepsilon = \lambda W\varepsilon + u$$

- Se estima por **máxima verosimilitud** (o MCG factible/GMM): gana eficiencia respecto de MCO.
- β **se interpreta igual** (mismo efecto marginal); λ es un parámetro de ruido.
- Como en MCG con serie temporal, la ganancia depende de que el modelo de error sea el correcto.

Ámsterdam (con distancia al centro): $\hat{\lambda} = 0{,}30$; $\hat{\beta}^{SEM}_{dorm} = 0{,}160$ (EE 0.022) frente a 0.166 con MCO. Prácticamente igual: ya no queda mucha dependencia en los residuos.

Apéndice: rezago espacial (SAR)

Si lo que pasa en una zona **causa** lo que pasa en las vecinas (derrames), el modelo es

$$y = \rho\, Wy + X\beta + \varepsilon, \qquad y = (I - \rho W)^{-1}(X\beta + \varepsilon)$$

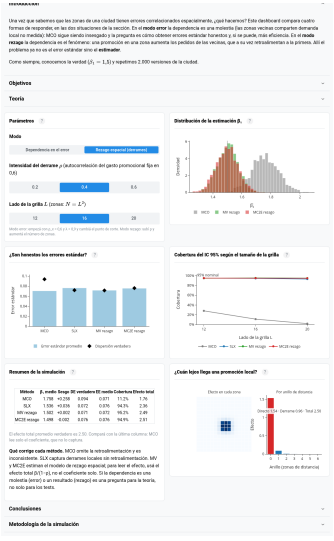
Es el análogo espacial de poner y_{t-1} en el modelo y trae el mismo peligro:

- Wy depende de los errores de los vecinos, que dependen de y_i: $\mathrm{Cov}(Wy, \varepsilon) \neq 0$ y **MCO es inconsistente**. Si omitimos Wy hay sesgo por variable omitida.
- Se estima por máxima verosimilitud o por MC2E usando WX y W^2X como instrumentos (con el problema usual de instrumentos débiles).
- **Cambia la interpretación**: β_1 ya no es el efecto marginal. El efecto de x_j sobre y_i es la entrada (i, j) de $(I - \rho W)^{-1}\beta_1$: **efecto directo**, **indirecto** (derrames) y **total**.

Ámsterdam (SAR, 8 vecinos): $\hat{\rho} = 0{,}21$; para un dormitorio adicional, efecto directo 0.166 y total 0.209.

Apéndice: dashboard de derrames (SAR)

[Dashboard: spatial_correlation_fixes], modo rezago espacial



A.1 Varianza de $\hat{\beta}_1$ con heterocedasticidad

De $\hat{\beta}_1 - \beta_1 = \sum_i (x_i - \bar{x})\varepsilon_i / SST_x$ y errores independientes:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sum_i (x_i - \bar{x})^2 \,\mathrm{Var}(\varepsilon_i \mid X)}{SST_x^2} = \frac{\sum_i (x_i - \bar{x})^2 \sigma_i^2}{SST_x^2}$$

Con $\sigma_i^2 = \sigma^2$: $\sigma^2 SST_x / SST_x^2 = \sigma^2 / SST_x$.

Con heterocedasticidad el numerador pondera cada $(x_i - \bar{x})^2$ por σ_i^2; el resultado depende de cómo se alinea la estructura de varianzas con la distribución de X.

A.2 Varianza de $\hat{\beta}_1$ con errores y regresor AR(1)

Con $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = \sigma^2 \rho_\varepsilon^{|t-s|}$, agrupando los pares por distancia $k = |t-s|$:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{SST_x}\Big[1 + 2\sum_{k=1}^{T-1} \rho_\varepsilon^k \, \hat{r}_k\Big], \qquad \hat{r}_k = \frac{\sum_{t=k+1}^{T}(x_t - \bar{x})(x_{t-k} - \bar{x})}{SST_x}$$

Si el regresor es AR(1) con persistencia ρ_x y T es grande, $\hat{r}_k \to \rho_x^k$ y

$$1 + 2\sum_{k\geq 1}(\rho_\varepsilon \rho_x)^k = 1 + \frac{2\rho_\varepsilon\rho_x}{1-\rho_\varepsilon\rho_x} = \frac{1+\rho_\varepsilon\rho_x}{1-\rho_\varepsilon\rho_x}$$

Por lo tanto la razón entre varianza verdadera y convencional es $\frac{1+\rho_\varepsilon\rho_x}{1-\rho_\varepsilon\rho_x}$ y $T_{ef} \approx T\,\frac{1-\rho_\varepsilon\rho_x}{1+\rho_\varepsilon\rho_x}$.

A.3 Durbin-Watson y la autocorrelación de los residuos

$$\sum_{t=2}^{T}(e_t - e_{t-1})^2 = \sum_{t=2}^{T} e_t^2 + \sum_{t=2}^{T} e_{t-1}^2 - 2\sum_{t=2}^{T} e_t e_{t-1}$$

Para T grande las dos primeras sumas son aproximadamente $\sum_t e_t^2$ (difieren en un extremo). Dividiendo por $\sum_t e_t^2$:

$$DW \approx 2 - 2\frac{\sum_t e_t e_{t-1}}{\sum_t e_t^2} = 2(1 - \hat{\rho}_1)$$

Si $\hat{\rho}_1 = 0$, $DW \approx 2$; si $\hat{\rho}_1 \to 1$, $DW \to 0$; si $\hat{\rho}_1 \to -1$, $DW \to 4$.

A.4 Efectos directos e indirectos en el modelo SAR

De $y = (I - \rho W)^{-1}(X\beta + \varepsilon)$, la derivada de y_i respecto de x_{jk} (variable k de la unidad j) es

$$\frac{\partial y_i}{\partial x_{jk}} = \left[(I - \rho W)^{-1}\right]_{ij} \beta_k$$

- **Efecto directo**: promedio de la diagonal, $\frac{1}{N}\mathrm{tr}\left[(I - \rho W)^{-1}\right]\beta_k$ (incluye la retroalimentación de los vecinos).
- **Efecto total**: promedio de la suma de cada fila, $\frac{1}{N} 1'(I - \rho W)^{-1} 1 \, \beta_k$.
- **Indirecto** = total − directo (derrames).
- Con W estandarizada por filas, el total es $\beta_k/(1 - \rho)$.

A.5 Logit: condiciones de primer orden

$\ell(\beta) = \sum_i [y_i \ln \Lambda_i + (1 - y_i) \ln(1 - \Lambda_i)]$ con $\Lambda_i = \Lambda(x_i'\beta)$ y $\Lambda' = \Lambda(1 - \Lambda)$:

$$\frac{\partial \ell}{\partial \beta} = \sum_i (y_i - \Lambda_i)\, x_i = 0$$

- Son las "ecuaciones normales" del logit: el residuo $y_i - \hat{p}_i$ es ortogonal a cada regresor (análogo a MCO). Con constante, $\sum_i \hat{p}_i = \sum_i y_i$.
- La matriz de información es $\sum_i \Lambda_i(1 - \Lambda_i) x_i x_i'$, y $\widehat{\mathrm{Var}}(\hat{\beta})$ su inversa.
- Se resuelve iterativamente: $\beta^{(m+1)} = \beta^{(m)} + \left[\sum_i \Lambda_i(1 - \Lambda_i) x_i x_i'\right]^{-1} \sum_i (y_i - \Lambda_i) x_i$.

A.6 Logit multinomial

Para J categorías sin orden, con la categoría 0 como referencia:

$$P(y = j \mid x) = \frac{e^{x'\beta_j}}{1 + \sum_{m=1}^{J-1} e^{x'\beta_m}}, \quad j = 1, \ldots, J-1$$

- Cada β_j describe el cambio en los log-odds de la categoría j *contra la referencia*.
- Los efectos marginales sobre cada probabilidad dependen de **todos** los β y de x; se reportan promedios (AME) por categoría.
- Supuesto: independencia de alternativas irrelevantes (IIA).
- Ejemplo: elección de comuna según ingreso y edad (EAH), en el notebook anterior de clasificación.