Herramientas Econométricas

Regresión Lineal Simple: Estimación, Propiedades e Inferencia

Ricardo Pasquini

UCA

21 de octubre de 2026

Plan de la clase

1. **Regresión lineal simple**: el modelo, estimación por MCO y bondad de ajuste
2. **Propiedades estadísticas** de los estimadores: insesgadez y varianza
3. **Tests de hipótesis** sobre el coeficiente de regresión

Dos ejemplos a lo largo de la clase

1. Ingresos y escolaridad en CABA (EAH 2016, $n = 10{,}048$): ejemplo principal; el mismo de la clase de CEF.

2. Campañas de publicidad digital (datos simulados, libro *Econometrics with Simulations*): nos permite jugar con los dashboards porque *conocemos* el modelo verdadero.

Objetivos

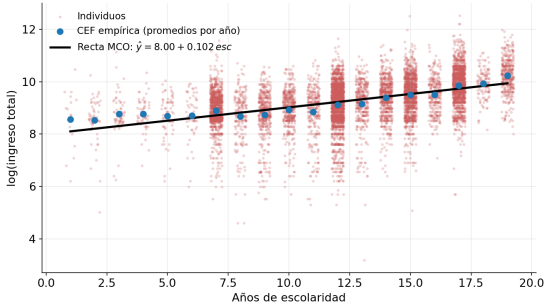
Al finalizar esta clase podrán:

1. Escribir el modelo $Y = \beta_0 + \beta_1 X + \varepsilon$ e interpretar cada uno de sus componentes.
2. Explicar qué criterio usa MCO, calcular $\hat{\beta}_0, \hat{\beta}_1$ e interpretarlos.
3. Descomponer la variación de Y (TSS = ESS + RSS), calcular e interpretar el R^2 y entender sus límites.
4. Entender al estimador como una *variable aleatoria*: demostrar y simular su insesgadez, y explicar de qué depende su varianza.
5. Estimar el error estándar y construir el estadístico t.
6. Realizar e interpretar un test de hipótesis: región de rechazo, p-valor, y la diferencia entre "no rechazar" y "aceptar".

De la CEF a la regresión

Repaso de la clase anterior

- La mejor función para predecir Y a partir de X es la CEF: $m(x) = E[Y \mid X = x]$.
- Estimarla promediando por cada valor de X es insesgado pero ruidoso, y poco práctico con X continuas.
- Una forma más eficiente: imponer una forma funcional y usar **toda** la muestra a la vez.
- Hoy, el caso más simple: una función **lineal**.



El modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- Y: variable **explicada**. Lo que queremos comprender o anticipar (log del ingreso, ingresos de una campaña).
- X: variable **explicativa**. Con lo que asociamos el comportamiento de Y (años de escolaridad, presupuesto publicitario).
- β_0: **intercepto**. Valor promedio de Y cuando $X = 0$.
- β_1: **pendiente**. Cuánto cambia Y, en promedio, cuando X aumenta en una unidad.
- ε: **error**. Todo lo que afecta a Y y no está en X: diferencias individuales, factores no observados, error de medición, azar.

Regresión *simple*: una sola variable explicativa. Más adelante incorporamos varias.

El error no es un fracaso del modelo

- Si la recta explicara exactamente todas las observaciones, no necesitaríamos econometría.
- ε es el reconocimiento explícito de que el mundo no es determinista.
- X y Y son variables aleatorias: cada observación (X_i, Y_i) es una extracción de la distribución conjunta, y el modelo describe cómo cambia la distribución de Y con X.
- Supuesto central (lo retomamos en la Parte 2):

$$E[\varepsilon \mid X] = 0$$

Los factores omitidos en ε no están sistemáticamente relacionados con X. Bajo este supuesto la recta describe la CEF: $E[Y \mid X] = \beta_0 + \beta_1 X$.

Los parámetros son desconocidos: necesitamos un criterio

- Conocemos la estructura, pero no β_0 ni β_1. Tenemos datos $(X_i, Y_i)_{i=1}^n$.
- Para cada recta candidata (b_0, b_1) hay predicciones y **residuos**:

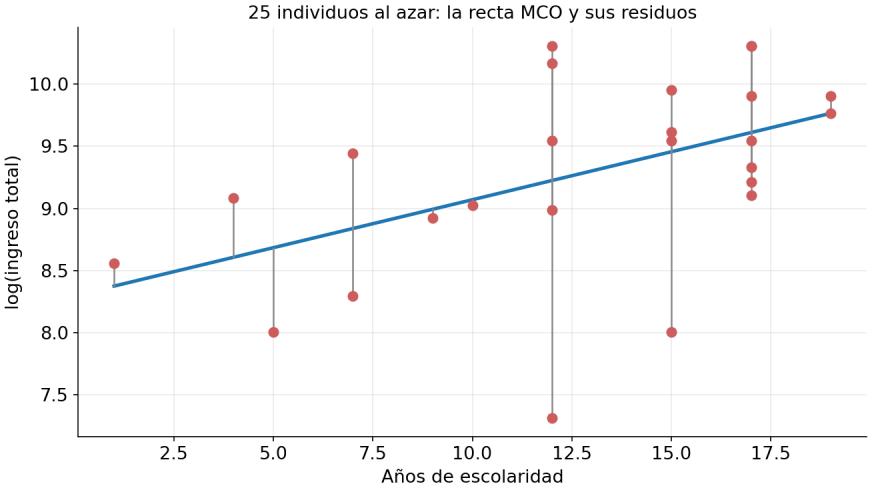
$$\hat{Y}_i = b_0 + b_1 X_i, \qquad \hat{\varepsilon}_i = Y_i - \hat{Y}_i$$

- Una medida del error total es la **suma de cuadrados de los residuos**:

$$RSS(b_0, b_1) = \sum_{i=1}^{n} [Y_i - (b_0 + b_1 X_i)]^2$$

- ¿Por qué al cuadrado? (i) positivos y negativos no se cancelan; (ii) penaliza más los errores grandes.
- Criterio MCO: elegir la recta que **minimiza** el RSS.

Los residuos en el ejemplo de ingresos



Antes de la fórmula: intenten ustedes

[Dashboard: Componentes del modelo: β_0, β_1 y RSS (`best_line`)] 140 campañas publicitarias: X = presupuesto (miles de USD), Y = ingresos generados (miles de USD).

- Muevan β_0 y β_1 para minimizar el RSS. Después comparen con "Mostrar solución MCO".
- ¿Qué hace mover β_0? ¿Y mover β_1?
- ¿La recta óptima pasa por la mayor cantidad de puntos?

[Actividad en clase: 5 minutos]

Dashboard: componentes del modelo

Parámetros de la recta ?

β_0 (intercepto)

-20 0 15 30 50

β_1 (pendiente)

-3 0 2 4 6

Ecuación actual

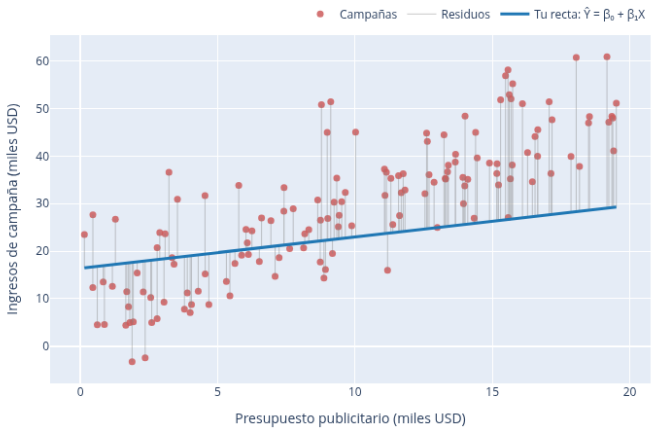
$$\hat{Y} = 16.39 + 0.66 \cdot X$$

RSS actual

25,370.60

Mostrar solución MCO

Nube de puntos + recta + residuos ?



Dashboard: componentes del modelo, con la solución MCO

Parámetros de la recta

β_0 (intercepto)

-20 0 15 30 50

β_1 (pendiente)

-3 0 2 4 6

Ecuación actual

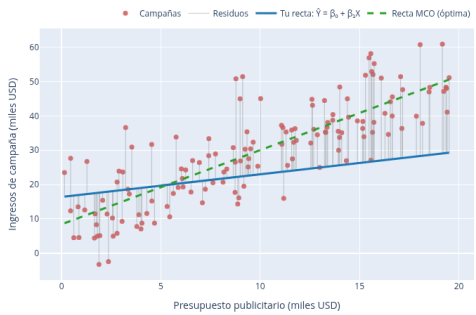
$$\hat{Y} = 16.39 + 0.66 \cdot X$$

RSS actual

25,370.60

Ocultar solución MCO

Nube de puntos + recta + residuos



Solución MCO — la recta que minimiza el RSS

β_0 MCO = 8.3948 | **β_1 MCO** = 2.1637

RSS mínimo = 9,524.06 | **Tu RSS** = 25,370.60 | **Exceso** = +15,846.54 (166.4% mayor)

Resumen numérico

Qué observamos

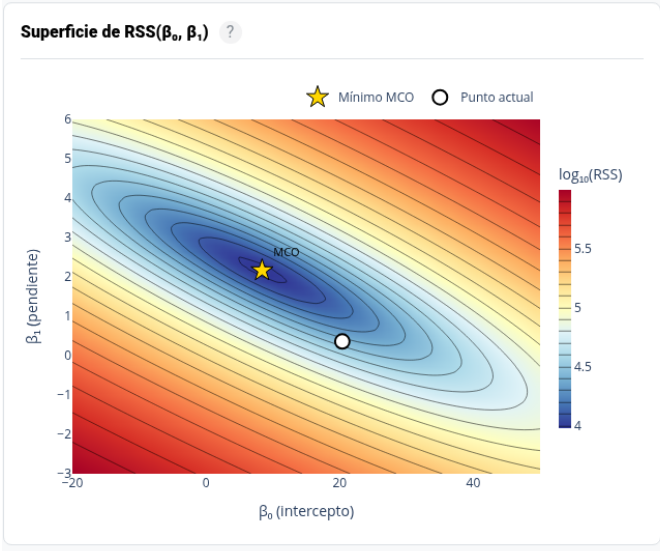
- β_0 y β_1 actúan distinto: mover β_0 desplaza la recta verticalmente; mover β_1 la rota.
- El RSS es el costo agregado de los errores. Una recta que se aleja poco en muchos puntos puede costar más que una que se aleja mucho en pocos, porque el cuadrado penaliza los errores grandes.
- La solución MCO **no** "pasa por todos los puntos": minimiza la distancia cuadrática total.

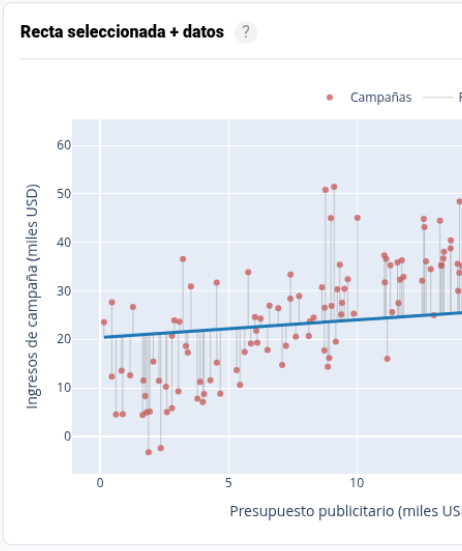
La superficie del RSS

[Dashboard: Superficie del RSS (`rss_surface`)]

- Ahora vemos el RSS para **todos** los pares (β_0, β_1) a la vez: cada punto del mapa es una recta distinta.
- ¿Dónde está el mínimo? ¿Qué forma tiene la superficie? ¿Hay más de un mínimo?
- ¿Qué pasa si nos movemos en una dirección con β_0 alto y β_1 bajo? (Pista: la "diagonal" del valle.)

Dashboard: superficie del RSS





Estimador de Mínimos Cuadrados Ordinarios (MCO)

Minimizamos el RSS respecto de β_0 y β_1. Condiciones de primer orden:

$$\frac{\partial RSS}{\partial \beta_0} = -2\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\partial RSS}{\partial \beta_1} = -2\sum_{i=1}^{n} X_i\,(Y_i - \beta_0 - \beta_1 X_i) = 0$$

Resolviendo el sistema de dos ecuaciones:

$$\boxed{\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}, \qquad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}}$$

Una segunda motivación: el método de los momentos

Del supuesto $E[\varepsilon \mid X] = 0$ se derivan dos condiciones poblacionales:

$$E[\varepsilon] = 0 \qquad\qquad E[\varepsilon X] = 0$$

- Reemplazar esperanzas por promedios muestrales da **exactamente** las mismas dos ecuaciones que las condiciones de primer orden de MCO.
- En población, esas condiciones implican

$$\beta_1 = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}, \qquad \beta_0 = E[Y] - \beta_1 E[X]$$

- Dos caminos –minimizar errores cuadráticos / imponer momentos– llevan al mismo estimador.
- El segundo deja claro **qué se necesita para interpretar** β_1: que ε no esté correlacionado con X. Si una variable omitida afecta a Y y se correlaciona con X, la condición falla.

Interpretación de los estimadores

$$\hat{\beta}_1 = \frac{\widehat{\mathrm{Cov}}(X, Y)}{\widehat{\mathrm{Var}}(X)} \qquad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

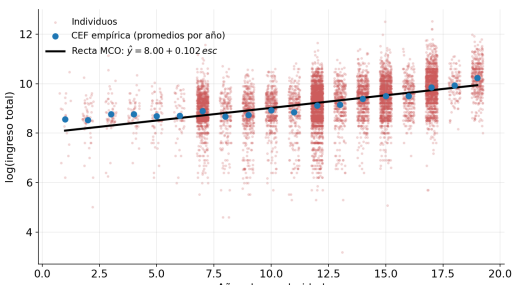
- La pendiente compara cuánto se mueven X e Y *juntas* con cuánto se mueve X *sola*.
- Si tienden a moverse en el mismo sentido, el numerador es positivo y $\hat{\beta}_1 > 0$. Si no hay asociación sistemática, $\hat{\beta}_1 \approx 0$.
- El intercepto se elige para que la recta pase por el **punto promedio** $(\bar{X}, \bar{Y})$.
- Es una medida resumida de cómo se mueven juntas X e Y. Interpretación *causal* requiere supuestos adicionales (próximas clases).

Aplicación: ingresos y años de escolaridad (EAH 2016)

Modelo: $\log(\text{ingreso}_i) = \beta_0 + \beta_1\, \text{esc}_i + \varepsilon_i$, con $n = 10{,}048$.

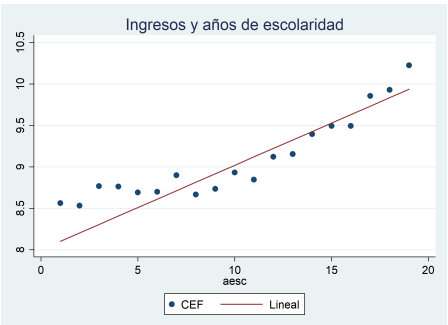
$$\widehat{\log(\text{ingreso})} = 8{,}00 + 0{,}102 \times \text{esc}$$

- $\hat{\beta}_1 = 0{,}102$: un año más de escolaridad se asocia con un ingreso **10.7 % mayor**, en promedio ($e^{0{,}102} - 1$; $\approx 100 \times \hat{\beta}_1$ para coeficientes chicos).
- $\hat{\beta}_0 = 8{,}00$: log-ingreso predicho con 0 años de escolaridad; no tiene interpretación natural (no hay casi nadie con 0 años), solo ancla la recta.
- Predicción para 12 años: $8{,}00 + 12 \times 0{,}102 = 9{,}22$ en logs.



La recta MCO frente a la CEF

- La recta es la mejor aproximación *lineal* a la CEF (en el sentido del menor error cuadrático).
- Si la CEF fuera lineal, coinciden. Acá la CEF es casi plana hasta los $\sim$11 años y sube después: la recta es una **aproximación** razonable pero imperfecta (recordar el spline y la cuadrática de la clase anterior).
- Con una sola X continua, la recta resume la relación en **un número**: $\hat{\beta}_1$.



Propiedades algebraicas de los residuos

Del primer orden de MCO (con intercepto) se siguen, siempre y para cualquier muestra:

(P1)	$\sum_i \hat{\varepsilon}_i = 0$	la recta no sobreestima ni subestima, en promedio
(P2)	$\sum_i X_i \hat{\varepsilon}_i = 0$	los residuos son ortogonales a X
(P3)	$\sum_i \hat{Y}_i \hat{\varepsilon}_i = 0$	y a los valores ajustados

- Son propiedades *mecánicas* de la muestra, no una verificación del modelo: valen aunque el modelo esté mal especificado.
- (P3) es lo que usaremos para descomponer la variación de Y.

Resumen de estimación

- Modelo: $Y = \beta_0 + \beta_1 X + \varepsilon$; β_0, β_1 desconocidos.
- MCO elige $(\hat{\beta}_0, \hat{\beta}_1)$ minimizando RSS; el mínimo existe, es único y tiene fórmula cerrada.
- Equivalente a imponer $E[\varepsilon] = 0$ y $E[\varepsilon X] = 0$ en la muestra.
- $\hat{\beta}_1 = \widehat{\mathrm{Cov}}(X, Y)/\widehat{\mathrm{Var}}(X)$.

Pregunta que sigue

Ya tenemos la "mejor" recta para esta muestra. ¿Cuánto del comportamiento de Y explica?
Y, más adelante: ¿qué tan confiable es $\hat{\beta}_1$?

Bondad de ajuste: ¿cuánto explica el modelo?

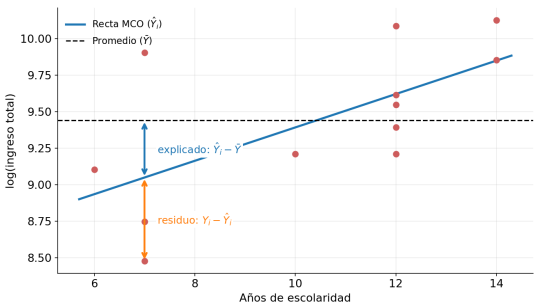
- En ciencias sociales ninguna recta es "correcta". La pregunta es qué tan *informativa* resulta.
- Descomponemos el fenómeno en dos partes:
  - **la parte explicada**: lo que la recta predice con éxito;
  - **el residuo**: azar y factores que no incluimos.
- Punto de partida: sin X, nuestra mejor predicción de cualquier Y_i es el promedio $\bar{Y}$. La dispersión alrededor de $\bar{Y}$ es todo lo que "hay para explicar":

$$TSS = \sum_{i=1}^{n} (Y_i - \bar{Y})^2$$

Descomposición de la variación

Para cada observación:

$$\underbrace{Y_i - \bar{Y}}_{\text{desvío total}} = \underbrace{\hat{Y}_i - \bar{Y}}_{\text{explicado por la recta}} + \underbrace{Y_i - \hat{Y}_i}_{\text{residuo}}$$



Elevando al cuadrado y sumando (el término cruzado se anula por P1 y P3):

$$TSS = \sum (Y_i - \bar{Y})^2$$

$$ESS = \sum (\hat{Y}_i - \bar{Y})^2$$

$$RSS = \sum (Y_i - \hat{Y}_i)^2$$

$$\boxed{TSS = ESS + RSS}$$

(vale siempre que haya intercepto; demostración en el Apéndice)

El coeficiente de determinación R^2

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} \in [0, 1]$$

Proporción de la variación **muestral** de Y explicada por el modelo.

- $R^2 = 0$: la recta es horizontal; X no aporta nada a la predicción.
- $R^2 = 1$: todos los puntos sobre la recta. En ciencias sociales, casi imposible; si ocurre, sospechar.
- Por ejemplo, $R^2 = 0{,}6$: el modelo explica el 60 % de la variación muestral de Y.

Otras medidas de error de predicción:

$$MSE = \frac{RSS}{n}, \qquad RMSE = \sqrt{MSE} \quad \text{(en las mismas unidades de } Y\text{)}$$

Ejemplo: escolaridad e ingresos

TSS	7.413
ESS	1.458
RSS	5.955
$R^2 = ESS/TSS$	0.197
$\hat{\sigma} = \sqrt{RSS/(n-2)}$	0.77

- La escolaridad "explica" alrededor del 20 % de la variación del log-ingreso. El 80 % restante: experiencia, sexo, ocupación, horas trabajadas, suerte...
- El desvío típico del residuo es $\approx 0{,}77$ log-puntos (un factor de $e^{0{,}77} \approx 2{,}2$ en ingresos): mucha dispersión individual alrededor de la recta.
- ¿Es un mal modelo? No necesariamente: la pendiente puede estar muy bien estimada (lo veremos en la Parte 3).

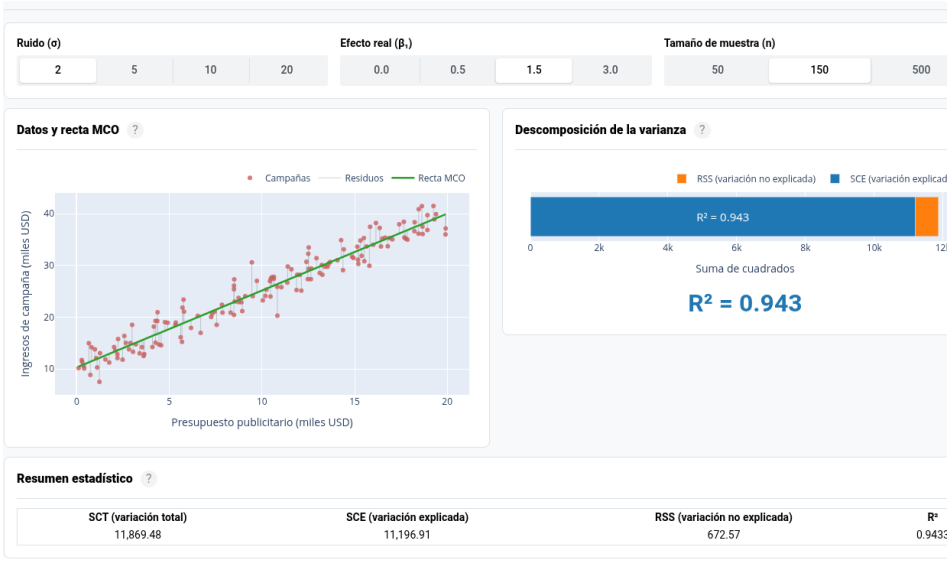
Explorando el R^2

[Dashboard: Visualizador de R^2 (`r2viz`)] Modelo poblacional: $Y = 10 + \beta_1 X + \varepsilon$, con $\varepsilon \sim N(0, \sigma^2)$. Controles: ruido σ, efecto β_1, tamaño de muestra n.

- Con $\beta_1 = 1{,}5$: ¿qué pasa con el R^2 cuando σ pasa de 2 a 20?
- Con $\beta_1 = 0$: ¿cuánto vale el R^2? ¿Es exactamente cero?
- Cambien n de 50 a 500: ¿qué mide el R^2 y qué no mide?

[Actividad en clase: 5 minutos]

Dashboard: R^2 con poco ruido ($\sigma = 2$)



Dashboard: R^2 con ruido intermedio ($\sigma = 5$)



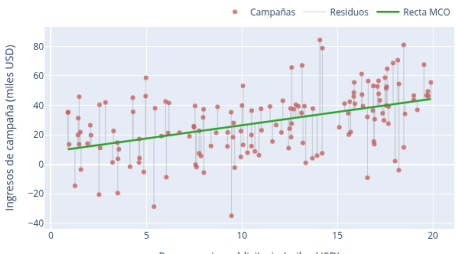
Dashboard: R^2 con mucho ruido ($\sigma = 20$)

Ruido (σ): 2 | 5 | 10 | **20**

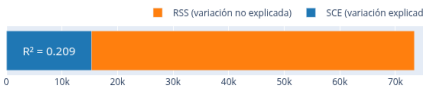
Efecto real (β_1): 0.0 | 0.5 | **1.5** | 3.0

Tamaño de muestra (n): 50 | **150** | 500

Datos y recta MCO



Descomposición de la varianza



R^2 = 0.209

Resumen estadístico

SCT (variación total)	SCE (variación explicada)	RSS (variación no explicada)	R²
73,437.67	15,326.78	58,110.89	0.2087

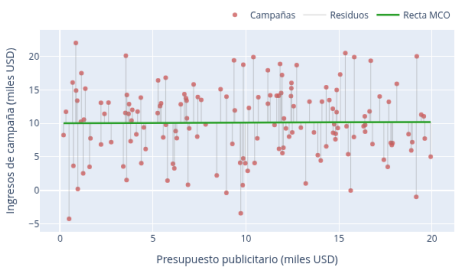
Dashboard: R^2 sin efecto ($\beta_1 = 0$)

Ruido (σ): 2 | **5** | 10 | 20

Efecto real (β_1): **0.0** | 0.5 | 1.5 | 3.0

Tamaño de muestra (n): 50 | **150** | 500

Datos y recta MCO



Descomposición de la varianza



R^2 = 0.000

Resumen estadístico

SCT (variación total)	SCE (variación explicada)	RSS (variación no explicada)	R^2
4,236.05	0.38	4,235.66	0.0001

Qué observamos y advertencias sobre el R^2

- **El ruido domina el R^2**: con σ alto el R^2 colapsa aunque el efecto sea real y el modelo lineal siga siendo el mejor disponible.
- **Ajuste no es causalidad**: un R^2 alto indica que se mueven juntas de forma predecible, no que una cause a la otra (helados e incendios).
- **Un R^2 bajo no invalida el modelo**: si el interés está en el efecto marginal $\hat{\beta}_1$ y está bien estimado, $R^2 = 0{,}2$ puede ser un resultado sólido.
- **El R^2 no mejora con n**: mide ajuste, no precisión del estimador.
- El R^2 crece *mecánicamente* con la dispersión de X, aunque la relación subyacente no cambie.
- $TSS = ESS + RSS$ siempre: la barra apilada lo ilustra.

Cierre de la Parte 1

- $Y = \beta_0 + \beta_1 X + \varepsilon$: una recta como aproximación lineal a la CEF.
- MCO elige la recta de menor RSS; equivalentemente, impone $E[\varepsilon] = 0$ y $E[\varepsilon X] = 0$ en la muestra.
- R^2 mide qué fracción de la variación de Y captura el modelo; no mide causalidad ni la calidad del estimador de β_1.

Lo que no sabemos todavía

$\hat{\beta}_1$ salió de *una* muestra. Con otra muestra hubiéramos obtenido otro número.
¿Qué podemos decir sobre el parámetro poblacional β_1?

[Pausa]

El estimador es una variable aleatoria

- β_1 es un número fijo (desconocido) de la **población**.
- $\hat{\beta}_1 = \dfrac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}$ es una función de la muestra; cada muestra distinta da un $\hat{\beta}_1$ distinto.
- Antes de observar los datos, $\hat{\beta}_1$ es una variable aleatoria con una **distribución muestral**.
- Preguntas estadísticas:
  1. ¿Está centrada en β_1? (**insesgadez**)
  2. ¿Qué tan dispersa es? (**varianza**)
  3. ¿Podemos estimar esa dispersión con una única muestra? (**error estándar**)

Supuestos

S1 **Linealidad en los parámetros**: la población cumple $Y = \beta_0 + \beta_1 X + \varepsilon$.

S2 **Muestreo aleatorio**: (X_i, Y_i) son extracciones independientes de la población.

S3 **Variación en X**: $SST_x = \sum (X_i - \bar{X})^2 > 0$.

S4 **Media condicional cero**: $E[\varepsilon \mid X] = 0$.

S5 **Homocedasticidad**: $\mathrm{Var}(\varepsilon \mid X) = \sigma^2$ (constante).

- S1–S4 garantizan **insesgadez**.
- Para la **fórmula de la varianza** además necesitamos S5 (la relajamos en el capítulo de heterocedasticidad).

La estrategia: ponerse en el lugar de quien conoce la verdad

- En la práctica tenemos una única muestra.
- En una **simulación** nosotros definimos la población: conocemos β_0, β_1, σ. Entonces podemos:
  1. generar muchas muestras de la población,
  2. estimar MCO en cada una,
  3. mirar la distribución de los $\hat{\beta}$ obtenidos.
- Verdad: $Y = 10 + 3X + \varepsilon$ ($\beta_0 = 10$, $\beta_1 = 3$). Se generan 500 muestras de 250 observaciones.

[Dashboard: Insesgadez y varianza de MCO (`unbiasedness`)]

- ¿Dónde está centrado el histograma de $\hat{\beta}_1$? ¿Y el de $\hat{\beta}_0$?
- ¿Qué pasa con la dispersión al aumentar σ_ε? ¿Y al aumentar σ_X?

Dashboard: caso base ($\sigma_\varepsilon = 10$, $\sigma_X = 10$)

Ajuste de parámetros

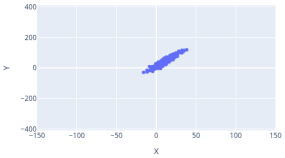
Desviación Estándar del Error (σ_ε)

1	**10**	20	30	40	50

Desviación Estándar de X (σ_X)

1	**10**	20	30	40	50

Gráfico de dispersión

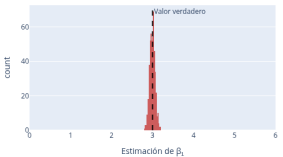


Distribución de estimaciones de β_0



Estadística	Valor
Media	9.9822
Desviación estándar	0.8928
Valor verdadero	10

Distribución de estimaciones de β_1



Estadística	Valor
Media	2.9991
Desviación estándar	0.0646
Valor verdadero	3

Dashboard: más ruido ($\sigma_\varepsilon = 50$)

Ajuste de parámetros

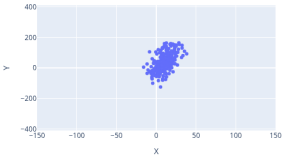
Desviación Estándar del Error (σ_ε)

1	10	20	30	40	**50**

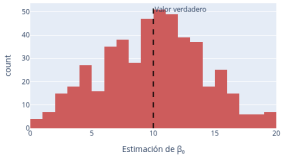
Desviación Estándar de X (σ_X)

1	**10**	20	30	40	50

Gráfico de dispersión



Distribución de estimaciones de β_0



Estadística	Valor
Media	9.9074
Desviación estándar	4.5395
Valor verdadero	10

Distribución de estimaciones de β_1



Estadística	Valor
Media	3.0045
Desviación estándar	0.3216
Valor verdadero	3

Dashboard: poca variación en X ($\sigma_X = 1$)

Ajuste de parámetros

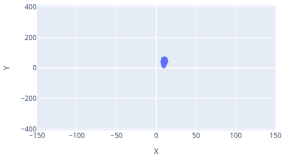
Desviación Estándar del Error (σ_ε)

1 | **10** | 20 | 30 | 40 | 50

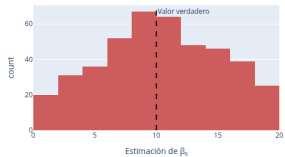
Desviación Estándar de X (σ_X)

1 | 10 | 20 | 30 | 40 | 50

Gráfico de dispersión

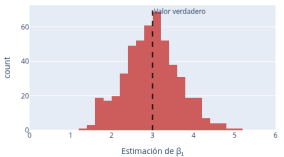


Distribución de estimaciones de β_0



Estadística	Valor
Media	10.2478
Desviación estándar	6.6264
Valor verdadero	10

Distribución de estimaciones de β_1



Estadística	Valor
Media	2.9794
Desviación estándar	0.6618
Valor verdadero	3

Dashboard: mucha variación en X ($\sigma_X = 50$)

Ajuste de parámetros

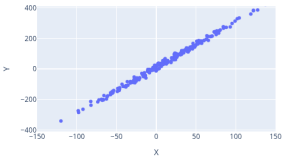
Desviación Estándar del Error (σ_ε)

1 | 10 | 20 | 30 | 40 | 50

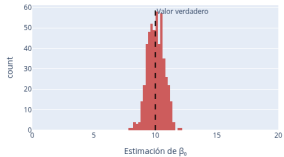
Desviación Estándar de X (σ_X)

1 | 10 | 20 | 30 | 40 | 50

Gráfico de dispersión

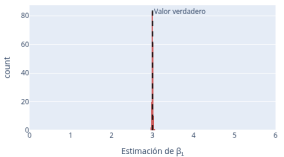


Distribución de estimaciones de β_0



Estadística	Valor
Media	10.0322
Desviación estándar	0.6739
Valor verdadero	10

Distribución de estimaciones de β_1



Estadística	Valor
Media	2.9985
Desviación estándar	0.0125
Valor verdadero	3

Qué observamos

- **Insesgadez**: en todas las configuraciones los histogramas están centrados en los valores verdaderos (10 y 3). Cada estimación individual se aleja, pero no sistemáticamente en una dirección.
- **Más ruido, más varianza**: al aumentar σ_ε ambas distribuciones se ensanchan.
- **Más dispersión de X, menos varianza**: un rango más amplio de X aporta más información para identificar la pendiente.
- $\hat{\beta}_0$ varía más que $\hat{\beta}_1$ (extrapola hasta $X = 0$).

Estos patrones no son una coincidencia de la simulación: la teoría los predice exactamente.

Insesgadez de $\hat{\beta}_1$

Resultado: bajo S1–S4, $E[\hat{\beta}_0] = \beta_0$ y $E[\hat{\beta}_1] = \beta_1$.

Demostración en dos pasos:

1. Reescribir el estimador en función del error. Sustituyendo $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$ y usando $\sum(X_i - \bar{X}) = 0$, $\sum(X_i - \bar{X})X_i = SST_x$:

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_i (X_i - \bar{X})\varepsilon_i}{SST_x}$$

2. Esperanza condicional en X:

$$E[\hat{\beta}_1 \mid X] = \beta_1 + \frac{1}{SST_x} \sum_i (X_i - \bar{X}) \underbrace{E[\varepsilon_i \mid X]}_{=0} = \beta_1$$

Por esperanzas iteradas, $E[\hat{\beta}_1] = \beta_1$. (Detalle en el Apéndice.)

Qué significa –y qué no– insesgadez

- En muestras repetidas MCO no sobreestima ni subestima: el sesgo es cero.
- **No** dice que *nuestra* estimación esté cerca de β_1; dice que el procedimiento no se equivoca sistemáticamente.
- Todo descansa en S4, $E[\varepsilon \mid X] = 0$. Si falla (variable omitida correlacionada con X), el estimador es sesgado **aunque** n **sea enorme**: tema de las próximas clases.
- Insesgadez es deseable, pero no suficiente: un estimador insesgado pero muy disperso es poco útil. Necesitamos la varianza.

Varianza de $\hat{\beta}_1$

Resultado: bajo S1–S5,

$$\boxed{\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{SST_x}, \qquad SST_x = \sum_{i=1}^{n}(X_i - \bar{X})^2}$$

con $\sigma^2 = \mathrm{Var}(\varepsilon \mid X)$.

Derivación: de $\hat{\beta}_1 - \beta_1 = \sum(X_i - \bar{X})\varepsilon_i / SST_x$, con errores independientes y homocedásticos:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{1}{SST_x^2}\sum_i (X_i - \bar{X})^2\sigma^2 = \frac{\sigma^2\, SST_x}{SST_x^2} = \frac{\sigma^2}{SST_x}$$

Los determinantes de la precisión

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{SST_x} = \frac{\sigma^2}{n \cdot \widehat{\mathrm{Var}}(X)}$$

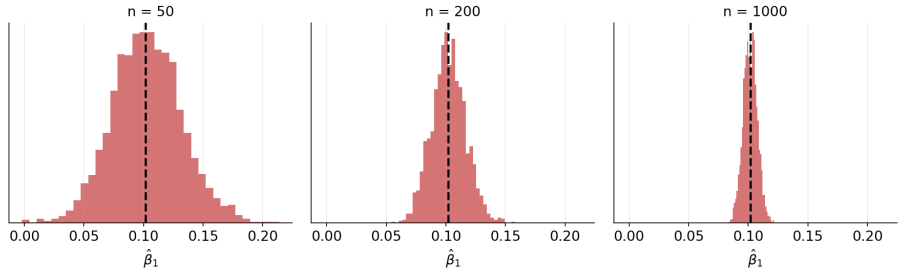
- **Más ruido** ($\sigma^2 \uparrow$) $\Rightarrow$ más varianza. Es lo que vimos moviendo σ_ε.
- **Más variación en** X ($SST_x \uparrow$) $\Rightarrow$ menos varianza. Es lo que vimos moviendo σ_X.
- **Más observaciones** ($n \uparrow$) $\Rightarrow$ $SST_x \uparrow \Rightarrow$ menos varianza; $SD(\hat{\beta}_1) \propto 1/\sqrt{n}$.

Implicancia para el diseño

Para estimar bien una pendiente conviene tener datos con **mucha variación en** X, no solo muchas observaciones concentradas en el mismo valor.

Lo mismo en el ejemplo de ingresos

Tratamos la EAH completa como "población" ($\beta_1 = 0{,}102$) y extraemos 2000 muestras al azar de cada tamaño.



	$n = 50$	$n = 200$	$n = 1000$
Media de los $\hat{\beta}_1$	0.103	0.102	0.102
Desvío de los $\hat{\beta}_1$	0.029	0.014	0.006
$\sigma/\sqrt{SST_x}$ (teoría)	0.029	0.015	0.007

Centrado en β_1 y el desvío cae como $1/\sqrt{n}$: $\times 4$ en $n \Rightarrow \div 2$ en el desvío.

Estimación de la varianza: el problema práctico

- La fórmula $\mathrm{Var}(\hat{\beta}_1) = \sigma^2 / SST_x$ es exacta, pero σ^2 es desconocido.
- Lo estimamos con los residuos:

$$\hat{\sigma}^2 = \frac{\sum_i \hat{\varepsilon}_i^2}{n-2} = \frac{RSS}{n-2}$$

- Dividimos por $n-2$ y no por n: MCO estima dos parámetros, lo que impone dos restricciones sobre los residuos (P1 y P2). Con $n-2$, $E[\hat{\sigma}^2] = \sigma^2$ (insesgado).
- **Error estándar** de $\hat{\beta}_1$:

$$SE(\hat{\beta}_1) = \sqrt{\widehat{\mathrm{Var}}(\hat{\beta}_1)} = \frac{\hat{\sigma}}{\sqrt{SST_x}}$$

- A pesar del nombre, no se refiere a los residuos: es el desvío estándar *estimado* de $\hat{\beta}_1$ a lo largo de muestras repetidas.

Aplicación: error estándar en el ejemplo de ingresos

- $\hat{\sigma} = 0{,}77, \quad SST_x = 140{,}223 \quad \Rightarrow \quad SE(\hat{\beta}_1) = \dfrac{0{,}77}{\sqrt{140{,}223}} \approx 0{,}0021$
- Es una única muestra (la EAH): el *SE* nos dice cuánto *esperaríamos* que varíe $\hat{\beta}_1$ si tuviéramos otras muestras.
- Con $n = 50$ el desvío es $\approx 0{,}029$: 14 veces más impreciso. La EAH es una muestra grande.

Para llevarse

Con el *SE* podemos evaluar no solo *dónde* cae nuestra estimación, sino **cuán lejos está de cualquier valor hipotético en relación con su propia precisión**. Esa es la lógica del test de hipótesis.

Cierre de la Parte 2

- $\hat{\beta}_1$ es una variable aleatoria; MCO es **insesgado** si $E[\varepsilon \mid X] = 0$.
- Su varianza, σ^2/SST_x, es menor con menos ruido, más variación de X y más observaciones.
- Se estima con $\hat{\sigma}^2 = RSS/(n-2)$ y se resume en el **error estándar**.
- Simular es una herramienta imprescindible: nos permite verificar propiedades que en datos reales no podemos observar.

Lo que falta

Conocemos el centro y el desvío de $\hat{\beta}_1$. Para afirmaciones probabilísticas necesitamos su **distribución completa**.

[Pausa]

Motivación

- Estimamos $\hat{\beta}_1 = 0{,}102$ con $SE = 0{,}0021$: ¿refleja un efecto genuino de la escolaridad o podríamos haberlo observado por azar si el efecto poblacional fuera cero?
- Cada muestra es una extracción distinta. Para responder necesitamos la distribución de $\hat{\beta}_1$ **bajo la hipótesis** de que $\beta_1 = 0$.
- Un ejemplo más ajustado: **una muestra de 20 personas** de la misma población dio $\hat{\beta}_1 = 0{,}094$ con $SE = 0{,}063$. ¿Alcanza?

Pregunta

Si $E[\hat{\beta}_1] = \beta_1$ y $\mathrm{Var}(\hat{\beta}_1) = \sigma^2 / SST_x$: ¿alcanza con media y varianza para decir "*qué tan probable* es observar $\hat{\beta}_1 = 0{,}094$ si $\beta_1 = 0$"?

Tres caminos para obtener la distribución de $\hat{\beta}_1$

1. **Supuesto sobre la distribución del error**: si $\varepsilon \mid X \sim N(0, \sigma^2)$, entonces $\hat{\beta}_1$ es exactamente normal para cualquier n.
2. **Teoría asintótica**: por el Teorema Central del Límite, para n grande $\hat{\beta}_1$ es aproximadamente normal sin importar la distribución del error.
3. **Métodos computacionales** (bootstrap): se remuestrea los datos para construir una distribución empírica. Tema de un capítulo posterior.

Empezamos con el primero y luego vemos qué tan necesario es.

Normalidad: la distribución de $\hat{\beta}_1$

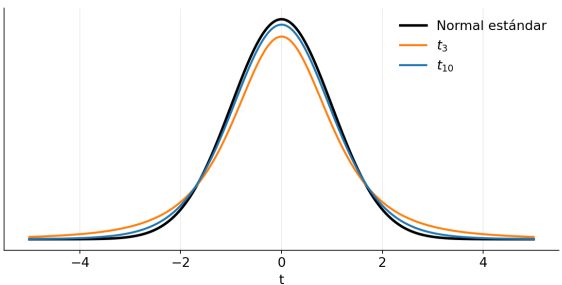
- Supuesto: $\varepsilon_i \mid X \sim N(0, \sigma^2)$ independientes.
- Como $\hat{\beta}_1 = \beta_1 + \sum c_i \varepsilon_i$ con $c_i = (X_i - \bar{X})/SST_x$ es una combinación lineal de normales, es normal:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{SST_x}\right) \quad \Longrightarrow \quad Z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/SST_x}} \sim N(0,1)$$

- Problema: no conocemos σ^2. Lo reemplazamos por $\hat{\sigma}^2$.
- Pero ese reemplazo no es inocuo: el estadístico deja de ser normal.

$$T = \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \sim t_{n-2}$$

La distribución t de Student



- Simétrica y acampanada como la normal, pero con **colas más pesadas**: refleja la incertidumbre adicional de estimar σ^2.
- $n-2$ grados de libertad: los dos parámetros estimados consumen dos dimensiones de información.
- Si $n \uparrow$ entonces $t_{n-2} \to N(0,1)$.

La lógica del test de hipótesis

1. Hacemos un **supuesto** sobre el parámetro (hipótesis nula) que nos da una distribución para el estimador: con qué probabilidad esperamos ver cada valor.
2. Vamos a los datos, calculamos el estimador, y vemos si es un valor **improbable** bajo ese supuesto.
3. Si es muy improbable, **rechazamos** el supuesto.

Asimetría clave

Lo único que podemos hacer es rechazar, o no rechazar, un supuesto. Nunca concluimos que el supuesto es válido: a lo sumo que *no tenemos evidencia suficiente para rechazarlo*.

Planteo del test

$$H_0 : \beta_1 = 0 \qquad \text{vs.} \qquad H_a : \beta_1 \neq 0$$

- Si H_0 es verdadera, X no tiene efecto lineal sobre Y (de acuerdo con nuestro modelo): típicamente la pregunta de interés.
- También podemos testear otros valores: $H_0 : \beta_1 = 1$ en un modelo log-log si queremos probar elasticidad unitaria.
- Bajo $H_0 : \beta_1 = 0$, el estadístico se simplifica:

$$\hat{T} = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t_{n-2} \quad \text{(bajo } H_0\text{)}$$

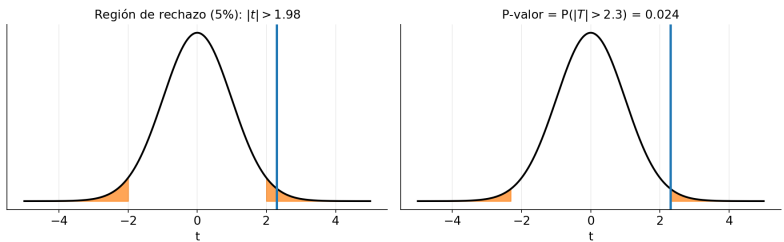
- Intuición: si $\beta_1 = 0$, esperamos $\hat{\beta}_1$ cerca de 0 y por lo tanto $\hat{T}$ cerca de 0. Rechazamos si $|\hat{T}|$ es grande.

Cuándo rechazar: región de rechazo y p-valor

- **Región de rechazo**: fijamos un nivel de significancia α (típico 5 %) = probabilidad de rechazar H_0 cuando es verdadera que toleramos. Rechazamos si $|\hat{T}| > t_{n-2,\,\alpha/2}$ ($\approx 1{,}96$ con n grande).
- **P-valor**: la probabilidad, bajo H_0, de obtener un valor al menos tan extremo como el observado:

$$p = P\left(|T_{n-2}| > |\hat{T}|\right)$$

Rechazamos al nivel α si $p < \alpha$.



Lo que el p-valor **no** es

- **No** es la probabilidad de que H_0 sea verdadera.
- Es una afirmación sobre *los datos dado* H_0: "si H_0 fuera cierta, ¿qué tan raro sería lo que observamos?"
- **No** mide el tamaño del efecto: un efecto minúsculo puede tener un p-valor chiquito con n grande.
- **No** es la probabilidad de que el resultado se deba al azar.
- El umbral 5 % es una convención, no una ley de la naturaleza.

Ejemplo con números

Supongamos $\hat{\beta}_1 = 10$, $SE = 2$, $n = 100$.

$$\hat{T} = \frac{10 - 0}{2} = 5 \sim t_{98} \text{ bajo } H_0$$

- Valor crítico al 5 %: $\approx 1{,}98$. $5 > 1{,}98 \Rightarrow$ **rechazamos** H_0.
- P-valor $\ll 0{,}001$: bajo H_0, un $\hat{T}$ de 5 ocurriría con probabilidad mucho menor al 1 %.
- En el ejemplo de la EAH: $\hat{T} = 0{,}102/0{,}0021 = 49{,}6 \Rightarrow p \approx 0$. Rechazamos $H_0 : \beta_1 = 0$ con muchísima holgura.
- También podríamos testear otro valor, p.ej. $H_0 : \beta_1 = 0{,}05$: $\hat{T} = (0{,}102 - 0{,}05)/0{,}0021 \approx 25$, se rechaza también.

Intervalo de confianza al 95 %

$$IC_{95\,\%} = \hat{\beta}_1 \pm t_{n-2,\,0{,}025} \cdot SE(\hat{\beta}_1)$$

- EAH: [0,098 ; 0,106]. Cada año extra de escolaridad se asocia con un 9.8 % a 10.6 % más de ingreso.
- Es la otra cara del test: rechazamos $H_0 : \beta_1 = c$ al 5 % si y solo si c *no* está en el intervalo.
- Informa más que el test: muestra la magnitud y la precisión, no solo "significativo / no significativo".
- Interpretación: si repitiéramos el procedimiento en muchas muestras, el 95 % de los intervalos contendrían el β_1 verdadero.

Significancia estadística como señal / ruido

$$\hat{T} = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} = \frac{\text{señal}}{\text{ruido}}, \qquad SE(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{SST_x}}$$

Un resultado es estadísticamente significativo cuando la señal es grande en relación al ruido:

1. el efecto verdadero β_1 es grande;
2. los residuos $\hat{\sigma}^2$ son chicos (datos limpios);
3. SST_x es grande: más observaciones o más variación en X.

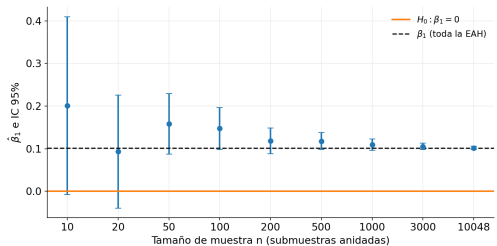
Consecuencia

No significativo $\neq \beta_1 = 0$. Puede significar que la muestra es chica o los datos ruidosos para distinguir β_1 de cero.

Misma población, distintos n

Submuestras anidadas de la EAH (β_1 "poblacional" $= 0{,}102$):

n	$\hat{\beta}_1$	SE	$\hat{T}$	p-valor
10	0.201	0.090	2.2	0.057
20	0.094	0.063	1.5	0.156
50	0.158	0.035	4.5	0.000
100	0.147	0.025	5.9	0.000
200	0.118	0.015	7.7	0.000
500	0.118	0.010	11.6	0.000
1.000	0.110	0.007	16.2	0.000
3.000	0.105	0.004	27.5	0.000
10.048	0.102	0.002	49.6	0.000



- Con $n = 20$ no rechazamos H_0 ($p = 0{,}16$) aunque el efecto es real.
- Con n grande todo se rechaza: significancia estadística $\neq$ relevancia económica.

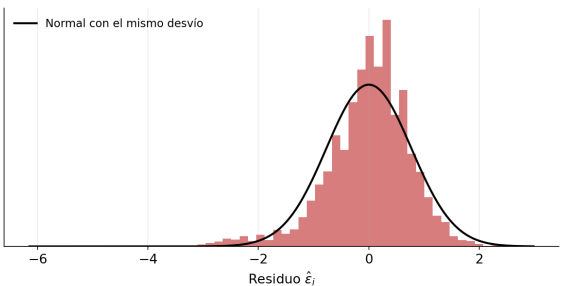
¿Y si los errores no son normales?

- $T \sim t_{n-2}$ es **exacto** solo bajo normalidad de ε.
- **Normalidad asintótica**: $\hat{\beta}_1 - \beta_1 = \sum c_i \varepsilon_i$ es un promedio ponderado de los errores. Con varianza finita y sin observaciones dominantes, el TCL da:

$$\frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \xrightarrow{d} N(0,1) \quad \text{si } n \to \infty$$

- Consecuencias prácticas:
  1. Con n moderado a grande, usar t o normal es razonable aunque los errores no sean normales.
  2. La normalidad del error importa en **muestras chicas**; con n chico y errores muy asimétricos o de colas pesadas, conviene bootstrap.
- Regla informal: $n \geq 30$ (depende de cuán no normal sea el error).

En nuestros datos: ¿los residuos son normales?



- Residuos de la regresión de log-ingreso: **asimetría** $-0{,}94$ y curtosis 5,7 (la normal tiene 0 y 3).
- Claramente no normales: cola izquierda pesada (ingresos muy bajos).
- Con $n = 10{,}048$ el TCL nos protege; con $n = 20$ no tanto. ¿Cuánto?

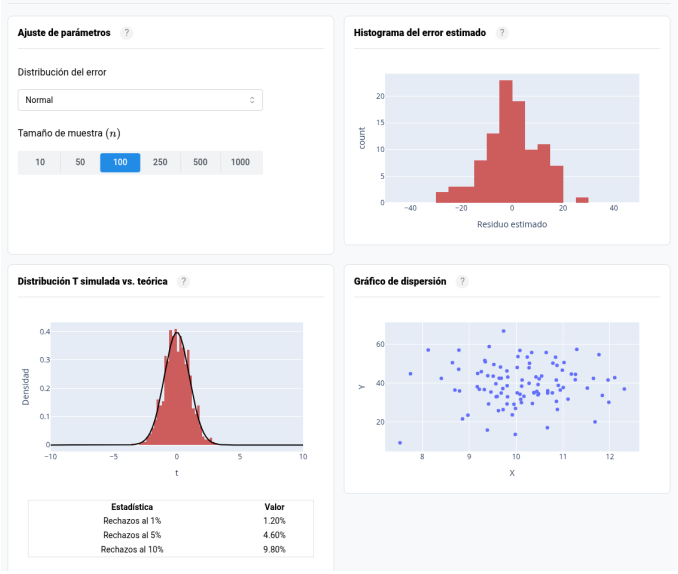
Explorando el test t con errores no normales

[Dashboard: El Test-T cuando el error no es normal (`ttest`)] Se simulan muchas muestras con $\beta_1 = 0$ y se calcula el estadístico T en cada una. Se compara con t_{n-2} teórica y se reporta el % de rechazos al 1 %, 5 % y 10 %.

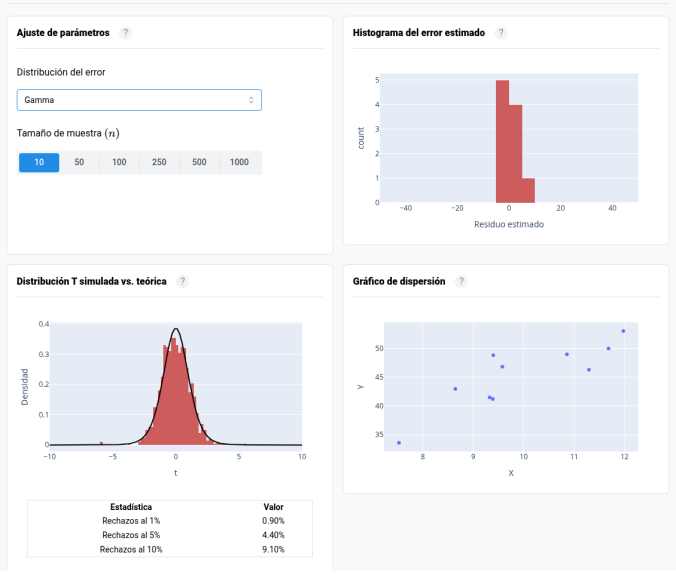
- Con error normal: ¿cuántos rechazos al 5 % esperamos? ¿Y observamos?
- Con error Gamma (asimétrico) y $n = 10$: ¿se parece el histograma de T a la t teórica? ¿Cambia el % de rechazos?
- Con error Gamma y $n = 1000$: ¿qué pasó?

[Actividad en clase: 5 minutos]

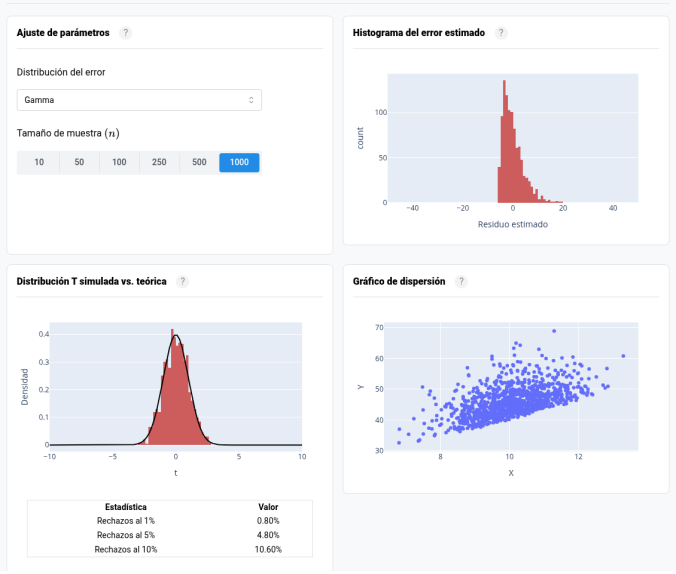
Dashboard: error normal, $n = 100$



Dashboard: error Gamma, $n = 10$



Dashboard: error Gamma, $n = 1000$



Qué observamos

- Bajo normalidad, la distribución simulada de $\hat{T}$ sigue de cerca a la t_{n-2} teórica, y los rechazos bajo H_0 son $\approx$ el nivel nominal (1 %, 5 %, 10 %).
- Con errores asimétricos y n chico, la distribución de $\hat{T}$ se desvía de la t y los rechazos pueden diferir del nivel nominal.
- A medida que n crece, $\hat{T}$ converge a la normal estándar **sea cual sea la forma del error**: el test es confiable en muestras grandes.
- Si β_1 verdadero es grande o σ^2 chico, la distribución de $\hat{T}$ se desplaza lejos de cero y es más fácil rechazar.

Qué leer en una tabla de regresión

log(ingreso)	Coef.	Std. Err.	t	$P > \|t\|$
escolaridad	0.102	0.0021	49.6	0.000
constante	8.00	0.027	295.6	0.000

- **Coef.**: $\hat{\beta}$. **Std. Err.**: $SE(\hat{\beta})$. $t = \hat{\beta}/SE$ (test de $H_0 : \beta = 0$). $P > |t|$: p-valor de dos colas.
- Además: $R^2 = 0{,}197$, $\hat{\sigma} = 0{,}77$ ("Root MSE"), $n - 2 = 10{,}046$ grados de libertad.
- Lectura: un año más de escolaridad se asocia a +10.7 % de ingreso; IC95 % [0,098; 0,106]; muy significativo, aunque la escolaridad sola explica el 20 % de la variación.

Cierre de la clase

- **Parte 1.** MCO: la recta que minimiza el RSS. R^2: fracción de la variación explicada; no es causalidad ni mide la calidad de $\hat{\beta}_1$.
- **Parte 2.** $\hat{\beta}_1$ es una variable aleatoria: insesgada si $E[\varepsilon \mid X] = 0$; varianza σ^2/SST_x.
- **Parte 3.** $T = \hat{\beta}_1/SE \sim t_{n-2}$ (normalidad exacta, TCL aproximada): rechazar H_0 si $|\hat{T}|$ es grande o p-valor bajo.
- No significativo no es "efecto cero"; significativo no es "efecto grande".

Próxima clase

¿Cuántas observaciones necesitamos para detectar un efecto dado? (**Potencia**). Y luego, múltiples variables explicativas, incluidas las categóricas.

Práctica

Usando datos de la EAH CABA (log del ingreso total y años de escolaridad):

1. Estimar $\log(\textit{ingreso}) = \beta_0 + \beta_1\, \textit{esc} + \varepsilon$ e interpretar $\hat{\beta}_1$.
2. Calcular a mano $\hat{\beta}_1 = \widehat{\mathrm{Cov}}/\widehat{\mathrm{Var}}$ y verificar contra el paquete.
3. Calcular *TSS*, *ESS*, *RSS* y R^2; verificar $\textit{TSS} = \textit{ESS} + \textit{RSS}$ y $\sum \hat{\varepsilon}_i = 0$.
4. Extraer una muestra aleatoria de $n = 100$ y repetir 1000 veces: graficar la distribución de $\hat{\beta}_1$ y comparar su desvío con el *SE* de una de las muestras.
5. Testear $H_0 : \beta_1 = 0$ y $H_0 : \beta_1 = 0{,}05$. Reportar t, p-valor e IC 95 %.
6. Repetir (1) con $n = 20$: ¿sigue siendo significativo?
7. Graficar el histograma de los residuos: ¿son normales?

Opcional: replicar en código el ejemplo de las campañas (cuaderno `simple_linear_regression_notebook` del libro).

Referencias

- Pasquini, R. *Econometrics with Simulations*: Regresión Lineal Simple; Insesgadez y Varianza de MCO; Tests de Hipótesis en Regresión Simple. Dashboards en simuecon.com.
- Wooldridge, J. *Introductory Econometrics*, caps. 2 y 4.
- Lumley, T. et al. (2002). The importance of the normality assumption in large public health data sets. *Annual Review of Public Health*.

A.1 $TSS = ESS + RSS$

Partimos de $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + \hat{\varepsilon}_i$. Elevamos al cuadrado y sumamos:

$$TSS = \underbrace{\sum(\hat{Y}_i - \bar{Y})^2}_{ESS} + 2\sum(\hat{Y}_i - \bar{Y})\hat{\varepsilon}_i + \underbrace{\sum \hat{\varepsilon}_i^2}_{RSS}$$

El término cruzado es cero:

$$\sum(\hat{Y}_i - \bar{Y})\hat{\varepsilon}_i = \underbrace{\sum \hat{Y}_i\hat{\varepsilon}_i}_{0 \text{ (P3)}} - \bar{Y}\underbrace{\sum \hat{\varepsilon}_i}_{0 \text{ (P1)}} = 0$$

donde P3 se sigue de P1 y P2, ya que $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$:

$$\sum \hat{Y}_i\hat{\varepsilon}_i = \hat{\beta}_0 \sum \hat{\varepsilon}_i + \hat{\beta}_1 \sum X_i\hat{\varepsilon}_i = 0$$

Por lo tanto $TSS = ESS + RSS$. ■

A.2 Insesgadez de $\hat{\beta}_1$ y $\hat{\beta}_0$

Paso 1. Con $\hat{\beta}_1 = \sum(X_i - \bar{X})Y_i/SST_x$ y $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$:

$$\hat{\beta}_1 = \frac{\sum(X_i - \bar{X})(\beta_0 + \beta_1 X_i + \varepsilon_i)}{SST_x} = \beta_1 + \frac{\sum(X_i - \bar{X})\varepsilon_i}{SST_x}$$

(se usa $\sum(X_i - \bar{X}) = 0$ y $\sum(X_i - \bar{X})X_i = SST_x$).
Paso 2. Esperanza condicional en X:

$$E[\hat{\beta}_1 \mid X] = \beta_1 + \frac{1}{SST_x}\sum(X_i - \bar{X})\underbrace{E[\varepsilon_i \mid X]}_{=0} = \beta_1$$

Como vale para toda realización de X, $E[\hat{\beta}_1] = \beta_1$.
Para $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X}$: tomando esperanza condicional,
$E[\hat{\beta}_0 \mid X] = \beta_0 + \beta_1\bar{X} - \beta_1\bar{X} = \beta_0$. ■

A.3 Varianza de $\hat{\beta}_1$

De A.2, $\hat{\beta}_1 - \beta_1 = \sum c_i \varepsilon_i$ con $c_i = (X_i - \bar{X})/SST_x$ y $\sum c_i^2 = 1/SST_x$. Con errores independientes y $\mathrm{Var}(\varepsilon_i \mid X) = \sigma^2$:

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \sum c_i^2 \, \sigma^2 = \frac{\sigma^2}{SST_x} \qquad \blacksquare$$

A.4 $\hat{\sigma}^2 = RSS/(n-2)$ es insesgado (esbozo)

- En forma matricial, $\hat{\varepsilon} = (\mathrm{I} - \mathrm{H})\varepsilon$, con $\mathrm{H} = \mathrm{X}(\mathrm{X}'\mathrm{X})^{-1}\mathrm{X}'$ simétrica e idempotente.
- Entonces

$$E[RSS] = E[\varepsilon'(\mathrm{I} - \mathrm{H})\varepsilon] = \sigma^2 \operatorname{tr}(\mathrm{I} - \mathrm{H}) = \sigma^2(n-2)$$

  porque $\operatorname{tr}(\mathrm{H}) = 2$ (dos columnas en X).
- Luego $E[\hat{\sigma}^2] = \sigma^2$. ■

A.5 $T \sim t_{n-2}$ bajo normalidad (esbozo)

Con $\varepsilon_i \mid X \sim N(0, \sigma^2)$ independientes:

1. $\hat{\beta}_1 \sim N(\beta_1, \sigma^2/SST_x)$, luego $Z = \dfrac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/SST_x}} \sim N(0,1)$.
2. $(n-2)\hat{\sigma}^2/\sigma^2 \sim \chi^2_{n-2}$ (proyección idempotente de rango $n-2$; Teorema de Cochran).
3. $\hat{\beta}_1$ y $\hat{\sigma}^2$ son independientes (dependen de proyecciones ortogonales de un vector normal).

Una normal estándar sobre la raíz de una $\chi^2_{n-2}/(n-2)$ independiente es una t_{n-2}:

$$T = \frac{Z}{\sqrt{\hat{\sigma}^2/\sigma^2}} = \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \sim t_{n-2} \qquad \blacksquare$$