Herramientas Econométricas

Regresión Múltiple, Variables Categóricas e Interacciones

Ricardo Pasquini

UCA

22 de octubre de 2026

Plan de la clase

1. **Regresión múltiple**: el modelo, la interpretación "manteniendo lo demás constante" y el estimador MCO
2. **Propiedades estadísticas**: insesgadez, varianza y multicolinealidad
3. **Especificación**: variables omitidas e irrelevantes
4. **Variables categóricas**: dummies, k categorías e interacciones

Dos ejemplos a lo largo de la clase

1. Ingresos, escolaridad y sexo en CABA (EAH 2016, $n = 10{,}048$): ejemplo principal.
2. Resultados escolares y gestión privada (308 escuelas) y **salarios en una empresa tecnológica** (datos simulados del libro *Econometrics with Simulations*): para jugar con los dashboards, porque *conocemos* el proceso verdadero.

Objetivos

Al finalizar esta clase podrán:

1. Interpretar un coeficiente de regresión múltiple como un efecto parcial, "controlando por" las demás variables.
2. Explicar cómo se estima el modelo (MCO, momentos) y qué dice el teorema de Frisch-Waugh-Lovell.
3. Explicar de qué depende la varianza de $\hat{\beta}_j$ y por qué la multicolinealidad afecta la precisión pero no el sesgo.
4. Identificar el sesgo por variable omitida y su dirección; entender el costo de incluir variables irrelevantes.
5. Incorporar variables categóricas (dummies, k categorías) y elegir la categoría de referencia.
6. Especificar e interpretar un modelo con interacciones y testear si las pendientes difieren.

Motivación: ¿estamos midiendo lo que creemos medir?

- La realidad económica rara vez se explica con una sola variable: el ingreso no depende solo de la escolaridad.
- Querer medir el efecto de una variable ignorando las demás nos expone a un problema fundamental: **¿medimos lo que creemos o confundimos efectos?**
- La regresión múltiple incluye varias variables explicativas a la vez e intenta aislar el efecto de cada una **manteniendo constantes las demás**.

Wooldridge

"The power of multiple regression analysis is that it allows us to do in nonexperimental environments what natural scientists are able to do in a controlled laboratory setting: keep other factors fixed."

El modelo de regresión múltiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

- $x_1, \ldots, x_k$: k regresores; $\beta_0, \ldots, \beta_k$: parámetros poblacionales; ε: todo lo que afecta a y y no está en el modelo.
- Ejemplo principal:

$$\log(\textit{ingreso}_i) = \beta_0 + \beta_1\, \textit{aesc}_i + \beta_2\, \textit{mujer}_i + \varepsilon_i$$

- Ejemplo del libro (concesionarios):
  $\textit{ventas} = \beta_0 + \beta_1\, \textit{publicidad} + \beta_2\, \textit{vendedores} + \varepsilon$.
- La diferencia clave con la regresión simple está en la **interpretación**.

Interpretación: efecto parcial

- Regresión simple: β_1 es la asociación *bruta* entre x_1 e y. Puede estar "contaminada": los concesionarios que más gastan en publicidad suelen tener más vendedores.
- Regresión múltiple: β_1 mide el efecto de x_1 **una vez tomado en cuenta** x_2:

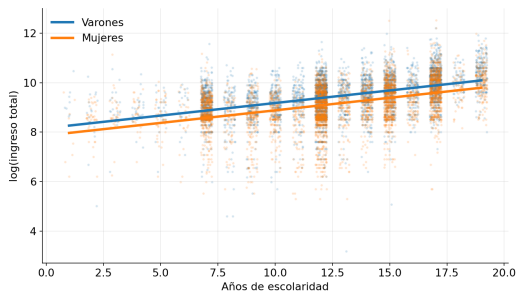
$$\beta_1 = \frac{\partial E[y \mid x_1, x_2]}{\partial x_1}$$

- Se dice "controlando por x_2" o "manteniendo x_2 constante": la comparación es entre unidades *con el mismo* x_2 que difieren en x_1.
- Un cambio sustancial de significado: el coeficiente de x_1 en el modelo simple y en el múltiple son, en general, **dos objetos distintos**.

Aplicación: ingresos, escolaridad y sexo (EAH 2016)

$$\widehat{\log(\textit{ingreso})} = 8{,}16 + 0{,}1015\ \textit{aesc} - 0{,}296\ \textit{mujer} \qquad (n = 10{,}048,\ R^2 = 0{,}226)$$

- $\hat{\beta}_{\textit{aesc}} = 0{,}1015$: comparando personas *del mismo sexo*, un año más de escolaridad se asocia con $\approx 10{,}7\,\%$ más de ingreso.
- $\hat{\beta}_{\textit{mujer}} = -0{,}296$ ($SE = 0{,}015$): comparando personas *con la misma escolaridad*, las mujeres ganan en promedio un **25.6 % menos** ($e^{-0{,}296} - 1$).



Dos rectas **paralelas**: misma pendiente, interceptos separados por $\hat{\beta}_{\textit{mujer}}$.

Un resultado interesante: la pendiente casi no cambió

	$\hat{\beta}_{aesc}$	$SE(\hat{\beta}_{aesc})$	R^2
$\log y \sim aesc$	0.1020	0.0021	0.197
$\log y \sim aesc + mujer$	0.1015	0.0020	0.226
$\log y \sim aesc + mujer + edad + edad^2$	0.1011	0.0020	0.281

- Agregar el sexo **no cambió** el coeficiente de escolaridad: en la muestra, varones y mujeres tienen casi la misma escolaridad (12,7 y 12,6 años).
- Pero sí mejoró el ajuste (R^2 de 0.197 a 0.226) y bajó levemente el error estándar: el sexo "limpia" parte del ruido.
- Controlar por una variable cambia el coeficiente de interés cuando está **correlacionada con ese regresor**. Lo formalizamos en la Parte C.

Agregando la edad: una cuadrática

$$\log(\mathit{ing}) = \beta_0 + \beta_1\, \mathit{aesc} + \beta_2\, \mathit{mujer} + \beta_3\, \mathit{edad} + \beta_4\, \mathit{edad}^2 + \varepsilon$$

- $\hat{\beta}_3 = 0{,}048$, $\hat{\beta}_4 = -0{,}00040$: el perfil del ingreso con la edad es cóncavo; el máximo se alcanza a los $-\hat{\beta}_3/(2\hat{\beta}_4) \approx 61$ años.
- Con *edad* y edad^2 en el modelo, ya no se interpreta cada coeficiente por separado: el efecto de la edad depende de la edad, $\partial \log y / \partial \mathit{edad} = \beta_3 + 2\beta_4\, \mathit{edad}$.
- El R^2 sube a 0.281; la pendiente de la escolaridad se mantiene en 0.1011.

Estimación: MCO en el modelo múltiple

- Mismo criterio que en la regresión simple: elegir $\hat{\beta}_0, \ldots, \hat{\beta}_k$ que minimicen

$$RSS = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_k x_{ki})^2$$

- Las condiciones de primer orden ($k+1$ ecuaciones, las **ecuaciones normales**) exigen que los residuos sean ortogonales a cada regresor:

$$\sum_i \hat{\varepsilon}_i = 0, \qquad \sum_i x_{ji} \hat{\varepsilon}_i = 0 \quad (j = 1, \ldots, k)$$

- La solución es única si ningún regresor es combinación lineal exacta de los otros. En forma matricial: $\hat{\boldsymbol{\beta}} = (X'X)^{-1} X'y$ (Apéndice).

Estimación: método de los momentos

- El supuesto $E[\varepsilon \mid x_1, \ldots, x_k] = 0$ genera $k+1$ condiciones de momentos:

$$E[\varepsilon] = 0, \qquad E[\varepsilon\, x_j] = 0 \quad (j = 1, \ldots, k)$$

- Reemplazando esperanzas por promedios muestrales: sistema de $k+1$ ecuaciones con $k+1$ incógnitas, exactamente identificado.
- Mismos estimadores que MCO, como en la regresión simple.
- $\Rightarrow$ Para interpretar $\hat{\beta}_j$ como "efecto" hace falta que ε no esté correlacionado con **ninguno** de los regresores incluidos.

Frisch-Waugh-Lovell: ¿qué significa "controlar por"?

Teorema. El coeficiente $\hat{\beta}_j$ de la regresión múltiple coincide con el de la regresión simple de y sobre $\tilde{x}_j$:

$$\hat{\beta}_j = \frac{\sum_i \tilde{x}_{ij}\, y_i}{\sum_i \tilde{x}_{ij}^2}$$

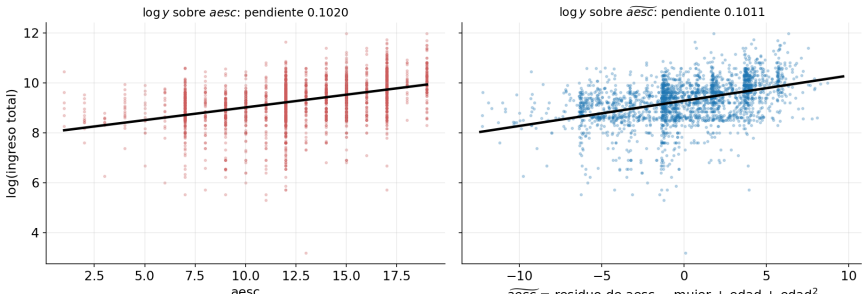
donde $\tilde{x}_j$ es el **residuo** de regresar x_j sobre todos los demás regresores.

1. Regresar x_j sobre los demás regresores: $x_j = \hat{x}_j + \tilde{x}_j$.
2. $\tilde{x}_j$ es la parte de x_j *no explicada* por los demás: la "variación propia" o neta de x_j.
3. $\hat{\beta}_j$ es la pendiente de y sobre esa variación propia.

"Controlar por" = **limpiar** x_j de todo lo que comparte con los demás regresores.

Frisch-Waugh-Lovell en la EAH

Limpiamos *aesc* de *mujer*, *edad* y $edad^2$: $\widetilde{aesc}$ = residuo de $aesc \sim mujer + edad + edad^2$ ($R^2 = 0{,}056$).



- Pendiente de $\log y$ sobre $\widetilde{aesc}$: 0.1011 (SE 0.0021). Es **exactamente** el $\hat{\beta}_{aesc} = 0{,}1011$ de la regresión múltiple completa.

Qué nos dice FWL sobre la precisión

- La variación que identifica a β_j es la **variación propia** $\tilde{x}_j$, no la total.
- Si x_j está muy explicada por los otros regresores, $\tilde{x}_j$ tiene poca variación y la pendiente se estima con mucha incertidumbre.
- Ese es exactamente el efecto de la **multicolinealidad**, que veremos a continuación.

[Pausa]

Supuestos

M1 **Linealidad en los parámetros**: $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \varepsilon$.

M2 **Muestreo aleatorio** de la población.

M3 **Sin multicolinealidad perfecta**: ningún regresor es combinación lineal exacta de los otros.

M4 **Media condicional cero**: $E[\varepsilon \mid x_1, \ldots, x_k] = 0$.

M5 **Homocedasticidad**: $\mathrm{Var}(\varepsilon \mid x_1, \ldots, x_k) = \sigma^2$.

- M1–M4 $\Rightarrow$ **insesgadez**: $E[\hat{\beta}_j] = \beta_j$ para todo $j = 0, 1, \ldots, k$.
- M5 $\Rightarrow$ fórmula de la **varianza**.
- M3 es nuevo respecto de la regresión simple (allí equivale a que x varíe).

La varianza de $\hat{\beta}_j$

$$\boxed{\mathrm{Var}(\hat{\beta}_j \mid X) = \frac{\sigma^2}{SST_j\,(1 - R_j^2)}}$$

- $\sigma^2 = \mathrm{Var}(\varepsilon)$: la varianza del error.
- $SST_j = \sum_i (x_{ij} - \bar{x}_j)^2$: la variación total del regresor j.
- R_j^2: el R^2 de la **regresión auxiliar** de x_j sobre *todos los demás regresores*.

Con $k = 1$ no hay regresión auxiliar ($R_j^2 = 0$) y se recupera σ^2/SST_x. (Derivación en el Apéndice: sale directo de FWL, ya que $\sum \tilde{x}_{ij}^2 = SST_j(1 - R_j^2)$.)

Los determinantes de la precisión

- **Más ruido** ($\sigma^2 \uparrow$) $\Rightarrow$ más varianza.
- **Más variación en** x_j ($SST_j \uparrow$) $\Rightarrow$ menos varianza.
- **Más correlación de** x_j **con los demás regresores** ($R_j^2 \uparrow$) $\Rightarrow$ más varianza. Factor nuevo: ya no alcanza con "mucha variación en x_j", tiene que ser variación **propia**.

Factor de inflación de la varianza

$VIF_j = \dfrac{1}{1 - R_j^2}$: cuántas veces se infla $\mathrm{Var}(\hat{\beta}_j)$ por la correlación con los otros regresores. $R_j^2 = 0{,}9 \Rightarrow VIF = 10$ y el error estándar se multiplica por $\approx 3{,}2$.

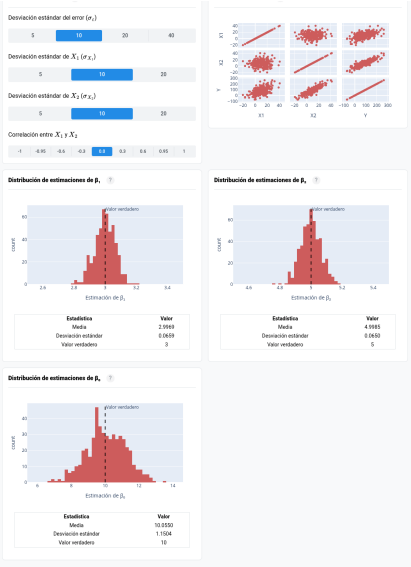
Simulación: insesgadez y varianza en regresión múltiple

[Dashboard: Regresión múltiple (`multiple_regression`)] Verdad: $y = 10 + 3x_1 + 5x_2 + \varepsilon$. Controles: σ_ε, σ_{X_1}, σ_{X_2} y la **correlación entre x_1 y x_2**.

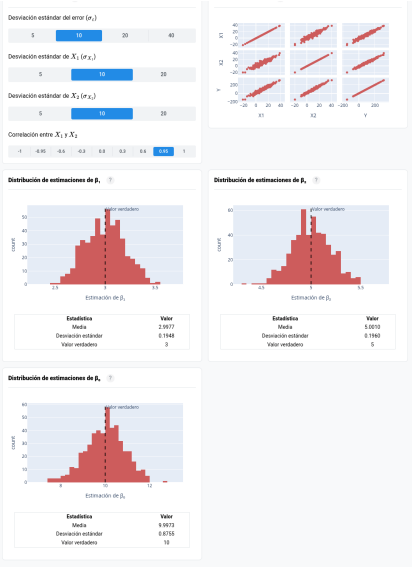
- ¿Están centrados los histogramas de $\hat{\beta}_1$ y $\hat{\beta}_2$ en los valores verdaderos? ¿Cambia eso con la correlación?
- Con correlación 0: ¿qué pasa con la dispersión al subir σ_ε? ¿Y al subir σ_{X_1}?
- **Subí la correlación entre x_1 y x_2 a 0.95**: ¿qué le pasa a la dispersión de *ambos* estimadores? ¿Y al centro?

[Actividad en clase: 5 minutos]

Dashboard: correlación entre x_1 y x_2 igual a 0



Dashboard: correlación entre x_1 y x_2 igual a 0.95



Qué observamos

- **Insesgadez**: en todas las configuraciones los histogramas están centrados en los valores verdaderos, también con correlación alta entre los regresores.
- **Ruido**: más σ_ε ensancha las distribuciones, igual que en la regresión simple.
- **Dispersión de los regresores**: más σ_{X_j} estrecha la distribución de $\hat{\beta}_j$.
- **Correlación entre regresores**: sin análogo en la regresión simple. Al acercarse a 1 las distribuciones de **ambos** estimadores se ensanchan mucho, sin perder el centro.

Esto es el factor $(1 - R_j^2)$ de la fórmula: la teoría lo predice exactamente.

Multicolinealidad

- **Perfecta**: un regresor es combinación lineal exacta de otros ($R_j^2 = 1$): la varianza no está definida, $X'X$ no es invertible y MCO no existe. Ejemplo: años y meses de experiencia.
- **Imperfecta**: correlación alta pero no perfecta. MCO existe, pero los errores estándar pueden ser muy grandes: estadísticos t chicos y coeficientes "no significativos" aunque las variables sean **conjuntamente** importantes.
- Síntoma clásico: el test F conjunto rechaza, pero ningún coeficiente individual parece significativo.

Dos puntos prácticos

1. La multicolinealidad **no introduce sesgo**: es un problema de precisión.
2. Más observaciones no lo resuelven si la correlación está en la población.

Ejemplo: resultados escolares y desempeño en pruebas ($n = 308$ escuelas)

Variable explicada: tasa de repetición 2012. Regresores: % de alumnos con nivel alto en Matemática, Cs. Naturales y Cs. Sociales (correlaciones 0,74, 0,68 y 0,71 entre ellas).

	Solo Matemática	Las tres juntas	
	coef. (SE)	coef. (SE)	t
Alto en Matemática	-23.5 (2.9)	-9.5 (4.4)	-2.2
Alto en Cs. Naturales		-10.0 (5.9)	-1.7
Alto en Cs. Sociales		-13.6 (4.7)	-2.9
R^2	0.179	0.228	

- El efecto de Matemática pasa de $t = -8{,}2$ a $t = -2{,}2$: el coeficiente se reparte entre variables que miden lo mismo y su *SE* se multiplica por 1.5 ($VIF \approx 2{,}4$).
- Test F conjunto: $F = 29{,}9$ ($p < 0{,}001$): las tres variables son *conjuntamente* muy relevantes.

Estimación de la varianza y tests con regresión múltiple

- σ^2 se estima con los residuos, corrigiendo por los $k+1$ parámetros estimados:

$$\hat{\sigma}^2 = \frac{RSS}{n-k-1} \qquad SE(\hat{\beta}_j) = \sqrt{\frac{\hat{\sigma}^2}{SST_j(1-R_j^2)}}$$

- El test de $H_0 : \beta_j = 0$ es el mismo de la clase anterior, ahora con $n-k-1$ grados de libertad:

$$\hat{T} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-k-1}$$

- Interpretación: significancia de β_j *controlando por* los demás regresores.
- El $R^2 = 1 - RSS/TSS$ **nunca baja** al agregar variables, aunque sean irrelevantes.

Cierre de las Partes A y B

- β_j es un efecto parcial: "manteniendo constantes las demás variables".
- MCO es insesgado bajo M1–M4; no pide ausencia de correlación entre los regresores, solo que no sean perfectamente colineales.
- $\mathrm{Var}(\hat{\beta}_j) = \sigma^2/[SST_j(1 - R_j^2)]$: más ruido, menos variación propia o más colinealidad, peor precisión.
- FWL conecta todo: $\hat{\beta}_j$ usa la variación *propia* de x_j.

Lo que sigue

Todo lo anterior supone que el modelo está **correctamente especificado**. ¿Qué pasa si omitimos una variable relevante, o incluimos una que no lo es?

Problemas de especificación

- Un problema de especificación es cualquier discrepancia entre el modelo que estimamos y el proceso generador de datos.
- Dos errores frecuentes, con consecuencias **asimétricas**:
  - **omitir** una variable relevante $\Rightarrow$ **sesgo**;
  - **incluir** una variable irrelevante $\Rightarrow$ pérdida de precisión, sin sesgo... en el caso simple.
- Aquí lo vemos brevemente: el tema se retoma en profundidad en la segunda parte del curso, cuando hablemos de causalidad.

Sesgo por variable omitida

Verdad: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$. Estimamos sin x_2: $y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + u$.

$$\boxed{E[\tilde{\beta}_1] = \beta_1 + \beta_2 \, \delta_1}$$

donde δ_1 es la pendiente de la regresión auxiliar $x_2 = \delta_0 + \delta_1 x_1 + v$.

- El sesgo es $\beta_2 \delta_1$: efecto de la omitida sobre y $\times$ asociación entre la omitida y la incluida.
- No hay sesgo si $\beta_2 = 0$ (no era relevante) **o** $\delta_1 = 0$ (no está correlacionada con x_1).
- La dirección sale de los signos: $\beta_2 > 0$ y $\delta_1 > 0 \Rightarrow$ sobreestima.

(Demostración en el Apéndice.)

Dirección del sesgo

Signo de β_2	Correlación x_2–x_1	Sesgo en $\tilde{\beta}_1$
$+$	$+$	hacia arriba (sobreestima)
$+$	$-$	hacia abajo (subestima)
$-$	$+$	hacia abajo (subestima)
$-$	$-$	hacia arriba (sobreestima)

Concesionarios: si los que más gastan en publicidad también tienen más vendedores ($\delta_1 > 0$) y los vendedores aumentan las ventas ($\beta_2 > 0$), la regresión simple que omite *vendedores* **sobreestima** el efecto de la publicidad.

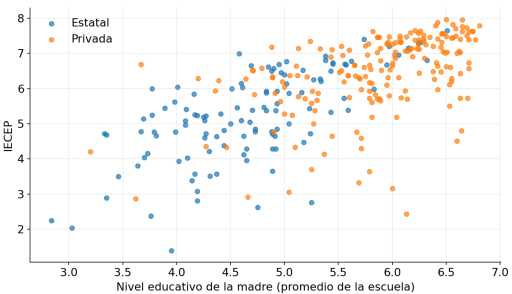
Ejemplo: ¿importa si la escuela es privada?

Variable explicada: **IECEP**, indicador de resultados de la escuela ($n = 308$: 192 privadas, 116 estatales).

	(1)	(2)
Privada	1.225 (0.139)	0.090 (0.148)
Nivel educativo de la madre		0.967 (0.080)
R^2	0.203	0.461

- (1): las escuelas privadas tienen un IECEP 1.225 puntos mayor. ¿Es *efecto* de la gestión privada?
- (2): al controlar por el nivel educativo de la madre (un proxy del contexto socioeconómico) el coeficiente cae a 0.090 y deja de ser significativo ($t = 0{,}61$).

Por qué cambió: el sesgo es $\beta_2\delta_1$



- $\hat{\beta}_2 = 0{,}967$: la educación de la madre se asocia fuertemente con el IECEP.
- $\hat{\delta}_1 = 1{,}174$: las privadas tienen madres con $\approx 1{,}2$ puntos más de nivel educativo (5.86 vs. 4.69; $R^2 = 0{,}402$).
- Sesgo $= 0{,}967 \times 1{,}174 = 1{,}135$ y

$$\underbrace{1{,}225}_{\text{corto}} = \underbrace{0{,}090}_{\text{largo}} + \underbrace{1{,}135}_{\text{sesgo}}$$

Explorando el sesgo por variable omitida

[Dashboard: Sesgo por variable omitida (`ovb`)] Se compara el estimador del modelo correcto con el del modelo que omite x_2. Controles: correlación entre x_1 y x_2, y efecto β_2.

- Con correlación 0: ¿hay sesgo? ¿Cuánto vale?
- Con correlación 0.6 y $\beta_2 = 5$: ¿hacia dónde se desplaza la distribución de $\tilde{\beta}_1$? ¿Y con correlación $-0{,}6$?
- Con correlación 0.6 y $\beta_2 = 0$: ¿desaparece el sesgo?

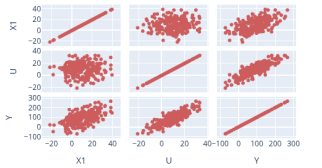
Dashboard: sin correlación ($\delta_1 = 0$)

Correlación entre X_1 y U

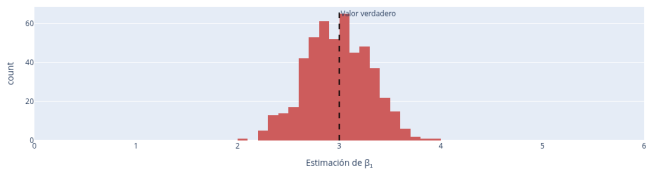
-0.9	-0.6	-0.3	**0.0**	0.3	0.6	0.9

Valor de β_2

-5.0	-2.5	0.0	2.5	**5.0**



Distribución de estimaciones de β_1



Estadística	Valor
Media	2.9861
Desviación estándar	0.3143
Valor verdadero	3

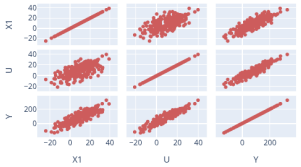
Dashboard: correlación 0.6, $\beta_2 = 5$

Correlación entre X_1 y U

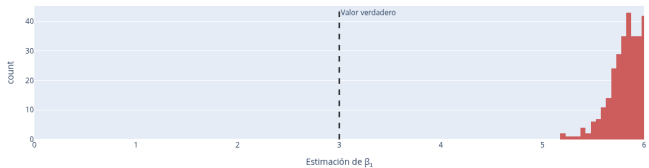
-0.9	-0.6	-0.3	0.0	0.3	**0.6**	0.9

Valor de β_2

-5.0	-2.5	0.0	2.5	**5.0**



Distribución de estimaciones de β_1



Estadística	Valor
Media	5.9871
Desviación estándar	0.2604
Valor verdadero	3

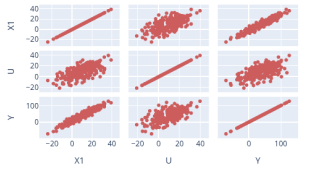
Dashboard: correlación 0.6, $\beta_2 = 0$

Correlación entre X_1 y U

-0.9	-0.6	-0.3	0.0	0.3	**0.6**	0.9

Valor de β_2

-5.0	-2.5	**0.0**	2.5	5.0



Distribución de estimaciones de β_1



Estadística	Valor
Media	3.0006
Desviación estándar	0.0610
Valor verdadero	3

De vuelta a los ingresos: ¿por qué no hubo sesgo al omitir el sexo?

- Omitir *mujer* sesgaría $\hat{\beta}_{aesc}$ en $\beta_{mujer} \times \delta$, donde δ es la pendiente de *mujer* $\sim$ *aesc*.
- Acá $\beta_{mujer} = -0{,}296 \neq 0$ pero $\hat{\delta} = -0{,}0017$ ($t = -1{,}3$): la escolaridad es prácticamente la misma en varones y mujeres.
- Sesgo $\approx -0{,}296 \times (-0{,}0017) \approx 0{,}0005$: de ahí que $\hat{\beta}_{aesc}$ pase de 0.1020 a 0.1015 (el pequeño cambio).
- Aun así vale la pena incluir *mujer*: mejora el ajuste y la precisión. Con otra variable correlacionada con *aesc* (p.ej. el origen social) el cambio sería grande.

Inclusión de variables irrelevantes

- Verdad: $y = \beta_0 + \beta_1 x_1 + \varepsilon$. Estimamos con x_2 de más (con $\beta_2 = 0$ en la población).
- El modelo estimado es compatible con el verdadero: $\hat{\beta}_1$ sigue siendo insesgado y esperamos $\hat{\beta}_2 \approx 0$.
- **Pero hay un costo**: x_2 puede estar correlacionada con x_1 ($R_1^2 > 0$) y entonces

$$\mathrm{Var}(\hat{\beta}_1) = \frac{\sigma^2}{SST_1(1 - R_1^2)} \text{ aumenta}$$

- Mayor SE, estadísticos t más chicos, menos potencia para rechazar.

Cuidado: "más controles" no es siempre mejor

Que incluir una variable irrelevante no sesgue vale en ese caso particular. **No es general**: en un contexto causal, incluir ciertas variables sí puede sesgar.

- **Mediador**: variable en la cadena causal entre x_1 e y. Controlar por ella bloquea ese canal y subestima el efecto total.
- **Colisionador**: variable causada por x_1 y por y (o por factores correlacionados con ellos). Controlar por ella abre una asociación espuria.

Ejemplo (EAH): al agregar *estado* (ocupado, desocupado, inactivo), $\hat{\beta}_{aesc}$ cae de 0.1015 a 0.0876. Parte del retorno de la educación opera *a través de* conseguir empleo: *estado* es un mediador.

La decisión de qué controlar no es solo estadística: requiere pensar la estructura causal. Lo veremos en la parte de inferencia causal.

Cierre de la Parte C

- Omitir una variable relevante **correlacionada** con un regresor sesga: $E[\tilde{\beta}_1] = \beta_1 + \beta_2\delta_1$.
- Incluir una irrelevante no sesga pero infla la varianza (si está correlacionada con los otros regresores).
- Pero "incluir más" no es gratis cuando hay estructura causal: mediadores y colisionadores.

[Pausa]

El problema: grupos en una regresión continua

- Las variables explicativas no siempre son continuas: el sexo, el departamento, el tipo de plan contratado, el estado ocupacional.
- Ejemplo del libro: salario de empleados de una empresa de tecnología según años de experiencia **y** departamento (Ingeniería vs. otras áreas).
- Con una sola recta, esta pasa entre las dos nubes sin ajustar a ninguna: es omitir una variable relevante, probablemente correlacionada con la experiencia.
- Alternativa: dos regresiones separadas. Pero cada una usa solo una fracción de los datos y pierde precisión.
- ¿Hay una forma de distinguir los grupos **sin sacrificar observaciones**?

La variable dummy

Una **dummy** (indicadora) vale 1 si la observación pertenece a una categoría y 0 si no:

$$D_i = \begin{cases} 1 & \text{si el empleado } i \text{ trabaja en Ingeniería} \\ 0 & \text{en otro caso} \end{cases}$$

Se incluye como cualquier regresor y se estima por MCO sin modificaciones:

$$\mathit{Salario}_i = \beta_0 + \beta_1 \, \mathit{Experiencia}_i + \beta_2 \, D_i + \varepsilon_i$$

- EAH: $\mathit{mujer}_i = 1$ si la persona es mujer, 0 si es varón.
- ¿Por qué 0/1 y no "1 para ingeniería, 2 para otra"? La codificación numérica impone una distancia entre categorías que no tiene sentido; 0/1 solo dice que los grupos son distintos.

Una dummy genera dos rectas paralelas

Fuera de Ingeniería ($D = 0$): $E[Salario \mid Exp, D = 0] = \beta_0 + \beta_1 Exp$.
Ingeniería ($D = 1$): $E[Salario \mid Exp, D = 1] = (\beta_0 + \beta_2) + \beta_1 Exp$.

- **Misma pendiente** β_1, interceptos separados exactamente por β_2.
- β_2: diferencia esperada de salario entre un ingeniero y alguien de otra área **con igual experiencia**. Si $\hat{\beta}_2 = 30$: 30 mil dólares más al año.
- β_1: efecto de un año de experiencia, manteniendo constante el departamento.
- Si los ingenieros tienen más experiencia en promedio, omitir la dummy **sobreestima** el retorno de la experiencia (sesgo por variable omitida, otra vez).

Explorando el efecto de la dummy

[Dashboard: Variables dummy (`dummy_variables`)] Verdad:
$Salario = 50 + 2\,Exp + 30\,D + \varepsilon$ (sobresueldo de Ingeniería $= 30$).

- Modelo **sin dummy**: una línea promedia sobre las dos nubes. ¿Se ajusta bien a alguna?
- Modelo **con dummy**: ¿cuántas líneas? ¿son paralelas? ¿dónde queda la separación respecto de $\hat{\beta}_2$?
- Compará el R^2 y el coeficiente de experiencia entre los dos modelos.

[Actividad en clase: 5 minutos]

Dashboard: sin dummy

Selector de modelo

Sin modelo

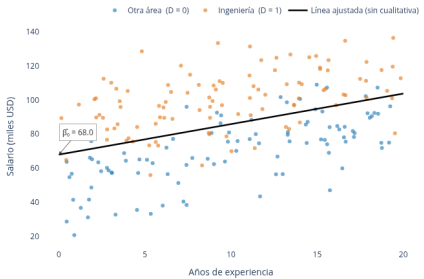
Sin variable cualitativa

Con variable cualitativa

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \, \text{Exp}_i + \hat{\varepsilon}_i$$

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	67.9789	3.0361	< 0.001
Experiencia (β_1)	1.7910	0.2670	< 0.001
R^2		0.1852	
MSE		452.3349	

Referencias

Dashboard: con dummy

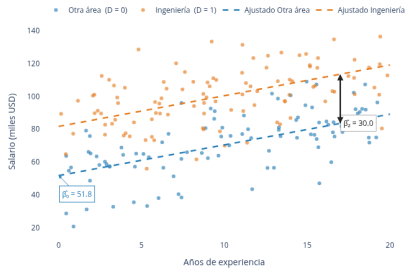
Selector de modelo

Sin modelo
Sin variable cualitativa
Con variable cualitativa

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_i + \hat{\epsilon}_i$$

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	51.7620	2.4427	< 0.001
Experiencia (β_1)	1.8710	0.1894	< 0.001
Ingeniería (β_2)	29.9548	2.1341	< 0.001
R^2	0.5926		
MSE	227.3036		

Referencias

Aplicación: la brecha de ingresos por sexo

	$\hat{\beta}_{mujer}$	*SE*
$\log y \sim mujer$	-0.306	0.017
$\log y \sim aesc + mujer$	-0.296	0.015
$\log y \sim aesc + mujer + edad + edad^2$	-0.310	0.015

- Sin controles, las mujeres ganan $\approx 26\,\%$ menos ($e^{-0{,}306} - 1$); a igual escolaridad, $\approx 25{,}6\,\%$; a igual escolaridad y edad, $\approx 27\,\%$.
- La brecha **no se explica por diferencias de escolaridad** (son casi iguales): el $\hat{\beta}_{mujer}$ casi no cambia al controlar por *aesc*.
- Es una brecha condicional: la comparación entre mujeres y varones *con las mismas características incluidas*. Interpretarla como discriminación requiere supuestos adicionales.

De dos grupos a k grupos

- Tres departamentos: Ingeniería, Ventas, Marketing. Una dummy por categoría:

$$D_{Ing,i}, \qquad D_{Ven,i}, \qquad D_{Mkt,i}$$

- Ejemplo EAH: *estado* con tres categorías (ocupado, desocupado, inactivo).
- ¿Qué pasa si incluimos las tres a la vez junto con la constante?

$$Salario_i = \beta_0 + \beta_1 Exp_i + \beta_2 D_{Ing} + \beta_3 D_{Ven} + \beta_4 D_{Mkt} + \varepsilon_i$$

La trampa de las variables dummy

- Cada empleado pertenece a exactamente un departamento, entonces para toda observación

$$D_{Ing,i} + D_{Ven,i} + D_{Mkt,i} = 1$$

  y esa suma es la columna del intercepto.
- Hay una combinación lineal exacta entre los regresores: **multicolinealidad perfecta**. $X'X$ es singular y MCO no existe.
- Solución: **omitir una categoría**, que pasa a ser la categoría de referencia.

Regla general

Para una variable categórica con k categorías, incluir exactamente $k - 1$ dummies (si el modelo tiene constante).

Explorando k categorías

[Dashboard: Múltiples categorías (`multiple_categories`)] Verdad:
$Salario = \alpha_{depto} + 2\,Exp + \varepsilon$, con $\alpha_{Ing} = 80$, $\alpha_{Ven} = 50$, $\alpha_{Mkt} = 20$.

- Con **las tres dummies**: ¿qué advertencia aparece? ¿Por qué?
- Con **dos dummies**: cambien la categoría de referencia. ¿Cambian los coeficientes? ¿Cambia el R^2 o el ajuste de las rectas?
- Con **una sola dummy**: ¿qué pasa con los grupos que quedan juntos?

[Actividad en clase: 5 minutos]

Dashboard: las tres dummies (la trampa)

Selector de modelo

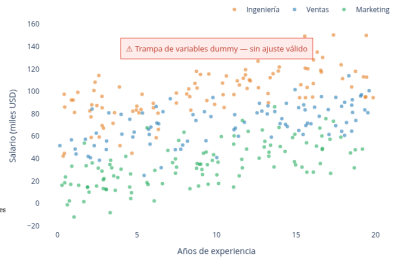
- Sin modelo
- Solo D_Ing
- Solo D_Ven
- Solo D_Mkt
- D_Ing + D_Ven (ref: Mkt)
- D_Ing + D_Mkt (ref: Ven)
- D_Ven + D_Mkt (ref: Ing)
- **Las tres (trampa)**

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_{\text{Eng},i} + \hat{\beta}_3 \, D_{\text{Sales}}$$

⚠ Trampa de variables dummy — ver advertencia abajo

Salario vs. años de experiencia



Resultados de la regresión

Trampa de Variables Dummy

Incluir D_A, D_B **y** D_C junto con la constante genera **multicolinealidad perfecta**: $D_{A,i} + D_{B,i} + D_{C,i} = 1$ para cada observación, lo que es idéntico a la columna de intercepto.

La matriz de diseño es de rango deficiente y MCO no puede estimarse de forma única. Los paquetes estadísticos resuelven esto omitiendo silenciosamente una dummy redundante (aquí, D_C). El resultado que se muestra a continuación es por tanto idéntico al modelo **D_A + D_B** con categoría de referencia C.

Conclusiones

Referencias

Dashboard: dos dummies (referencia Marketing)

Selector de modelo

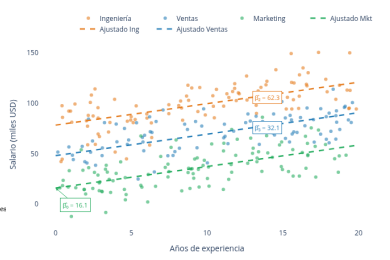
- Sin modelo
- Solo D_Ing
- Solo D_Ven
- Solo D_Mkt
- **D_Ing + D_Ven (ref: Mkt)**
- D_Ing + D_Mkt (ref: Ven)
- D_Ven + D_Mkt (ref: Ing)
- Las tres (trampa)

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_{\text{Eng},i} + \hat{\beta}_3 \, D_{\text{Sales}}$$

Categoría de referencia: Marketing

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	16.1036	1.9906	< 0.001
Experiencia (β_1)	2.1244	0.1539	< 0.001
Ingeniería (D_Eng)	62.2784	2.1230	< 0.001
Ventas (D_Ven)	32.0904	2.1799	< 0.001
R^2	0.7889		
MSE	233.7135		

Conclusiones

Referencias

Dashboard: una sola dummy

Selector de modelo

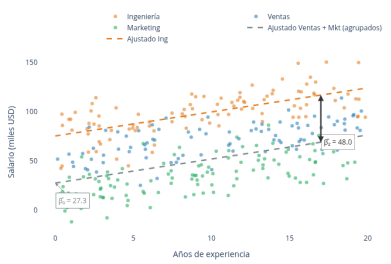
- Sin modelo
- **Solo D_Ing**
- Solo D_Ven
- Solo D_Mkt
- D_Ing + D_Ven (ref: Mkt)
- D_Ing + D_Mkt (ref: Ven)
- D_Ven + D_Mkt (ref: Ing)
- Las tres (trampa)

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_{\text{Eng},i} + \hat{\epsilon}_i$$

Categoría de referencia: Ventas y Mkt agrupados

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	27.3155	2.4164	< 0.001
Experiencia (β_1)	2.4479	0.2001	< 0.001
Ingeniería (D_Eng)	47.9678	2.4797	< 0.001
R^2	0.6343		
MSE	403.4579		

Conclusiones

Referencias

La categoría de referencia

Con Marketing como referencia: $Salario = \beta_0 + \beta_1 Exp + \beta_2 D_{Ing} + \beta_3 D_{Ven} + \varepsilon$.

Departamento	Intercepto	Pendiente
Marketing (referencia)	β_0	β_1
Ingeniería	$\beta_0 + \beta_2$	β_1
Ventas	$\beta_0 + \beta_3$	β_1

- Cada coeficiente de dummy es una **comparación contra la referencia**, controlando por experiencia.
- La diferencia entre Ingeniería y Ventas es $\hat{\beta}_2 - \hat{\beta}_3$ (con su error estándar).
- Cambiar la referencia cambia los coeficientes, **no** las predicciones ni el R^2.

Aplicación: ingresos según estado ocupacional (EAH)

$$\log y = \beta_0 + \beta_1\, aesc + \beta_2\, mujer + \beta_3\, inactivo + \beta_4\, ocupado + \varepsilon \qquad (R^2 = 0{,}306)$$

	Referencia: desocupado	Referencia: ocupado
$\hat{\beta}_{ocupado}$	1.170 (0.041)	—
$\hat{\beta}_{inactivo}$	0.781 (0.043)	-0.389
$\hat{\beta}_{desocupado}$	—	-1.170

- n: 320 desocupados, 7.258 ocupados, 2.470 inactivos (con ingreso positivo).
- Un ocupado gana $\approx e^{1{,}170} - 1 \approx 222\,\%$ más que un desocupado de igual escolaridad y sexo; un inactivo, $\approx e^{0{,}781} - 1 \approx 118\,\%$ más.
- Mismos datos, otra referencia: ocupado − inactivo $= 1{,}170 - 0{,}781 \approx 0{,}39$ (izq.); inactivo − ocupado $= -0{,}389$ (der.).
- Como *estado* es un mediador de la escolaridad (Parte C), **es una descripción, no un efecto causal**.

El supuesto de rectas paralelas y sus límites

- Los modelos con dummies suponen que la **pendiente es la misma** en todos los grupos: la dummy solo desplaza el intercepto.
- ¿Es razonable? En Ingeniería la experiencia técnica acumulada puede valer mucho más que en otras áreas: la pendiente sería mayor y las rectas no serían paralelas.
- Para capturar esto necesitamos una **interacción**: el producto de una dummy por una variable continua.

Explorando pendientes distintas

[Dashboard: Interacciones (`interaction_terms`)] Verdad: pendientes distintas por departamento ($\beta_{Ing} = 3$, $\beta_{resto} = 1$). Modelos: agrupado, solo dummy, completo.

- Con **solo dummy** (rectas paralelas): ¿dónde falla el modelo?
- Con el **modelo completo**: ¿cuánto vale $\hat{\beta}_3$? ¿Coincide con la diferencia de pendientes (≈ 2)?
- Observen cómo mejora el R^2: agrupado $\rightarrow$ solo dummy $\rightarrow$ completo.

Dashboard: solo dummy (rectas paralelas)

Selector de modelo

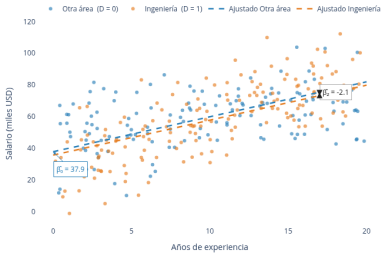
- Sin modelo
- Agrupado (sin dummy)
- **Solo dummy**
- Modelo completo

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_{\text{Engr},i} + \hat{\varepsilon}_i$$

Categoría de referencia: Otra área

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	37.8822	2.1020	< 0.001
Experiencia (β_1)	2.2062	0.1621	< 0.001
Ingeniería (β_2)	-2.1410	1.8881	0.258
R^2	0.3856		
MSE	264.6718		

Conclusiones

Referencias

Dashboard: dummy + interacción

Selector de modelo

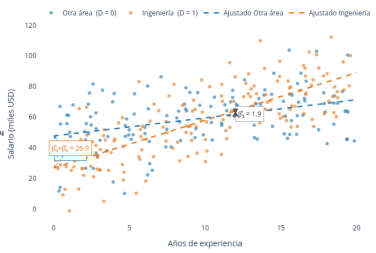
Sin modelo
Agrupado (sin dummy)
Solo dummy
Modelo completo

Modelo estimado:

$$\text{Salary}_i = \hat{\beta}_0 + \hat{\beta}_1 \,\text{Exp}_i + \hat{\beta}_2 \, D_{\text{Eng},i} + \hat{\beta}_3 \,(D_{\text{Eng}}$$

Categoría de referencia: Otra área

Salario vs. años de experiencia



Resultados de la regresión

Variable	Coeficiente	Error estándar	P-valor
Intercepto (β_0)	47.7633	2.5235	< 0.001
Experiencia (β_1)	1.1848	0.2225	< 0.001
Ingeniería (β_2)	-20.8553	3.4605	< 0.001
D_Ing × Exp (β_3)	1.9245	0.3054	< 0.001
R^2	0.4582		
MSE	234.1588		

Conclusiones

Referencias

El modelo con interacción

$$Salario_i = \beta_0 + \beta_1 Exp_i + \beta_2 D_i + \beta_3 (D_i \times Exp_i) + \varepsilon_i$$

$$D = 0: \quad E[Salario \mid Exp] = \beta_0 + \beta_1 \, Exp$$
$$D = 1: \quad E[Salario \mid Exp] = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) \, Exp$$

- β_1: retorno de un año de experiencia en el grupo de referencia ($D = 0$).
- β_3: **diferencia de pendientes** entre los grupos. Si $\hat{\beta}_3 > 0$, cada año de experiencia vale más en Ingeniería.
- β_2: diferencia de interceptos *cuando experiencia* $= 0$, un punto fuera del rango real de los datos: difícil de interpretar.

Centrar la variable continua

- Reemplazamos Exp_i por $\widetilde{Exp}_i = Exp_i - \overline{Exp}$:

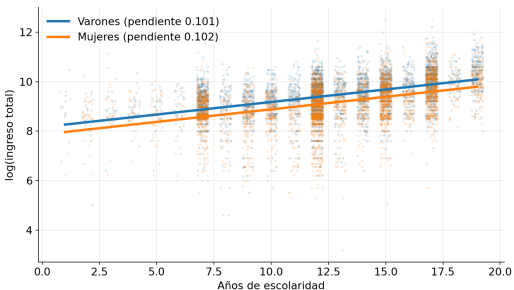
$$Salario_i = \beta_0 + \beta_1 \widetilde{Exp}_i + \beta_2 D_i + \beta_3 (D_i \times \widetilde{Exp}_i) + \varepsilon_i$$

- Ahora β_2 es la brecha entre grupos **para un empleado con experiencia promedio**: un número concreto e interpretable.
- Pendientes, predicciones e inferencia no cambian: es solo una reparametrización.

Aplicación: ¿el retorno de la escolaridad difiere entre varones y mujeres?

$$\log y = \beta_0 + \beta_1\, aesc + \beta_2\, mujer + \beta_3\,(mujer \times aesc) + \varepsilon$$

- Pendiente de varones: $\hat{\beta}_1 = 0{,}1013$.
- Pendiente de mujeres: $\hat{\beta}_1 + \hat{\beta}_3 = 0{,}1016$.
- $\hat{\beta}_3 = 0{,}0002$ ($SE = 0{,}0041$, $t = 0{,}06$, $p = 0{,}95$): **no se rechaza** $H_0 : \beta_3 = 0$.
- El retorno a la escolaridad es el mismo para varones y mujeres: el modelo de rectas paralelas es suficiente.



¿Cuándo usar una interacción?

- Agrega un parámetro: más flexible, pero menos preciso. La pregunta empírica es si la diferencia de pendientes es significativa: el estadístico t de $\hat{\beta}_3$ lo responde.
- Si no se rechaza $H_0 : \beta_3 = 0$ (EAH: sexo $\times$ escolaridad), el modelo de rectas paralelas alcanza.
- El modelo con interacción da **exactamente los mismos coeficientes** que dos regresiones separadas por grupo, pero impone que la varianza del error sea igual en ambos grupos (homocedasticidad). Si eso es dudoso, errores robustos o submuestras.
- Otros ejemplos: SaaS (premium del contrato anual), retail (ingreso por cliente en flagships vs. locales estándar).

Cierre de la clase

- **Regresión múltiple:** β_j es un efecto parcial; FWL: se identifica con la variación propia de x_j.
- **Propiedades:** insesgada bajo M1–M4; $\mathrm{Var}(\hat{\beta}_j) = \sigma^2/[SST_j(1 - R_j^2)]$; la multicolinealidad afecta la precisión, no el sesgo.
- **Especificación:** omitir una variable relevante correlacionada sesga ($\beta_2\delta_1$); incluir una irrelevante cuesta precisión; "más controles" no es siempre mejor.
- **Categóricas:** $k - 1$ dummies; los coeficientes comparan contra la referencia; la interacción permite pendientes distintas.

Próxima clase

Modelos con variable dependiente categórica (logit y probit) e inferencia robusta a heterocedasticidad.

Práctica

Usando la EAH 2016 (log del ingreso total) y los datos de escuelas:

1. Estimar $\log y = \beta_0 + \beta_1\, aesc + \beta_2\, mujer + \varepsilon$ e interpretar ambos coeficientes en porcentajes.
2. Verificar FWL: residualizar *aesc* respecto de *mujer* y *edad*, y regresar $\log y$ sobre el residuo.
3. Agregar *edad* y $edad^2$. ¿A qué edad se maximiza el ingreso? ¿Cambia el coeficiente de *aesc*?
4. Con los datos de escuelas: estimar el IECEP sobre `Privada` con y sin el nivel educativo de la madre; verificar que $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2\hat{\delta}_1$.
5. Estimar la tasa de repetición sobre las tres variables `one_alto_*` y calcular los VIF.
6. Agregar *estado* como categórica y cambiar la categoría de referencia.
7. Testear si el efecto de la escolaridad difiere por sexo (interacción).

Referencias

- Pasquini, R. *Econometrics with Simulations*: Regresión Múltiple: Interpretación, Propiedades y Especificación; Variables Categóricas e Interacciones. Dashboards en simuecon.com.
- Wooldridge, J. *Introductory Econometrics*, caps. 3, 6 y 7.
- Angrist, J. y Pischke, J.-S. *Mostly Harmless Econometrics*, cap. 3.

A.1 Ecuaciones normales y solución matricial

Minimizar *RSS* respecto de cada β_j da $k+1$ condiciones:

$$\sum_i \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{1i} - \cdots - \hat{\beta}_k x_{ki}\right) = 0, \qquad \sum_i x_{ji} \left(y_i - \hat{\beta}_0 - \cdots - \hat{\beta}_k x_{ki}\right) = 0$$

En forma matricial, con X de $n \times (k+1)$ (columna de unos incluida): $X'(y - X\hat{\boldsymbol{\beta}}) = 0$, o

$$\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'y$$

$X'X$ es invertible si y solo si las columnas de X son linealmente independientes (ausencia de multicolinealidad perfecta).

A.2 Insesgadez

Por FWL, con $\tilde{x}_{ij}$ el residuo de regresar x_j sobre los demás regresores (ortogonal a ellos):

$$\hat{\beta}_j = \frac{\sum_i \tilde{x}_{ij} y_i}{\sum_i \tilde{x}_{ij}^2} = \beta_j + \frac{\sum_i \tilde{x}_{ij} \varepsilon_i}{\sum_i \tilde{x}_{ij}^2}$$

(los términos en β_l, $l \neq j$, se anulan porque $\sum_i \tilde{x}_{ij} x_{il} = 0$, y $\sum_i \tilde{x}_{ij} x_{ij} = \sum_i \tilde{x}_{ij}^2$).
Tomando esperanza condicional en X:

$$E[\hat{\beta}_j \mid X] = \beta_j + \frac{\sum_i \tilde{x}_{ij} E[\varepsilon_i \mid X]}{\sum_i \tilde{x}_{ij}^2} = \beta_j \qquad \blacksquare$$

A.3 Varianza de $\hat{\beta}_j$

De A.2, con errores independientes y homocedásticos:

$$\mathrm{Var}(\hat{\beta}_j \mid X) = \frac{\sum_i \tilde{x}_{ij}^2 \, \sigma^2}{\left(\sum_i \tilde{x}_{ij}^2\right)^2} = \frac{\sigma^2}{\sum_i \tilde{x}_{ij}^2}$$

Como $R_j^2 = 1 - \sum_i \tilde{x}_{ij}^2 / SST_j$, se tiene $\sum_i \tilde{x}_{ij}^2 = SST_j(1 - R_j^2)$ y

$$\mathrm{Var}(\hat{\beta}_j \mid X) = \frac{\sigma^2}{SST_j(1 - R_j^2)} \qquad \blacksquare$$

A.4 Sesgo por variable omitida

Verdad $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$; regresión corta de y sobre x_1:

$$\tilde{\beta}_1 = \frac{\sum_i (x_{1i} - \bar{x}_1) y_i}{SST_1} = \beta_1 + \beta_2 \underbrace{\frac{\sum_i (x_{1i} - \bar{x}_1) x_{2i}}{SST_1}}_{\hat{\delta}_1} + \frac{\sum_i (x_{1i} - \bar{x}_1) \varepsilon_i}{SST_1}$$

(se usan $\sum (x_{1i} - \bar{x}_1) = 0$ y $\sum (x_{1i} - \bar{x}_1) x_{1i} = SST_1$). $\hat{\delta}_1$ es la pendiente de x_2 sobre x_1. Esperanza condicional, con $E[\varepsilon \mid x_1, x_2] = 0$:

$$E[\tilde{\beta}_1 \mid X] = \beta_1 + \beta_2 \hat{\delta}_1 \qquad \blacksquare$$

Con la muestra, la identidad $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}_1$ vale **exactamente** (regresión corta, larga y auxiliar).

A.5 Rango deficiente con k dummies

Sean 1_n la columna del intercepto y $\mathrm{d}_1, \ldots, \mathrm{d}_k$ las dummies de una variable con k categorías mutuamente excluyentes y exhaustivas:

$$\mathrm{d}_1 + \cdots + \mathrm{d}_k = 1_n$$

La columna del intercepto es combinación lineal exacta de las dummies: $\mathrm{rank}(X) <$ número de columnas y $X'X$ no tiene inversa. Quitando una columna (una dummy) se recupera el rango completo; esa categoría es la de referencia.

A.6 Interacción $\equiv$ regresiones separadas

Modelo: $y_i = \beta_0 + \beta_1 x_i + \beta_2 D_i + \beta_3 D_i x_i + \varepsilon_i$.

- Para $D_i = 0$: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. Las condiciones MCO restringidas a ese grupo determinan $\hat{\beta}_0, \hat{\beta}_1$ como una regresión simple del grupo.
- Para $D_i = 1$: $y_i = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) x_i + \varepsilon_i$: determinan $\hat{\beta}_0 + \hat{\beta}_2$ y $\hat{\beta}_1 + \hat{\beta}_3$.
- Las cuatro condiciones de primer orden se separan en dos sistemas independientes de dos ecuaciones. Mismos coeficientes que dos regresiones por grupo; la diferencia es que el modelo conjunto impone la misma σ^2 en ambos grupos. ■